

碩士論文口試

整合臨床特徵、劑量體學與影像體學並結合多級知識蒸餾之

乳癌放射治療毒性預測模型研究

A Multimodal Machine Learning Model Integrating Clinical, Dosimetric, and Radiomic Features with Multi-Level Knowledge Distillation for Toxicity Prediction in Breast Cancer Radiotherapy

國立雲林科技大學

電機工程系

指導教授：張廷安 教授

研究生：劉祐誠

2026.07.07


- 研究動機
- 研究目的
- 研究架構與結果
- 相關論文比較
- 結論與貢獻
- 未來展望

1

研究動機

Research Motivation

乳癌為全球女性最常見的惡性腫瘤之一，近年發生率持續上升。根據統計，女性罹患乳癌後的五年存活率約為90%；然而，癌細胞若已發生轉移，五年存活率將下降至約30%。因此，乳癌已成為重要的公共健康議題。




圖片取自：<https://www.uho.com.tw/article-62038.html>

本研究所納入之患者皆接受過腫瘤切除手術，並進行後續放射治療。



手術治療

將癌細胞切除切除範圍取決於
腫瘤的大小、性質和擴散程度



放射治療

利用高能量射線來
局部性消滅癌細胞



化學治療


利用抗癌藥物來破壞癌細胞，
但亦會殺死正常細胞



標靶治療


對特定癌細胞具有針對性能
識別、鎖定並攻擊癌細胞

放射治療是利用高能量放射線來殺死癌細胞，但射線在穿透人體組織的過程中，會不可避免地傷害到皮膚組織進而造成損傷。



圖片取自：Gemini 生成

放射劑量圖



放射性皮膚炎等級

一級

局部輕微發紅、乾脫皮



二級

發紅範圍更廣、出現脫皮、
小塊濕性脫皮


三級

出現大片濕性脫皮、伴隨出血



四級

皮膚壞死潰爛，並影響到生命徵象


圖片取自：<https://heho.com.tw/archives/40574>

2

研究目的

Research Purpose

本研究利用乳癌患者於放射治療規劃階段所獲取之相關資料，建立放射治療副作用等級預測模型，以預測患者治療後可能產生之副作用嚴重程度，並協助臨床醫師於治療規劃階段進行個人化治療方案調整，降低副作用的風險。



3

研究架構與結果

Research Framework and Results


本研究是與雲林虎尾台大分院合作，針對2017年3月到2022年12月期間接受強度調控放術治療的193位乳癌患者資料進行分析 (研究案號: 202110027RINB)。

納入標準：

1. 經病理檢查確認為乳癌
2. 具有完整且高品質的診斷影像資料
3. 具備完整的臨床追蹤紀錄
4. 依據 CTCAE v5.0 評估放射性皮膚炎


排除標準：

1. 病歷資料不完整者
2. 先前有胸腔放射治療史者



01

電腦斷層掃描 (CT)




來源：

電腦斷層掃描影像是手術治療後由臨床常規電腦斷層掃描檢查取得。

02

治療部位 (PTV)



來源：

治療部位由具臨床經驗之醫師於電腦斷層掃描影像上進行人工繪製，以標註目標病灶區域。


03

放射劑量影像 (Dose)




來源：

放射劑量影像由放射治療醫師於放射治療計畫系統中，依據所規劃之治療部位及施打劑量進行設定並產生，用以表示各體素所接收之放射劑量分佈。



影像轉檔步驟:




特徵名稱	定義	Range
Age	年齡	Mean : 55.88 Range: 29-95
Ki67	細胞核蛋白 (評估腫瘤細胞的增殖活性)	Mean : 14.64 Range: 1-60
Tumor size	腫瘤大小(mm)	Mean : 17.55 Range: 1-80
BMI	體重(公斤)除以身高(公尺)的平方	Mean : 25.04 Range: 16-37.1

特徵名稱	定義	數量
Laterality	腫瘤床在胸部上的測性	1:91 2:69
ECOG	生活功能狀態評估	0:85 1:75
T	原發性腫瘤的大小與擴散範圍	0:39 1:78 2:43
LN	淋巴侵犯有無	0:153 1:7
Grade	癌細胞異常程度與惡性程度	1:49; 2:73; 3:36 9:2
Histology type	腫瘤細胞在顯微鏡下的型態	1:137 2:7 3:10 4:3 5:3



特徵名稱	定義	數量
FISH	螢光原位雜交	0:26 1:17 9:117
ER	動情激素接受體檢測	0:16 1:144
Endocrine	內分泌治療	0:23 1:137
Neo/Adj	前導性治療、後續輔助性、 無化療標靶免疫藥物	1:6 2:37 9:117
Chemo	化學治療	0:118 1:42
Target	輔助行標靶治療	0:150 1:10
PR	黃體激素接受體檢測	0:32 1:109 9:19
DoseOfCTVH	最高劑量值	4800 : 63 5005 : 90 5205 : 3 5405 : 4
FxOfCTVH	放射治療照射次數	16 : 63 20 : 89 21 : 3 22 : 5
Her2	免疫組織化學法的實驗數值	0:47 1:37 2:30 3:9 9:37

Radiomics 特徵


Radiomics Feature : 這裡使用兩種影像，**胸腔CT** 和 **PTV治療部位**(影像格式nrrd)，PTV作為Mask使用Pyradiomics提取 Radiomics的一階特徵、形狀特徵、紋理特徵，在這裡命名為 **Radiomics Feature**



diagnostic	diagnostics	diagnostics	diagnostics	diagnostics	original_st	original_st	original_st	original_st	original_st	original_st
-1233.73	-3024	3071	15207	1	0.927399	0.608436	36.18325	59.46927	69.26903	66.20125
-803.602	-1024	3071	1828	1	0.633528	0.390243	14.6998	37.66838	30.0102	28.03874
-1252.6	-3024	3071	7515	1	0.903467	0.494117	25.56271	51.73414	50.82824	56.62721
-1368.6	-3024	3071	6067	1	0.667314	0.299392	17.19498	57.43301	53.94149	40.34427
-1271.75	-3024	3071	31849	1	0.742311	0.660795	55.32115	83.71911	78.00255	90.10191
-1388.64	-3024	3071	8025	1	0.63784	0.277371	20.2853	73.13417	74.70609	59.90826

一階特徵 (first-order features)	紋理特徵 (texture features)	形狀特徵 (shape features)
		
介紹： 描述影像灰階強度的統計分布特性，包括平均值、中位數、標準差、偏態、峰度等，反映影像強度的整體分布。	介紹： 影像灰階強度在空間上的分布與異質性，透過灰階共生矩陣（GLCM）、灰階游程矩陣（GLRLM）、灰階區域大小矩陣（GLSZM）、灰階相依矩陣（GLDM）以及鄰近灰階差異矩陣（NGTDM）等方法，量化區域內影像的結構特徵與紋理模式。	介紹： 量化遮罩區域的幾何外形，例如體積、表面積與體積比及最大直徑等，用於描述腫瘤或目標區域的外形特性。

全乳劑量(第一次治療)



施打劑量：4000 - 4005 cGy

單次治療：250cGy

治療次數：15 - 16次

腫瘤床劑量(第二次治療)



施打劑量：1000 - 1600 cGy


單次治療：50cGy

治療次數：15 - 16次


步驟一：劑量分割

全乳劑量(45Gy) 以5為增量分割出各個區間的DOSE 作為Mask提取Dosiomics特徵


最大劑量 45Gy




0.01Gy - 5.00Gy




5.01Gy - 10.00Gy




10.01Gy - 15.00Gy




15.01Gy - 20.00Gy




20.01Gy - 25.00Gy




25.01Gy - 30.00Gy




30.01Gy - 35.00Gy



35.01Gy - 40.00Gy




40.01Gy - 45.00Gy




步驟一：劑量分割 腫瘤床劑量(10Gy) 以5為增量分割出各個區間的DOSE 作為Mask 提取Dosiomics特徵


最大劑量 10 Gy



0.01Gy - 5.00Gy




5.01Gy - 10.00Gy




Dosiomics 特徵

Dose Feature : 這裡要以兩部分來處理，第一部分要以5為增量分割出各個區間的DOSE作為Mask，第二步使用 Pyradiomics 提取 Dosiomics的一階特徵、形狀特徵、紋理特徵，在這裡命名為 **Dosiomics Feature**

劑量分布圖(nrrd)



劑量區段遮罩(nrrd)



傳統特徵提取



Pyradiomics 套件

一階特徵、形狀特徵、紋理特徵
(112)

結構性資料

250_45_o	250_45_o	250_45_o	250_45_o	250_45_o	250_45_o	250_45_o	250_45_o	50_5_diag	50_5_diag	50_5_diag	50_5_diag	50_5_diag
#####	0.00011	0	0	1000000	0	0	0	0.88799	0	43.4963	234155	11
#####	0.00011	0	0	1000000	0	0	0	0.02795	0	12.5089	124924	1
#####	0.00013	0	0	1000000	0	0	0	0.74232	0	44.0317	116731	6
#####	0.00029	0	0	1000000	0	0	0	0.41555	0	42.1515	223877	8
#####	0.00018	0	0	1000000	0	0	0	0.00979	0	11.9869	73311	1
#####	0.00027	0	0	1000000	0	0	0	1.03609	0	43.8967	96349	12
#####	7.08E-05	0	0	1000000	0	0	0	1.49691	0	44.3152	328313	13

3D Densenet-121



Feature name	特徵數量	格式	使用軟體套件	功能
DS121	12,288	影像	3D Slicer	3D Slicer：用於將nrrd檔轉成nii檔，以便後續丟給DenseNet進行分析，以及特徵提取。 經過3D DenseNet-121特徵提取器，出來的特徵是結構性資料
Radiomics	112	影像	3D Slicer Pyradiomics	3D Slicer：用於將Chest 和PTV的DICOM 檔轉成nrrd檔。 Pyradiomics：此套件將Chest作為影像，PTV作為mask，對該區域進行提取一階、形狀、紋理特徵。
Dosiomics	1232	影像	3D Slicer SimpleITK Pyradiomics	3D Slicer：用於將 RTDose 檔轉成nrrd檔格式。 SimpleITK：3D Slicer 平台中執行，結合 SimpleITK 與 Slicer 的影像處理能力，將放射治療劑量影像(nrrd)依照劑量值範圍進行閾值分割，並自動產生每個區段的二值遮罩（mask），儲存為 NRRD 檔。 Pyradiomics：此套件將Chest作為影像，PTV作為mask，對該區域進行提取一階、形狀、紋理特徵。
Clinical	20	結構性	無	此次份由醫院提供

CSV檔



受試者 ID	放射型皮膚炎 四分類標籤	放射型皮膚炎 二分類標籤	DenseNet-121特徵 (12,288欄)	放射組學特徵 (112欄)	劑量組學特徵(1232欄)	臨床特徵 (20欄)
Sub_001	0	0	[0.013, 0.046,...,0.114]	[0.145, 0.891,...,0.214]	[0.145, 0.891,...,0.214]	[60, 40,...,1]
Sub_002	1	1	[0.026, 0.050,...,0.211]	[0.054, 0.124,...,0.694]	[0.054, 0.124,...,0.694]	[70, 60,...,2]
Sub_003	2	0	[0.041, 0.120,...,0.514]	[0.078, 0.113,...,0.982]	[0.078, 0.113,...,0.982]	[55,80,...,2]
...	...	...	...	...	...	...
Sub_160	3	1	[0.041, 0.120,...,0.514]	[0.078, 0.113,...,0.982]	[0.078, 0.113,...,0.982]	[75,50,...,2]




CSV 檔案中，每列資料對應一位病人的完整特徵資訊。

資料切分


Data : 總數量(訓練 + 測試)

Dermatitis 4 : 0 : 16(13+3) 、 1 : 48(38+10) 、 2 : 81(65+16) 、 3 : 15(12+3)

Dermatitis 2 : 0 : 64(51+13) 、 1 : 96(77+19)



RF




樹生長模式：Depth-wise

樹建立方式：獨立建立 (Bagging)

決策方式：多數投票

模型的穩定性比較高

XGBoost




樹生長模式：Depth-wise

樹建立方式：逐步建立 (Boosting)

決策方式：加權加總

提升整體的預測效能

LightGBM



樹生長模式：Leaf-wise

樹建立方式：逐步建立 (Boosting)

決策方式：加權加總

資訊增益最大的葉節點
進行分裂訓練速度上更快

評估指標

評估指標	公式	說明
 準確率 (Accuracy, ACC)	$\frac{TP + TN}{TP + TN + FP + FN}$	模型正確預測的比例。
 精確率 (Precision)	$\frac{TP}{TP + FP}$	模型預測為陽性時，有多少比例是真的陽性。
 召回率 (Recall)	$\frac{TP}{TP + FN}$	所有真實陽性樣本中，模型正確預測為陽性的比例。
 F1-Score	$2 \times \frac{PPV \times SEN}{PPV + SEN}$	評估模型在找出正例能力與預測正例準確性之間的平衡。


<i>actual</i> <i>Predict</i>	0	1
	0	1
0	True Positive (TP)	False Positive (FP)
1	False Negative (FN)	True Negative (TN)

ROC曲線下面積 (ROC_AUC):

ROC-AUC 是用來評估分類模型整體分類能力的指標，透過整合不同分類閾值下真陽性率與假陽性率的表現，以曲線下面積衡量模型對各類別的區分能力，數值越大代表模型效能越佳。

PR曲線下面積 (PR_AUC):

PR曲線是用來評估分類模型在不同閾值下的精確率與召回率之間的關係，特別適用於類別不平衡的資料集。曲線下的面積越大代表模型在精確率與召回率之間的整體表現越佳。



不同特徵組合對模型表現

4種特徵 11組特徵組合進行分析

	Feature Combination	Feature Count
A	Radiomics + Clinical	132
B	Dosiomics + Clinical	1,252
C	DS121 + Clinical	12,308
D	Radiomics + Dosiomics	1,344
E	Radiomics + DS121	12,400
F	Dosiomics + DS121	13,520
G	DS121 + Radiomics + Dosiomics	13,632
H	DS121 + Radiomics + Clinical	12,420
I	DS121 + Dosiomics + Clinical	13,540
J	Radiomics + Dosiomics + Clinical	1,364
K	DS121 + Radiomics + Dosiomics + Clinical	13,652



Dermatitis 4

ACC

ROC_AUC

Comparison of Model Performance Across Different Feature Combinations in 4-Class Dermatitis Classification

Comparison of Model Performance Across Different Feature Combinations in 4-Class Dermatitis Classification



小結：在預測放射性皮膚炎四分類情況下，(K) Radiomics + Dosiomics + Clinical + DS121 特徵組合模型效能最佳。


不同特徵組合對模型表現

Dermatitis 2


ACC

ROC_AUC


Comparison of Model Performance Across Different Feature Combinations in 2-Class Dermatitis Classification



Comparison of Model Performance Across Different Feature Combinations in 2-Class Dermatitis Classification



小結：在預測放射性皮膚炎(0 - 1)情況下，**Radiomics + Dosiomics + Clinical + DS121** 特徵組合模型效能最佳。雖然Accuracy 跟其他特徵組合比較沒有明顯的突出，但Accuracy 跟 Roc_AUC 綜合評估全特徵K組合效能最佳



傳統基準架構


Dermatitis four class Feature : Radiomics + Dosiomics + Clinical

	Accuracy (95%CI)	ROC_AUC (95%CI)	PR_AUC (95%CI)	Precision (95%CI)	Recall (95%CI)	F1-Score (95%CI)
XGBoost	0.750 (0.594 – 0.875)	0.760 (0.623 – 0.883)	0.525 (0.389 – 0.737)	0.614 (0.301 – 0.870)	0.518 (0.380 – 0.733)	0.521 (0.336 – 0.745)
LightGBM	0.750 (0.594 – 0.875)	0.749 (0.625 – 0.871)	0.537 (0.405 – 0.721)	0.619 (0.307 – 0.725)	0.518 (0.383 – 0.716)	0.524 (0.337 – 0.707)
RF	0.719 (0.563 – 0.875)	0.857 (0.750 – 0.943)	0.698 (0.523 – 0.881)	0.360 (0.273 – 0.565)	0.434 (0.360 – 0.611)	0.393 (0.311 – 0.578)

Dermatitis two class Feature : Radiomics + Dosiomics + Clinical

	Accuracy (95%CI)	ROC_AUC (95%CI)	PR_AUC (95%CI)	Precision (95%CI)	Recall (95%CI)	F1-Score (95%CI)
XGBoost	0.844 (0.719 – 0.969)	0.777 (0.573 – 0.943)	0.811 (0.620 – 0.965)	0.818 (0.647 – 0.985)	0.947 (0.833 – 1.0)	0.878 (0.757 – 0.974)
LightGBM	0.875 (0.750 – 0.969)	0.818 (0.639 – 0.969)	0.853 (0.696 – 0.987)	0.857 (0.700 – 1.0)	0.947 (0.823 – 1.0)	0.900 (0.788 – 0.979)
RF	0.844 (0.719 – 0.969)	0.875 (0.729 – 0.984)	0.908 (0.780 – 0.992)	0.818 (0.650 – 0.957)	0.947 (0.842 – 1.0)	0.878 (0.762 – 0.972)

小結：在傳統架構下，使用 Radiomics + Dosiomics + Clinical 特徵時，LightGBM 在放射性皮膚炎 四分類（0-3）與 二分類（0-1）任務中整體表現最佳，於多數評估指標上皆優於其他模型。



Dermatitis four class Feature : Radiomics + Dosiomics + Clinical + DS121

	Accuracy (95%CI)	ROC_AUC (95%CI)	PR_AUC (95%CI)	Precision (95%CI)	Recall (95%CI)	F1-Score (95%CI)
DS - XGBoost	0.750 (0.594 – 0.906)	0.805 (0.698 – 0.906)	0.627 (0.445 – 0.847)	0.866 (0.342 – 0.938)	0.585 (0.392 – 0.852)	0.641 (0.362 – 0.866)
DS - LightGBM	0.781 (0.625 – 0.906)	0.849 (0.722 – 0.952)	0.698 (0.534 – 0.894)	0.901 (0.379 – 0.953)	0.592 (0.396 – 0.833)	0.655 (0.371 – 0.864)
DS - RF	0.719 (0.563 – 0.875)	0.780 (0.681 – 0.905)	0.564 (0.446 – 0.802)	0.360 (0.273 – 0.565)	0.434 (0.360 – 0.611)	0.393 (0.311 – 0.578)


ACC : ↑ 3.1 %
ROC_AUC : ↑ 10 %

Dermatitis two class Feature : Radiomics + Dosiomics + Clinical + DS121

	Accuracy (95%CI)	ROC_AUC (95%CI)	PR_AUC (95%CI)	Precision (95%CI)	Recall (95%CI)	F1-Score (95%CI)
DS - XGBoost	0.844 (0.719 – 0.969)	0.838 (0.655 – 0.984)	0.852 (0.694 – 0.993)	0.850 (0.684 – 1.0)	0.895 (0.737 – 1.0)	0.872 (0.743 – 0.973)
DS - LightGBM	0.875 (0.750 – 0.969)	0.842 (0.672 – 0.976)	0.868 (0.719 – 0.987)	0.857 (0.70 – 1.0)	0.947 (0.823 – 1.0)	0.900 (0.788 – 0.979)
DS - RF	0.844 (0.719 – 0.969)	0.838 (0.671 – 0.957)	0.881 (0.723 – 0.977)	0.818 (0.636 – 0.957)	0.947 (0.823 – 1.0)	0.878 (0.750 – 0.973)

ACC : ↑ 0 %
ROC_AUC : ↑ 2.4 %

小結 : 在傳統 Radiomics、Dosiomics 與 Clinical 特徵基礎上加入 DS121 深度特徵，在四分類任務中，LightGBM 各項指標皆改善，顯示深度特徵有助於嚴重度分級；二分類任務中，雖然 Accuracy 變化有限，但 ROC-AUC 與 PR-AUC 提升，顯示加入 DS121 深度特徵可以提升放射性皮膚炎預測效能。





● 限制對比自適應直方圖(Contrast Limited Adaptive Histogram Equalization, CLAHE)

CLAHE是一種影像增強技術，透過將影像中原本集中於過亮區域的灰階資訊重新分散至較暗區域，使整體對比度分布更為均勻，使組織結構與影像細節更加清晰。

兩個重要參數：


- ClipLimit：控制對比度增強的強度。
- TileGridSize：控制影像分割成多少小區塊進行局部對比度調整。




- 限制對比自適應直方圖(Contrast Limited Adaptive Histogram Equalization,CLAHE)

CLAHE參數優化曲線圖

TileGridSize : 8



ClipLimit : 2



實驗步驟: 利用CLAHE進行影像增強，再將處理後的CT影像輸入3D DenseNet-121提取深度特徵，最後將特徵輸入LightGBM模型進行分類，並以測試集準確率（Accuracy）評估不同CLAHE參數設定對模型效能之影響。

- 限制對比自適應直方圖(Contrast Limited Adaptive Histogram Equalization,CLAHE)




改成CLAHE處理後重新提取的CT影像特徵



受試者 ID	放射型皮膚炎 四分類標籤	放射型皮膚炎 二分類標籤	DenseNet-121特徵 (12,288欄)	放射組學特徵 (112欄)	劑量組學特徵(1232欄)	臨床特徵 (20欄)
Sub_001	0	0	[0.013, 0.046,...,0.114]	[0.145, 0.891,...,0.214]	[0.145, 0.891,...,0.214]	[60, 40,...,1]
Sub_002	1	1	[0.026, 0.050,...,0.211]	[0.054, 0.124,...,0.694]	[0.054, 0.124,...,0.694]	[70, 60,...,2]
Sub_003	2	0	[0.041, 0.120,...,0.514]	[0.078, 0.113,...,0.982]	[0.078, 0.113,...,0.982]	[55,80,...,2]
...	...	...	...	...	...	...
Sub_160	3	1	[0.041, 0.120,...,0.514]	[0.078, 0.113,...,0.982]	[0.078, 0.113,...,0.982]	[75,50,...,2]

- 合成少數類過採樣技術 (Synthetic Minority Over-sampling Technique, SMOTE)

CSV檔





$$x_{new} = x_i + \lambda * (x_{zi} - x_i) \quad (\text{公式 1})$$

x_i : 少數類樣本

x_{zi} : 從 x_i 的少數類鄰居中隨機挑選的一筆樣本

λ : 一個隨機數，範圍在 $[0, 1]$ ，用於在兩點之間做線性插值





CSV檔

- 最小-最大正規化 (Min-Max Normalization)

Min-Max Normalization 是一種常用的資料標準化方法，目的在於將不同尺度的特徵值映射到固定範圍（通常為 0 到 1 之間），能有效避免因特徵範圍差異過大所造成的模型偏差。

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (\text{公式 2})$$

X ：原始特徵值

X_{min} ：特徵的最小值

X_{max} ：特徵的最大值

X_{norm} ：正規化後的特徵值

本研究提出之完整架構

Dermatitis four class **Feature** : Radiomics + Dosiomics + Clinical + DS121 **State** : CLAHE + SMOTE + Normalization

	Accuracy (95%CI)	ROC_AUC (95%CI)	PR_AUC (95%CI)	Precision (95%CI)	Recall (95%CI)	F1-Score (95%CI)
DS - XGBoost	0.822 (0.689 – 0.933)	0.946 (0.893 – 0.986)	0.884 (0.790 – 0.974)	0.875 (0.784 – 0.955)	0.813 (0.671 – 0.940)	0.835 (0.696 – 0.940)
DS - LightGBM	0.867 (0.756 – 0.956)	0.956 (0.910 – 0.998)	0.908 (0.830 – 0.997)	0.913 (0.836 – 0.974)	0.847 (0.729 – 0.955)	0.868 (0.748 – 0.958)
DS - RF	0.800 (0.667 – 0.911)	0.912 (0.848 – 0.968)	0.809 (0.703 – 0.919)	0.850 (0.759 – 0.939)	0.791 (0.650 – 0.913)	0.811 (0.675 – 0.920)

ACC : ↑ 8.6 %
ROC_AUC : ↑ 10.7 %

Dermatitis two class **Feature** : Radiomics + Dosiomics + Clinical + DS121 **State** : CLAHE + SMOTE + Normalization

	Accuracy (95%CI)	ROC_AUC (95%CI)	PR_AUC (95%CI)	Precision (95%CI)	Recall (95%CI)	F1-Score (95%CI)
DS - XGBoost	0.867 (0.756 – 0.956)	0.902 (0.804 – 0.978)	0.917 (0.815 – 0.985)	0.828 (0.677 – 0.960)	0.960 (0.869 – 1.0)	0.889 (0.784 – 0.964)
DS - LightGBM	0.889 (0.800 – 0.978)	0.898 (0.788 – 0.984)	0.900 (0.764 – 0.988)	0.857 (0.708 – 0.967)	0.960 (0.875 – 1.0)	0.906 (0.809 – 0.980)
DS - RF	0.867 (0.756 – 0.956)	0.926 (0.830 – 0.992)	0.926 (0.815 – 0.995)	0.807 (0.667 – 0.936)	1.0 (1.0 – 1.0)	0.893 (0.800 – 0.967)

ACC : ↑ 1.4 %
ROC_AUC : ↑ 5.6 %

小結：在預測放射性皮膚炎(0 - 1)情況下，Radiomics + Dosiomics + Clinical + DS121 特徵組合模型效能最佳。雖然Accuracy 跟其他特徵組合比較沒有明顯的突出，但Accuracy 跟 Roc_AUC 綜合評估全特徵組合效能最佳


放射性皮膚炎四級分類 SHAP

250 : 全乳劑量 ; 50 : 腫瘤床劑量


250_5 : 劑量區段 ; 250_5_feature : 3D Densenet-121 提取特徵

250_5_接其他名稱 : Pyradiomics 提取特徵


Class0





Class1





Class2




放射性皮膚炎四級分類 SHAP



放射性皮膚炎二級分類 SHAP



使用SHAP平均特徵貢獻度排名前500名特徵出來進行篩選



Dermatitis four class **Feature** : Radiomics + Dosiomics + Clinical + DS121 **State** : CLAHE + SMOTE + Normalization + Feature selection (400)

	Accuracy (95%CI)	ROC_AUC (95%CI)	PR_AUC (95%CI)	Precision (95%CI)	Recall (95%CI)	F1-Score (95%CI)
DS - XGBoost	0.822 (0.689 – 0.933)	0.934 (0.877 – 0.981)	0.841 (0.737 – 0.956)	0.879 (0.793 – 0.962)	0.804 (0.667 – 0.938)	0.827 (0.681 – 0.938)
DS - LightGBM	0.867 (0.756 – 0.956)	0.940 (0.881 – 0.991)	0.881 (0.785 – 0.978)	0.910 (0.826 – 0.978)	0.854 (0.731 – 0.964)	0.875 (0.756 – 0.965)
DS - RF	0.800 (0.689 – 0.911)	0.944 (0.898 – 0.982)	0.880 (0.799 – 0.960)	0.857 (0.768 – 0.940)	0.791 (0.662 – 0.906)	0.808 (0.675 – 0.912)

ACC : ↓ 0 %
ROC_AUC : ↓ 1.6 %


Dermatitis two class **Feature** : Radiomics + Dosiomics + Clinical + DS121 **State** : CLAHE + SMOTE + Normalization + Feature selection (50)

	Accuracy (95%CI)	ROC_AUC (95%CI)	PR_AUC (95%CI)	Precision (95%CI)	Recall (95%CI)	F1-Score (95%CI)
DS - XGBoost	0.867 (0.756 – 0.956)	0.896 (0.784 – 0.983)	0.897 (0.768 – 0.990)	0.828 (0.686 – 0.958)	0.960 (0.869 – 1.0)	0.889 (0.792 – 0.964)
DS - LightGBM	0.889 (0.778 – 0.978)	0.882 (0.765 – 0.974)	0.893 (0.775 – 0.979)	0.833 (0.688 – 0.962)	1.0 (1.0 – 1.0)	0.909 (0.815 – 0.980)
DS - RF	0.867 (0.756 – 0.956)	0.896 (0.795 – 0.980)	0.908 (0.803 – 0.985)	0.828 (0.679 – 0.962)	0.960 (0.871 – 1.0)	0.889 (0.792 – 0.964)

ACC : ↓ 0 %
ROC_AUC : ↓ 1.6 %

小結 :在預測放射性皮膚炎 0–3 級時，需篩選約 400 個特徵就能維持最佳表現；而在 0–1 級預測下，僅需 50 個特徵就可達到穩定效果。即使特徵數量明顯減少，各項指標並未顯著下降，顯示特徵篩選能在不影響效能的情況下有效降低模型負擔。

由於前述模型多為複雜的模型架構，雖然預測效果不錯，但運算量較大，因此本研究進一步導入知識蒸餾技術。透過將教師模型的知識傳遞給學生模型，讓較小的模型也能學習到重要特徵，進而在維持預測效能的同時，大幅降低模型複雜度與運算成本。



- 硬標籤損失計算(Hard Label)

Step 1 : logits_student = [2.0, 0.5, -1.0, 0.2]

Step 2 : 轉成softmax 機率 : $p_i^{student}$ $\longrightarrow$ $p_i = \frac{\exp(z_i)}{\sum_{j=1}^4 \exp(z_j)}$ $\longrightarrow$ $\underline{p_student = [0.695, 0.155, 0.035, 0.115]}$
模型預測

Step 3 : 假設樣本真實類別是1類別時 $\rightarrow y = [1, 0, 0, 0]$

套用交叉熵公式：

$$L_{Hard} = -\sum_i y_i \log(p_i^{student}) = \underbrace{-(1 * \log(0.695))}_{1 \text{ 類}} + \underbrace{0 * \log(0.155)}_{2 \text{ 類}} + \underbrace{0 * \log(0.035)}_{3 \text{ 類}} + \underbrace{0 * \log(0.115)}_{4 \text{ 類}} = 0.364 \quad (\text{公式 3})$$

當模型預測越接近真實標籤時，損失值越小；反之，若預測錯誤，損失值則會增加。訓練過程中會透過反向傳播持續更新模型參數，以提升分類效能。


● 軟標籤計算 (Soft label)

logits = [z1, z2, z3, z4]
[3.2, 1.1, -0.5, 0.7]

$$p_i = \frac{\exp(z_i/T)}{\sum_{j=1}^4 \exp(z_j/T)}$$

溫度軟化機率分布

教師模型軟標籤計算



類別	z_i	z_i / T
1	3.2	0.800
2	1.1	0.275
3	-0.5	-0.125
4	0.7	0.175

類別	z_i / T	$\exp(z_i / T)$
1	0.800	2.225
2	0.275	1.317
3	-0.125	0.882
4	0.175	1.191

$$\sum_{j=1}^4 \exp(z_j/T) = 2.225 + 1.317 + 0.882 + 1.191 = 5.615$$


類別	$\exp(z_i/T)$	soft label p_i
1	2.225	$2.225 / 5.615 = 0.3958$
2	1.317	$1.317 / 5.615 = 0.2346$
3	0.882	$0.882 / 5.615 = 0.1571$
4	1.191	$1.191 / 5.615 = 0.2121$

轉換成軟標籤機率分布(相加為1)

logits = [z1, z2, z3, z4]
[2.0, 0.5, -1.0, 0.2]

$$p_i = \frac{\exp(z_i/T)}{\sum_{j=1}^4 \exp(z_j/T)}$$

學生模型軟標籤計算



類別	z_i	z_i / T
1	2.0	0.5
2	0.5	0.125
3	-1.0	-0.25
4	0.2	0.05

類別	z_i / T	$\exp(z_i / T)$
1	0.5	1.649
2	0.125	1.133
3	-0.25	0.779
4	0.05	1.051

$$\sum_{j=1}^4 \exp(z_j/T) = 1.649 + 1.133 + 0.779 + 1.051 = 4.612$$

類別	$\exp(z_i/T)$	soft label p_i
1	1.649	$1.649 / 4.612 = 0.357$
2	1.133	$1.133 / 4.612 = 0.246$
3	0.779	$0.779 / 4.612 = 0.169$
4	1.051	$1.051 / 4.612 = 0.228$

轉換成軟標籤機率分布(相加為1)


● 溫度軟化機率分布(Temperature, T)

原始機率分布

logits = [z1, z2, z3, z4]=[3.2, 1.1, -0.5, 0.7]

$$p_i = \frac{\exp(z_i)}{\sum_{j=1}^4 \exp(z_j)} \quad (\text{公式 4})$$

類別	$\exp(z_i)$	soft label p_i
1	24.53253	$24.53253 / 30.1568 = 0.813$
2	3.00417	$3.00417 / 30.1568 = 0.100$
3	0.60653	$0.60653 / 30.1568 = 0.020$
4	2.01375	$2.01375 / 30.1568 = 0.067$




原始機率分布只會讓學生模型學到「答案最可能的那一類」，而無法學到類別之間的相對關係。

軟化的機率分布

logits = [z1, z2, z3, z4]=[3.2, 1.1, -0.5, 0.7]

$$p_i = \frac{\exp(z_i/T)}{\sum_{j=1}^4 \exp(z_j/T)} \quad (\text{公式 5})$$

類別	$\exp(z_i/T)$	soft label p_i
1	2.225	$2.225 / 5.615 = 0.3958$
2	1.317	$1.317 / 5.615 = 0.2346$
3	0.882	$0.882 / 5.615 = 0.1571$
4	1.191	$1.191 / 5.615 = 0.2121$



軟化過後 ($T > 1$) 的機率分布，學生模型不僅能學到「答案最可能的那一類」，也能學到其他類別之間的相對關係

- 教師與學生軟標籤損失計算 (Soft label loss)

教師模型軟標籤

類別	$\exp(z_i/T)$	soft label p_i
1	2.225	$2.225 / 5.615 = 0.3958$
2	1.317	$1.317 / 5.615 = 0.2346$
3	0.882	$0.882 / 5.615 = 0.1571$
4	1.191	$1.191 / 5.615 = 0.2121$

學生模型軟標籤

類別	$\exp(z_i/T)$	soft label p_i
1	1.649	$1.649 / 4.612 = 0.357$
2	1.133	$1.133 / 4.612 = 0.246$
3	0.779	$0.779 / 4.612 = 0.169$
4	1.051	$1.051 / 4.612 = 0.228$

用 **KL Divergence** 衡量學生軟標籤和教師軟標籤差異：

$$L_{soft} = \sum_i p_i^{teacher} \cdot \log \frac{p_i^{teacher}}{p_i^{student}} \quad (\text{公式 6})$$

$$L_{soft} = \underbrace{0.396 \cdot \log(0.396/0.357)}_{1 \text{ 類}} + \underbrace{0.235 \cdot \log(0.235/0.246)}_{2 \text{ 類}} + \underbrace{0.157 \cdot \log(0.157/0.169)}_{3 \text{ 類}} + \underbrace{0.212 \cdot \log(0.212/0.228)}_{4 \text{ 類}} = 0.003$$

- 總損失計算 (Soft label loss)

設定 $\alpha = 0.5$


$$L_{total} = \alpha L_{Hard} + (1-\alpha) L_{soft} \quad (\text{公式 7})$$

$$= 0.5 * 0.364 + (1 - 0.5) * 0.003$$

$$= 0.182 + 0.0015$$

$$= 0.1835$$

- 架構1：單一教師知識蒸餾架構



	模型大小	推論速度(平均推論時間)
Teacher (DS-LightGBM)	0.241 MB	0.02 ms
Student DS-MLP (2 Layer,64neurons)	0.122 MB	0.129 ms




單一知識蒸餾架構

Dermatitis four class

Feature : Radiomics + Dosiomics + Clinical + DS121

State : CLAHE + SMOTE + Normalization + Feature selection (400)




	Accuracy (95%CI)	ROC_AUC (95%CI)	PR_AUC (95%CI)	Precision (95%CI)	Recall (95%CI)	F1-Score (95%CI)
Teacher model (DS - LightGBM)	0.867 (0.756 – 0.956)	0.940 (0.881 – 0.991)	0.881 (0.785 – 0.978)	0.910 (0.826 – 0.978)	0.854 (0.731 – 0.964)	0.875 (0.756 – 0.965)
Distilled student model DS-MLP(2 Layer,64neurons)	0.822 (0.711 – 0.933)	0.907 (0.809 – 0.981)	0.833 (0.723 – 0.953)	0.836 (0.706 – 0.936)	0.816 (0.702 – 0.926)	0.819 (0.681 – 0.924)
Baseline model DS-MLP (2Layer,64neurons)	0.800 (0.689 – 0.911)	0.913 (0.833 – 0.986)	0.837 (0.739 – 0.961)	0.813 (0.700 – 0.917)	0.819 (0.695 – 0.929)	0.813 (0.683 – 0.913)



單一知識蒸餾架構


Dermatitis two class **Feature** : Radiomics + Dosimetrics + Clinical + DS121 **State** : CLAHE + SMOTE + Normalization + Feature selection (400)

	Accuracy (95%CI)	ROC_AUC (95%CI)	PR_AUC (95%CI)	Precision (95%CI)	Recall (95%CI)	F1-Score (95%CI)
Teacher model (DS - LightGBM)	0.889 (0.778 – 0.978)	0.882 (0.765 – 0.974)	0.893 (0.775 – 0.979)	0.833 (0.688 – 0.962)	1.0 (1.0 – 1.0)	0.909 (0.815 – 0.980)
Distilled student model DS-MLP (2-layer, 64 neurons)	0.867 (0.778 – 0.956)	0.902 (0.790 – 0.992)	0.898 (0.774 – 0.994)	0.807 (0.647 – 0.933)	1.0 (1.0 – 1.0)	0.893 (0.786 – 0.966)
Baseline model DS-MLP (2-layer, 64 neurons)	0.844 (0.733 – 0.933)	0.866 (0.716 – 0.982)	0.809 (0.640 – 0.986)	0.800 (0.643 – 0.931)	0.960 (0.871 – 1.0)	0.873 (0.764 – 0.952)



多級知識蒸餾架構

● 架構2：多級知識蒸餾架構



$$\text{Weight1} = w_1 \times L_{\text{Soft1}} + w_2 \times L_{\text{Soft2}}$$

$$\text{Weight2} = w_1 \times L_{\text{Soft1}} + w_2 \times L_{\text{Soft2}} + w_3 \times L_{\text{Soft3}}$$

$$\text{KD} = \text{Loss} = \alpha \times L_{\text{Hard}} + (1-\alpha) \times L_{\text{Soft}}$$

	Model size	Model speed
Teacher1 (DS-LightGBM)	0.241 MB	0.02 ms
Teacher2 (DS-XGBoost)	0.247MB	0.33ms
Assistant model DS-MLP (2 Layer,64neurons)	0.122 MB	0.129 ms
Student model DS-MLP (2 Layer,32neurons)	0.0597 MB	0.125 ms

多級知識蒸餾架構

Dermatitis four class






Feature : Radiomics + Dosiomics + Clinical + DS121

State : CLAHE + SMOTE + Normalization + Feature selection (400)

	Accuracy (95%CI)	ROC_AUC (95%CI)	PR_AUC (95%CI)	Precision (95%CI)	Recall (95%CI)	F1-Score (95%CI)
Teacher model 1 DS-LightGBM	0.867 (0.756 – 0.956)	0.940 (0.881 – 0.991)	0.881 (0.785 – 0.978)	0.910 (0.826 – 0.978)	0.854 (0.731 – 0.964)	0.875 (0.756 – 0.965)
Teacher model 2 DS-XGBoost	0.822 (0.689 – 0.933)	0.934 (0.877 – 0.981)	0.841 (0.737 – 0.956)	0.879 (0.793 – 0.962)	0.804 (0.667 – 0.938)	0.827 (0.681 – 0.938)
Assistant model DS-MLP (2 Layer, 64neurons)	0.844 (0.733 – 0.956)	0.915% (0.836 – 0.986)	0.841 (0.745 – 0.963)	0.861 (0.750 – 0.961)	0.832 (0.713 – 0.946)	0.842 (0.718 – 0.945)
Distilled student model (DS-MLP) (2 Layer, 32neurons)	0.867 (0.756 – 0.956)	0.910 (0.830 – 0.985)	0.836 (0.731 – 0.964)	0.905 (0.821 – 0.972)	0.847 (0.737 – 0.950)	0.859 (0.731 – 0.953)
Baseline model (DS-MLP) (2 Layer, 32neurons)	0.822 (0.711 – 0.933)	0.897 (0.801 – 0.981)	0.828 (0.728 – 0.956)	0.850 (0.732 – 0.947)	0.807 (0.692 – 0.916)	0.814 (0.685 – 0.919)

第一層蒸餾
雙教師蒸餾助教

第二層蒸餾
雙教師 + 助教
蒸餾學生



多級知識蒸餾架構

Dermatitis two class





Feature : Radiomics + Dosiomics + Clinical + DS121

State : CLAHE + SMOTE + Normalization + Feature selection (400)

	Accuracy (95%CI)	ROC_AUC (95%CI)	PR_AUC (95%CI)	Precision (95%CI)	Recall (95%CI)	F1-Score (95%CI)
Teacher model 1 (DS-LightGBM)	0.889 (0.778 – 0.978)	0.882 (0.765 – 0.974)	0.893 (0.775 – 0.979)	0.833 (0.688 – 0.962)	1.0 (1.0 – 1.0)	0.909 (0.815 – 0.980)
Teacher model 2 (DS-XGBoost)	0.867 (0.756 – 0.956)	0.896 (0.784 – 0.983)	0.897 (0.768 – 0.990)	0.828 (0.686 – 0.958)	0.960 (0.869 – 1.0)	0.889 (0.792 – 0.964)
Assistant model DS-MLP(2 Layer, 64neurons)	0.867 (0.756 – 0.956)	0.900 (0.788 – 0.992)	0.863 (0.702 – 0.995)	0.852 (0.708 – 0.966)	0.920 (0.800 – 1.0)	0.885 (0.783 – 0.964)
Distilled student model DS-MLP (2 Layer, 32 neurons)	0.889 (0.800 – 0.978)	0.890 (0.770 – 0.994)	0.852 (0.692 – 0.995)	0.857 (0.708 – 0.968)	0.960 (0.870 – 1.0)	0.906 (0.810 – 0.980)
Baseline model DS-MLP (2 Layer, 32neurons)	0.844 (0.733 – 0.933)	0.900 (0.780 – 0.991)	0.875 (0.730 – 0.995)	0.846 (0.682 – 0.966)	0.880 (0.742 – 1.0)	0.863 (0.744 – 0.952)

第一層蒸餾
雙教師蒸餾助教

第二層蒸餾
雙教師 + 助教
蒸餾學生



4

相關論文比較

Comparison of Related Studies

Authors	Present study	Lee et al. (2024)	Bagherpour et al.(2025)
Patient number	160	102	78
Endpoint	RD ≥ 2	RD ≥ 2	RD ≥ 2
Model	Distilled DS-MLP	RF	RF
Feature types	Clinical + Radiomics + Dosimetrics + DS121 features	Clinical + Radiomics + Dosimetrics	Clinical + Radiomics + Dosimetrics
ACC(%)	88.89	77.00	75.00
ROC-AUC(%)	89.00	83.00	74.00
F1 (%)	90.60	54.00	74.00

沒有放射性皮膚炎四級分類的相關論文 在這只比較二級分類

5

結論與貢獻

Contributions and Conclusions

1 提出多級知識蒸餾架構

本研究提出一種多級知識蒸餾架構，在多級架構上，透過不同規模與複雜度之教師模型、助教模型與學生模型進行分層式知識傳遞，使學生模型能有效學習高階決策資訊與隱含特徵表徵。此架構不僅提升模型效能，同時兼顧模型輕量化與實際應用可行性。

2 資料蒐集

本研究之臨床資料與醫學影像資料是與虎尾台大醫院共同配合取得，此資料集命名為虎尾台大乳癌患者資料集。資料集內部包含160位乳癌患者臨床資訊、CT影像、患者治療劑量及範圍等資訊，並已通過院內人體研究倫理委員會審核（IRB編號：202110027RINB）。

3 特徵萃取與創新

本研究於傳統 pyradiomic 特徵萃取方法之基礎上，進一步導入深度學習模型 DenseNet-121 進行深度特徵提取，建立結合手工特徵與深度特徵之混合式特徵架構。實驗結果顯示，相較於僅使用傳統 pyradiomic 特徵之模型，所提出之特徵融合方法可提升模型準確率達 3.1%，顯示深度特徵對模型辨識能力具有顯著增益效果。

4 影像與資料前處理流程建構

本研究建構完整之影像與資料處理流程，涵蓋影像標準化與影像增強、資料平衡處理及特徵篩選等機制，以提升資料品質與模型學習效果。實驗結果顯示，透過所建立之系統化處理架構，可使模型整體預測效能提升8.6%，顯示本研究流程具有實質增益效果。

5 提出新型分類模型建構

本研究提出一種新型分類模型建構方法，融合深度學習與傳統機器學習之優勢，建立混合式分類架構。首先以 DenseNet-121 作為特徵擷取器，從醫學影像中萃取高維深度特徵，並將其輸入至不同機器學習分類器，進而建構 DS 系列分類模型（包括 DS-LightGBM、DS-XGBoost 與 DS-RF），以提升模型之預測效能與穩定性。

6

未來展望

Feature Work

- 持續擴充資料來源，納入多中心與不同醫療設備之資料，以提升模型之泛化能力與臨床適用性。
- 擴大整體資料量並進行更完整之外部驗證，以提升模型穩定性與可靠性。
- 延伸發展多域多級知識蒸餾架構，以強化不同模型與不同模態間之知識轉移與融合能力。

謝謝各位聆聽