



國立台灣科技大學
電子工程系

碩士學位論文

基於不同教師模型架構進行知識蒸餾之研究
**Study of Knowledge Distillation Based on Various
Teacher Model Architectures**

黃郁雯
M10702152

指導教授：呂政修 博士

中華民國 110 年 1 月 19 日



碩士學位論文指導教授推薦書

Master's Thesis Recommendation Form



M10702152

系所：

電子工程系

Department/Graduate Institute

Department of Electronic and Computer Engineering

姓名：

黃郁雯

Name

HUANG, YU-WEN

論文題目：

基於不同教師模型架構進行知識蒸餾之研究

(Thesis Title)

Study of Knowledge Distillation Based on Various Teacher Model Architectures

係由本人指導撰述，同意提付審查。

This is to certify that the thesis submitted by the student named above, has been written under my supervision. I hereby approve this thesis to be applied for examination.

指導教授簽章：

Advisor's Signature

呂政修

共同指導教授簽章（如有）：

Co-advisor's Signature (if any)

日期：

Date(yyyy/mm/dd)

110, 01, 19



碩士學位考試委員審定書
Qualification Form by Master's Degree Examination Committee



M10702152

系所： 電子工程系
Department/Graduate Institute Department of Electronic and Computer Engineering
姓名： 黃郁雯
Name HUANG, YU-WEN
論文題目： 基於不同教師模型架構進行知識蒸餾之研究
(Thesis Title) Study of Knowledge Distillation Based on Various Teacher Model Architectures

經本委員會審定通過，特此證明。

This is to certify that the thesis submitted by the student named above, is qualified and approved by the Examination Committee.

學位考試委員會

Degree Examination Committee

委員簽章：

Member's Signatures

謝序文 周承隆
王瑞堂 呂政修

指導教授簽章：

Advisor's Signature

呂政修

共同指導教授簽章（如有）：

Co-advisor's Signature (if any)

廖顯奎

系所（學程）主任（所長）簽章：

Department/Study Program/Graduate Institute Chair's Signature

日期：

Date(yyyy/mm/dd)

110 / 01 / 19

基於不同教師模型架構進行知識蒸餾之研究

研究生：黃郁雯

指導教授：呂政修

時間：中華民國一百一十年一月

論文摘要

隨著類神經網路技術的高度發展，為了符合更複雜且高準確度要求的使用情境，近年來被提出的類神經網路的模型體積愈來愈龐大，運算複雜度也不斷提升，而擁有良好辨識能力的網路模型往往伴隨著相當高的硬體需求。為了使複雜的模型能夠實際部署在有限效能的硬體平台上，多種模型壓縮技術隨之誕生，其中知識蒸餾提取複雜教師模型的知識轉移到相對小的學生模型架構上，進而達到提高模型效能的結果。




本論文基於知識蒸餾探討兩種教師模型架構，分別為未完整訓練教師架構與多教師助教架構：未完整訓練教師架構是使用沒有經過完整訓練的教師模型蒸餾學生模型，本論文嘗試使用不同程度的未完整訓練教師模型進行蒸餾，經實驗結果顯示其蒸餾效果與經過完整訓練的教師模型相同，更可以大幅縮短訓練時間；本論文也提出多教師助教模型架構，其結合了多教師模型架構與助教模型架構，經實驗結果顯示蒸餾效果優於原先兩種架構。最後再將未完整訓練教師架構與多教師助教架構結合，使得知識蒸餾可以提升準確率和減少模型的訓練時間。

關鍵字：深度學習、模型壓縮、知識蒸餾、圖像辨識

ABSTRACT

With the rapid development of neural network technology, in order to meet more complex and high accuracy requirements, the model volume of neural network proposed in recent years has become larger and larger, and the computational complexity has also increased. Network models with good recognition capabilities are often accompanied by high hardware requirements. In order to enable complex models to be actually deployed on hardware platforms with limited performance, a variety of model compression techniques have emerged. Among them, knowledge distillation extracts the knowledge of the complex teacher model and transfers it to the relatively small student model, thereby achieving the result of improving the effectiveness of the model.



In this paper, we explore two teacher model architectures based on knowledge distillation, namely Poorly-Trained-Teacher and Multi-Teacher-Assistant. Poorly-Trained-Teacher is to extract knowledge from a incompletely trained teacher model and transfer it to a student model, we try several teacher models that were trained with different epochs for knowledge distillation. The experimental results show that the performance of Poorly-Trained-Teacher model is much the same as that of the fully trained teacher model, but the training time can be greatly shortened. We also propose Multi-Teacher-Assistant architecture, which combines the multi-teacher architecture and teacher-assistant architecture, the experimental results show that the performance is better than the original two architectures. Finally, we merge two proposed architectures, so that it can improve the accuracy and reduce the model training time as well.

Keywords—Deep learning, Model Compression, Knowledge Distillation

致謝

這篇論文能夠完成首先先感謝呂政修教授，在我研究生生涯感到迷惘時拉了我一把，真的由衷感謝；感謝王瑞堂教授讓我接觸了很多不一樣的案子，學到很多不同的東西；感謝口委周承復教授以及衛信文教授，感謝在百忙之中抽空參加論文口試，給予指導及建議。

感謝 MITLab 的大家，感謝俊邦給了我論文很多的指導及建議，也感謝景文、譯勻、品禎、士逸、少鏞、時新各位的照顧；感謝婉萍、雨承、鈺清，在這段時間幫助我很多；感謝學弟妹們家乘、昱明、勝安、偉倫、和軒、岱樺、又瑜、映澄、祐瑞、冠霖、宏毅、於樵，讓我最後的實驗室生活過得很開心。還有感謝明紘、書維、思之、心瑜、雅珩、書華、柏毅、家瑋、易霖、喻至，我絕對不會忘記那段曾經一起同甘共苦的日子。

最後感謝我的家人們，都無條件的支持任何我想做的事，讓我沒有後顧之憂的完成學業，有你們才有今天的我；也真誠的感謝在我求學過程中關心及幫助過我的大家，希望大家在這亂世中都能身體健康，平安快樂。

郝雯 謹誌

中華民國一百一十年一月

目錄

基於不同教師模型架構進行知識蒸餾之研究	I
論文摘要.....	I
ABSTRACT.....	II
致謝.....	III
目錄.....	IV
圖片索引.....	VI
第 1 章 緒論	1
1.1 研究背景與動機.....	1
1.2 研究目的.....	3
1.3 章節提要.....	4
第 2 章 相關技術	5
2.1 剪枝.....	5
2.2 量化.....	6
2.3 低秩分解.....	7
2.4 知識蒸餾.....	8
第 3 章 研究方法	9
3.1 知識蒸餾.....	9
3.1.1 知識蒸餾架構.....	9
3.1.2 Soft Target.....	10
3.1.3 Temperature	12
3.1.4 Cross Entropy	13
3.2 知識蒸餾教師架構設計.....	15
3.2.1 未完整訓練教師	15
3.2.2 多教師助教模型	16

第 4 章 實驗結果	19
4.1 實驗準備	19
4.1.1 實驗環境	19
4.1.2 實驗資料集	20
4.1.3 模型網路架構	21
4.2 實驗結果	23
4.2.1 未完整訓練教師	23
4.2.2 多教師助教模型	27
第 5 章 結論	31
參考文獻	32



圖片索引

圖 1、神經網路示意圖.....	2
圖 2、剪枝示意圖.....	5
圖 3、量化示意圖.....	6
圖 4、低秩分解示意圖.....	7
圖 5、知識蒸餾示意圖.....	8
圖 6、知識蒸餾架構圖.....	9
圖 7、Soft Target 示意圖.....	10
圖 8、不同溫度對於模型輸出機率影響折線圖.....	12
圖 9、Loss Function 示意圖.....	14
圖 10、Underfitting 與 Overfitting 示意圖.....	15
圖 11、一般知識蒸餾架構示意圖.....	16
圖 12、多教師架構示意圖.....	16
圖 13、助教架構示意圖.....	17
圖 14、多教師助教架構示意圖.....	17
圖 15、Soft Loss 修改示意圖.....	18
圖 16、CIFAR-10 資料集示意圖.....	20
圖 17、LeNet 架構圖.....	21
圖 18、Residual Block 示意圖.....	22
圖 19、教師模型 CNN30 不同訓練次數蒸餾比較折線圖.....	23
圖 20、教師模型 CNN10 不同訓練次數蒸餾比較折線圖.....	24
圖 21、教師模型 CNN8 不同訓練次數蒸餾比較折線圖.....	24
圖 22、教師模型 ResNet110 不同訓練次數蒸餾比較折線圖.....	25
圖 23、教師模型 ResNet56 不同訓練次數蒸餾比較折線圖.....	25
圖 24、CNN2 在不同蒸餾架構下準確率比較圖.....	28

圖 25、CNN4 在不同蒸餾架構下準確率比較圖	28
圖 26、CNN2(EPOCH=50)在不同蒸餾架構下準確率比較圖	29
圖 27、CNN2(EPOCH=5)在不同蒸餾架構下準確率比較圖	29
圖 28、ResNet20(EPOCH=50)在不同蒸餾架構下準確率比較圖	30
圖 29、ResNet20(EPOCH=5)在不同蒸餾架構下準確率比較圖	30



第 1 章 緒論

1.1 研究背景與動機

人工智慧 (Artificial Intelligence, AI) 一詞最初是在 1956 年達特茅斯 (Dartmouth) 會議上提出，指透過電腦程式來呈現人類智慧的技術。推動人工智慧技術發展的三大因素，分別為運算能力、演算法及資料儲存成本。這三個領域的發展分別推動了軟硬體產業的發展。根據摩爾定律 (Moore's Law)，過了將近半個世紀，伴隨著硬體的提升，大數據、感測器的普及，運算能力增加和儲存成本下降，機器學習 (Machine Learning)、深度學習 (Deep Learning) 等 AI 分支也隨之興起。其中 2016 年 AlphaGo 利用深度學習，透過不斷反覆自己與自己下棋的訓練，打敗了韓國職業圍棋棋士李世乭，更是把人工智慧推向另一個高峰。



在這數據化的時代，深度學習早已深入生活之中。舉例來說，手機語音助理，例如蘋果 Siri 與 Google 助理，運用了自然語言處理 (Natural Language Processing, NLP) 技術與語音辨識 (Speech Recognition) 技術；上班打卡的門禁系統結合人臉辨識 (Facial Recognition) 和自動駕駛的圖像辨識 (Image Recognition)；又或者是 Spotify 跟 Netflix 上的推薦系統等。所謂的深度學習，是透過模仿人腦的類神經網路 (Neural Network, NN) 來學習大量資料的手法。而在越複雜精細的應用上，神經網路更需要大量的計算和記憶體，模型複雜度也不斷升高，導致模型體積趨於龐大繁重，因此很難在嵌入式系統上進行部署。




圖 1、神經網路示意圖

為了解決模型過於龐大，導致實際部屬應用時硬體效能難以負荷的問題，模型壓縮(Model Compression)技術隨之產生。模型壓縮技術大致可分為四類：剪枝(Pruning)、量化(Quantization)、低秩分解(Low-Rank Factorization)、知識蒸餾(Knowledge Distillation)。各種技術之間可以互相結合，例如 Google 的 Learn2Compress 技術[1]就是結合剪枝、量化、知識蒸餾；Antonio Polino 提出量化結合知識蒸餾[2]等。其中知識蒸餾是抽取複雜教師模型訓練出的精華為另一個簡單學生模型所用，讓學生模型也能達到跟教師模型一樣的效果。

1.2 研究目的

近年來研究發現知識蒸餾有許多可以探討問題，例如：Seyed Iman Mirzadeh 的實驗結果顯示準確率高的教師蒸餾效果比準確率低的教師蒸餾效果還差[3]；Li Yuan 使用沒有完整訓練的教師蒸餾也可以提升學生的準確率[4]；Jang Hyun Cho 的實驗結果顯示在溫度 T 過高時經過蒸餾反而比沒有經過蒸餾效果還差[5]；Qizhe Xie 提出學生自己蒸餾自己也可以提升準確率[6]等。

基於以上問題，本論文將基於知識蒸餾，探討兩種教師模型架構，主要貢獻如下：

- 討論「未完整訓練教師架構」：本論文使用不同程度的未完整訓練教師模型進行蒸餾，經實驗結果顯示其蒸餾效果與經過完整訓練的教師模型相同，更可以大幅縮短訓練時間。
- 提出「多教師助教模型架構」：本論文結合了多教師模型架構與助教模型架構，經實驗結果顯示其蒸餾效果優於原先兩種架構。

1.3 章節提要

本篇論文架構包含五個章節，其章節內容如以下：

第 1 章 緒論：描述本篇論文的研究背景與動機、研究目的與章節提要。

第 2 章 相關技術：描述目前常見的模型壓縮相關技術。

第 3 章 研究方法：描述本篇論文的實驗設計架構。

第 4 章 實驗結果：描述本篇論文的實驗環境、測試資料集，及各實驗之數據與結果。

第 5 章 結論：描述本篇論文的貢獻與未來研究。



第 2 章 相關技術

根據[7-9]的統整，模型壓縮技術大致可以分為剪枝、量化、低秩分解及知識蒸餾，以下對這四種技術進行介紹。

2.1 剪枝

剪枝(Pruning) [10] [11]和量化起初是用來解決模型過擬和的問題，現在更多用於減少網路複雜度，是目前模型壓縮使用最多且簡單有效的方法。剪枝原理是透過刪除神經網路中對準確率影響不大的參數，來達到降低模型體積的目的。神經網路剪枝概念如圖 2 所示，通常分為權重剪枝和連結剪枝，去除不必要的神經元和連結，留下重要的部分，進而增加神經網路的稀疏性。讓模型在保持一定程度的準確率下，不僅減少整個模型的體積大小，還可以節省計算所耗的時間。




圖 2、剪枝示意圖

2.2 量化

剪枝是通過減少權重的數量來壓縮模型，量化(Quantization)[12][13]則是透過減少權重的大小來壓縮模型。量化以犧牲精度為代價，將神經網路中連續或離散的浮點參數線性映射到定點數，降低資料儲存，達到減少模型體積大小的效果。Benoit Jacob 將資料壓縮到 int8[14]，因為 int8 可以相對完整覆蓋大部分的模型權重值，以 float32 為例，壓縮到 int8 可以減少百分之七十五的儲存空間，大幅度降低了模型體積。




圖 3、量化示意圖

2.3 低秩分解

低秩分解(Low-Rank Factorization) [15] [16]是利用矩陣轉化來降低模型大小，達到模型壓縮的目的。神經網路中有大量的矩陣乘法，如圖 4 所示，這些龐大的矩陣透過低秩分解可以表示為多個低秩矩陣的乘積，而這些低秩矩陣又可以再分解為更小規模的矩陣乘積。常見的低秩分解方法有奇異值分解(Singular Value Decomposition, SVD)、張量分解(Tensor Decomposition)等方法。近年來低秩分解不再流行是因為越來越多神經網路採用 1×1 的卷積，小的卷積使用矩陣分解很難實行模型壓縮。




圖 4、低秩分解示意圖

2.4 知識蒸餾

知識蒸餾(Knowledge Distillation) [17] [18]是知識遷移的一種方法，採用教師與學生的架構。先讓模型體積較大的教師模型經過訓練，將學到的知識蒸餾出來，蒸餾出來的精華稱為暗知識(Dark Knowledge)，再把暗知識作為訓練教材訓練模型體積較小的學生模型，提高學生的準確率。圖 5 上方的流程為一般模型的訓練步驟，而下方為知識蒸餾訓練步驟。




圖 5、知識蒸餾示意圖

第 3 章 研究方法

3.1 知識蒸餾

3.1.1 知識蒸餾架構

知識蒸餾是知識遷移的一種方法，在 2015 年由 Google 的 Geoffrey Hinton 及 Jeff Dean 等人發表[17]。如圖 6 所示，知識蒸餾架構有教師與學生大小兩個模型，訓練一開始，資料集同時輸入教師模型與學生模型，教師模型會輸出結合溫度 T 與激勵函數 Softmax 的機率分佈，此機率分佈稱為軟目標(Soft Target)；學生模型會產出兩種機率分佈，一種是一般訓練只經過激勵函數 Softmax 的機率分佈，另一種則是經過結合溫度 T 的激勵函數 Softmax 輸出的機率分佈，兩種機率分佈分別與資料集真實標籤(Ground Truth)和教師模型輸出的 Soft Target 進行損失函數(Loss Function)運算，分別為 Hard Loss 和 Soft Loss，兩項 Loss 再由 α 調整比例輸出一個 Total Loss。經過此步驟反覆訓練，就可以得到一個經過知識蒸餾的學生模型。




圖 6、知識蒸餾架構圖

3.1.2 Soft Target

知識蒸餾的概念，就是「蒸餾」教師的「知識」，讓這個知識變得淺顯易懂後再傳遞給學生。




圖 7、Soft Target 示意圖

知識就是指教師模型訓練後各類別的預測機率，一般分類模型所輸出的預測是使用激勵函數 Softmax。Softmax 是將機率分布輸出映射到 $(0, 1)$ 區間內，因此教師所預測出的結果是有很高極端值的機率分布，也就是正確類別的機率相當接近於 1，其他類別的機率都非常接近 0。激勵函數 Softmax 如公式 3.1 所示：

$$Softmax = \frac{\exp(z_i)}{\sum_j \exp(z_j)} \quad (3.1)$$

蒸餾就是將原先的激勵函數 Softmax 加上了溫度 T ，使得這些輸出機率平坦化，把隱含的訊息顯露更多出來，可以更明顯的了解各類別彼此相異或相似的程度，在訓練過程中增加更多的判斷條件。而這些經過平坦化的輸出機率就稱為軟目標(Soft Target)，也稱為暗知識。加入溫度 T 的 Softmax 如公式 3.2 所示：

$$\text{Softmax with Temperature} = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)} \quad (3.2)$$

$\exp$ 為指數函數，將每個指數函數的輸出除上一個 T 值；如果 T 為 1，就等於與原本的激勵函數 Softmax 相同沒有變化。



3.1.3 Temperature

溫度 T 可以讓輸出的機率分佈在保持等比例的情況下，拉近各數值間的距離，使得機率分佈變得平坦化，進而提供更多的訊息。如圖 8 所示，在 CIFAR-10 上進行影像辨識，真實標籤是馬，經過不同數值溫度 T 的 Soft Target 在驢子上的機率提高，而非只是 0。溫度 T 大小也會使得輸出的機率分佈不同：溫度 T 數值越高，機率分佈越加平坦；溫度 T 數值越低，機率分佈則越極端。




圖 8、不同溫度對於模型輸出機率影響折線圖

3.1.4 Cross Entropy

Geoffrey Hinton 提出的知識蒸餾架構中，學生模型所輸出的兩種機率分佈分別與資料集真實標籤和教師模型輸出的 Soft Target 做 Hard Loss 與 Soft Loss 計算，兩種 Loss 都使用交叉熵 (Cross Entropy) 作為損失函數，再經由 α 調配比例合成一個 Total Loss。

- Cross Entropy

$$\text{Cross Entropy} = - \sum_{c=1}^N (y_{o,c} \cdot \log(p_{o,c})) \quad (3.3)$$

- N 為類別數量。
- o 為真實標籤。
- c 為預測結果。
- $y_{o,c}$ 表示預測類別 c 與真實標籤 o 是否相同，相同為 1，反之為 0。
- $p_{o,c}$ 表示預測類別 c 屬於真實標籤 o 的預測機率。






圖 9、Loss Function 示意圖

- Hard Loss

$$\text{Hard Loss} = \text{Cross Entropy}(\text{Hard Target } h, \text{Hard Output } q) \quad (3.4)$$

- Hard Target h 為資料集的真实標籤。
- Hard Output q 為學生模型只經過激勵函數 Softmax 輸出的機率分佈。



- Soft Loss

$$\text{Soft Loss} = \text{Cross Entropy}(\text{Soft Target } s, \text{Soft Output } r) \quad (3.5)$$

- Soft Target s 為教師模型經過結合溫度 T 的激勵函數 Softmax 輸出的機率分佈。
- Soft Output r 為學生模型經過結合溫度 T 的激勵函數 Softmax 輸出的機率分佈。

- Total Loss

$$\text{Total Loss} = \alpha \cdot \text{Soft Loss} + (1 - \alpha) \cdot \text{Hard Loss} \quad (3.6)$$

- α 為 0 到 1 區間的權重控制參數，用來決定模型訓練結果更趨近於 Soft Loss 或者 Hard Loss。

3.2 知識蒸餾教師架構設計

3.2.1 未完整訓練教師

神經網路模型跟訓練次數有很大的關係，訓練次數太少會欠擬合(Underfitting)，太多則會過擬合(Overfitting)，如圖 10 所示，曲線由欠擬合變為最佳(Optimum)，再變為過擬合，所以選擇適當的訓練次數是很重要的。




圖 10、Underfitting 與 Overfitting 示意圖

基於 Seyed Iman Mirzadeh 的實驗結果顯示準確率高的教師蒸餾效果比準確率低的教師蒸餾結果還差[3]，Li Yuan 使用僅訓練一次的模型當作未完整訓練教師模型，其蒸餾出的學生模型也可以提升準確率[4]；此研究探討使用同一教師模型架構，利用訓練次數不同，形成不同程度的未完整訓練教師，進行蒸餾學生模型，相對於經過完整訓練的完整訓練教師，試圖探討蒸餾效果是否因此有所不同。

3.2.2 多教師助教模型

本篇論文提出多教師助教架構(Multi-teacher-assistant)，其結合多教師架構(Multi-teacher)[19]和助教架構(Teacher-assistant)[3]。

一般知識蒸餾架構為使用一個教師模型蒸餾一個模型體積比教師模型小的學生模型，如圖 11 所示。




圖 11、一般知識蒸餾架構示意圖

多教師架構為使用多個教師模型，一起共同蒸餾同個學生模型。如圖 12 所示，三個教師模型(T_1, T_2, T_3)共同蒸餾學生模型 S 。其特點為可以使學生模型學習到不同教師模型的知識。




圖 12、多教師架構示意圖

助教架構為使用一個教師模型，先蒸餾一個模型體積比教師模型小且比學生模型大的助教模型，再用助教模型蒸餾學生模型。如圖 13 所示，教師模型 T 先蒸餾助教模型 A₁，助教模型 A₁ 接著蒸餾下一個助教模型 A₂，助教模型 A₂ 再接著蒸餾助教模型 A₃，最後助教模型 A₃ 再蒸餾學生模型 S。其特點為解決教師模型與學生模型差距太大導致蒸餾效果不好的問題。




圖 13、助教架構示意圖

多教師助教架構結合多教師架構和助教架構，先使用一個教師模型蒸餾多個助教模型，再用多個助教模型共同蒸餾同個學生模型，或使用一個教師模型跟多個助教模型共同蒸餾同個學生模型。如圖 14 所示，左邊架構教師模型 T 蒸餾三個助教模型(A₁, A₂, A₃)，三個助教模型(A₁, A₂, A₃)再共同蒸餾學生模型 S；右邊架構教師模型 T 蒸餾三個助教模型(A₁, A₂, A₃)，教師模型 T 與三個助教模型(A₁, A₂, A₃)再共同蒸餾學生模型 S。




圖 14、多教師助教架構示意圖

多教師助教架構的 Soft Loss 經過修改後如公式 3.7，其中 t_n 為第 n 個教師模型的輸出結果， w_n 為第 n 個教師模型所配置的權重。可以藉由調配權重來決定蒸餾更趨近於哪個教師模型，但在此實驗每個教師模型權重都一樣。

$$\text{Soft Loss}_s = \frac{(w_1 t_1 + w_2 t_2 + \cdots + w_n t_n)}{(w_1 + w_2 + \cdots + w_n)} \quad (3.7)$$




圖 15、Soft Loss 修改示意圖

第 4 章 實驗結果

4.1 實驗準備

4.1.1 實驗環境

- 硬體規格
 - 處理器：Intel(R) Xeon(R) CPU E5-2620 v4 @ 2.10GHz
 - 記憶體：62G
 - 顯示卡：NVIDIA GeForce RTX 2080 Ti
- 作業系統
 - Ubuntu 18.04.4 LTS
- 軟體套件
 - CUDA 10.0.130
 - CuDNN 7.6.0
 - Python 3.7.4
 - Tensorflow-gpu 2.0.0
- 開發環境
 - Visual Studio Code 1.49.0



4.1.2 實驗資料集

- CIFAR-10

所有實驗皆使用 CIFAR-10 當測試資料集。CIFAR-10 是由加拿大先進研究所 (Canadian Institute for Advanced Research, CIFAR) 所整理的影像資料集，廣泛用於機器學習與深度學習的研究。CIFAR-10 資料集總共包含 60,000 張 32x32 彩色影像。其中訓練集包含 50,000 張影像，測試集包含 10,000 萬張影像。這些影像涵蓋 10 個不同的類別，分別代表飛機，汽車，鳥類，貓，鹿，狗，青蛙，馬，輪船和卡車。每種類別有 6,000 張影像，各個類別的影像是互斥的，不存在一張影像屬於兩種或兩種以上類別的情況。




圖 16、CIFAR-10 資料集示意圖

4.1.3 模型網路架構

本論文使用兩種網路架構，一般的卷積神經網路和深度殘差網路。

- 卷積神經網路

LeNet 於 1998 年由 Yann LeCun 提出[20]，被認為是卷積神經網路 (Convolutional Neural Network, CNN) 始祖。如圖 18 所示，LeNet 包含了三層的卷積層 (Convolutional Layer)、兩層池化層 (Pooling Layer) 以及兩層全連結層 (Fully Connected Layer)。卷積用於萃取出圖片的特徵，利用這些特徵達到辨識的效果；池化用於減少維度，保留重要特徵並降低參數量，避免過擬合。

本論文實驗所用卷積神經網路分為五個大小不同的網路，CNN2、CNN4、CNN6、CNN8、CNN10 和 CNN30。CNN2 有兩層卷積層，CNN4 有四層卷積層，CNN6 則有六層卷積層，以此類推。




圖 17、LeNet 架構圖

- 深度殘差網路

當網路層數越深，梯度在反向傳播的過程中，偏微分次數也隨之增加，當偏微分出來的數值越來越小趨近於 0 或越來越大趨近於無限大，即無法對前面網路層的參數進行有效的更新，影響模型收斂，稱為梯度消失(Vanishing Gradient Problem)或梯度爆炸(Exploding Gradient Problem)。

為了解決前述問題，Kaiming He 於 2015 年提出了一種新的 CNN 架構[21]，稱為深度殘差學習 (Deep Residual Learning, ResNet)。Kaiming He 提出一種殘差模塊(Residual Block)，其核心概念是將平常的網路輸入與輸出之間建立一條輸入等於輸出的捷徑，利用這條捷徑達到恆等映射(Identity Mapping)的效果。如圖 18 所示， x 為原始輸入， $F(x)$ 是一般模型的輸出， $H(x)$ 為殘差模塊的輸出。輸入 x 加上原先模型輸出 $F(x)$ 得到輸出 $H(x)$ ，而當 $F(x)$ 逼近 0 時， $H(x)=x$ ，使 $H(x)$ 保留住上一層的輸出，確保網路不會隨著變深而退化，達到恆等映射的效果。

本論文實驗所用深度殘差網路為 Kaiming He 提出用於資料集 CIFAR-10 的網路，分為 ResNet20、ResNet32、ResNet44、ResNet56 和 ResNet110。




圖 18、Residual Block 示意圖

4.2 實驗結果

4.2.1 未完整訓練教師

此實驗使用同一教師模型架構，訓練次數依序遞增形成不同程度的未完整訓練教師模型，分別去蒸餾同個學生模型，試圖探討蒸餾效果是否因此有所不同。實驗使用了下列教師模型：CNN30，準確率為 85.34%；CNN10，準確率為 84%；CNN8，準確率為 78.49%；ResNet110，準確率為 85.18%；ResNet56，準確率為 85%。

如圖 19 所示，縱軸是準確率，橫軸是教師模型的訓練次數，學生模型的訓練次數則都是固定的。CNN30 為教師模型，藍線是教師模型在訓練幾次下的準確率，橘線是 CNN2 作為學生模型，經過分別不同訓練次數的教師模型蒸餾後的準確率，灰線則是以 CNN4 為學生模型。




圖 19、教師模型 CNN30 不同訓練次數蒸餾比較折線圖

實驗結果可以看出教師模型 CNN30 訓練次數越多，準確率越高，但準確率高的教師模型蒸餾到學生模型 CNN2 和 CNN4 的準確率卻沒有提高。

圖 20 以 CNN8 為教師模型，藍線是教師模型的準確率，橘線是學生模型 CNN2 的準確率，灰線是學生模型 CNN4 的準確率。




圖 20、教師模型 CNN10 不同訓練次數蒸餾比較折線圖



圖 21 以 CNN8 為教師模型，藍線是教師模型的準確率，橘線是學生模型 CNN2 的準確率，灰線是學生模型 CNN4 的準確率。




圖 21、教師模型 CNN8 不同訓練次數蒸餾比較折線圖

圖 22 以 ResNet110 為教師模型，藍線是教師模型的準確率，橘線是學生模型 ResNet20 的準確率，灰線是學生模型 ResNet32 的準確率。




圖 22、教師模型 ResNet110 不同訓練次數蒸餾比較折線圖



圖 23 以 ResNet56 為教師模型，藍線是教師模型的準確率，橘線是學生模型 ResNet20 的準確率，灰線是學生模型 ResNet32 的準確率。




圖 23、教師模型 ResNet56 不同訓練次數蒸餾比較折線圖

根據以上實驗結果，可以得出以下結論：

- 同一教師模型，訓練次數越高，教師模型準確率越高。
- 對於蒸餾學生模型，訓練次數高，準確率高的教師模型，和訓練次數低，準確率低的教師模型，效果是一樣的。
- 所以用訓練次數低的未完整訓練教師模型去蒸餾學生模型，雖然無法提高學生模型的準確率，但可以大幅縮短教師模型的訓練時間。



4.2.2 多教師助教模型

此實驗使用多教師助教架構(Multi-teacher-assistant)，其結合多教師架構(Multi-teacher)和助教架構(Teacher-assistant)[3]，下列為實驗結果。

- $S(m)$ ：學生模型 m 直接訓練的準確率。
- $T(m)$ ：以教師模型 m 蒸餾學生模型 S 的準確率。
- $MT(m_1/m_2/\dots m_x)$ ：多教師架構，以 m_1 、 m_2 ... m_x 共同蒸餾學生模型 S 的準確率。
- $TA(m_1/m_2/\dots m_x)$ ：助教架構，以 m_1 蒸餾 m_2 ，再以 m_2 蒸餾 m_3 ...依序蒸餾到 m_x ，再以 m_x 蒸餾學生模型 S 的準確率。
- $MTA(m_1/m_2/\dots m_x)$ ：多教師助教架構，以 m_1 蒸餾 m_2 ，再以 m_1 蒸餾 m_3 ...再以 m_1 蒸餾 m_x ，最後以 m_2 ... m_x 共同蒸餾學生模型 S 的準確率。
- $MTTA(m_1/m_2/\dots m_x)$ ：多教師助教架構，以 m_1 蒸餾 m_2 ，再以 m_1 蒸餾 m_3 ...再以 m_1 蒸餾 m_x ，最後以 m_1 、 m_2 ... m_x 共同蒸餾學生模型 S 的準確率。

圖 24 以 CNN2 為學生模型，圖 25 以 CNN4 為學生模型。實驗結果顯示多教師助教架構蒸餾效果優於其他架構。




圖 24、CNN2 在不同蒸餾架構下準確率比較圖




圖 25、CNN4 在不同蒸餾架構下準確率比較圖

接著進一步結合「未完整訓練教師」，原本教師模型與學生模型訓練次數都是 50 次，把教師模型的訓練次數減少為 5 次，而學生模型的訓練次數依舊是 50 次，比較不同教師架構蒸餾效果。

圖 26 以 CNN2 為學生模型，教師訓練次數為 50 次；圖 27 以 CNN2 為學生模型，教師訓練次數為 5 次。藍線為各蒸餾的準確率，綠色直條為各個架構教師模型與學生模型的總訓練時間。實驗結果顯示教師訓練時間不同對於學生蒸餾效果幾乎沒有差別，但訓練時間可以大幅下降。




圖 26、CNN2(EPOCH=50)在不同蒸餾架構下準確率比較圖




圖 27、CNN2(EPOCH=5)在不同蒸餾架構下準確率比較圖

圖 28 以 ResNet20 為學生模型，教師訓練次數為 50 次；圖 29 以 ResNet20 為學生模型，教師訓練次數為 5 次。實驗結果顯示教師訓練時間不同對於學生蒸餾效果幾乎沒有差別，訓練時間亦可以大幅下降。




圖 28、ResNet20(EPOCH=50)在不同蒸餾架構下準確率比較圖




圖 29、ResNet20(EPOCH=5)在不同蒸餾架構下準確率比較圖

綜合上述實驗結果，根據本論文所研究不同教師模型架構的知識蒸餾，可以依照實際應用的嵌入式環境來決定學生模型體積大小，再以上述的教師模型架構進行知識蒸餾，達到最好的蒸餾效果。

第 5 章 結論

本篇論文基於模型壓縮技術知識蒸餾的架構下，提出兩種教師模型架構，實現於兩種 CNN 模型架構及應用於資料集 CIFAR-10 上。

本篇論文中的主要貢獻如下：

- 討論「未完整訓練教師架構」：本論文使用不同程度的未完整訓練教師模型進行蒸餾，經實驗結果顯示其蒸餾效果與經過完整訓練的教師模型相同，更可以大幅縮短訓練時間。
- 提出「多教師助教模型架構」：本論文結合了多教師模型架構與助教模型架構，經實驗結果顯示其蒸餾效果優於原先兩種架構。

在未來的研究，我們可以嘗試更多不同模型架構的知識蒸餾，例如同深度但不同寬度的知識蒸餾；也可以改變更多不同的蒸餾方式，例如教師與學生互相蒸餾；又或者是針對暗知識去探討蒸餾效果，讓知識蒸餾可以達到更好的模型壓縮效果。

参考文献

- [1] S. Ravi, "Custom on-device ML models with Learn2Compress," ed, 2018.
- [2] A. Polino, R. Pascanu, and D. Alistarh, "Model compression via distillation and quantization," *arXiv preprint arXiv:1802.05668*, 2018.
- [3] S. I. Mirzadeh, M. Farajtabar, A. Li, N. Levine, A. Matsukawa, and H. Ghasemzadeh, "Improved knowledge distillation via teacher assistant," in *Proceedings of the AAAI Conference on Artificial Intelligence*, 2020, vol. 34, no. 04, pp. 5191-5198.
- [4] L. Yuan, F. E. Tay, G. Li, T. Wang, and J. Feng, "Revisit knowledge distillation: a teacher-free framework," *arXiv preprint arXiv:1909.11723*, 2019.
- [5] J. H. Cho and B. Hariharan, "On the efficacy of knowledge distillation," in *Proceedings of the IEEE International Conference on Computer Vision*, 2019, pp. 4794-4802.
- [6] Q. Xie, M.-T. Luong, E. Hovy, and Q. V. Le, "Self-training with noisy student improves imagenet classification," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020, pp. 10687-10698.
- [7] Y. Cheng, D. Wang, P. Zhou, and T. Zhang, "A survey of model compression and acceleration for deep neural networks," *arXiv preprint arXiv:1710.09282*, 2017.
- [8] J. Cheng, P.-s. Wang, G. Li, Q.-h. Hu, and H.-q. Lu, "Recent advances in efficient computation of deep convolutional neural networks," *Frontiers of Information Technology & Electronic Engineering*, vol. 19, no. 1, pp. 64-77, 2018.
- [9] T. Choudhary, V. Mishra, A. Goswami, and J. Sarangapani, "A comprehensive survey on model compression and acceleration," *Artificial Intelligence Review*, pp. 1-43, 2020.
- [10] Y. LeCun, J. Denker, and S. Solla, "Optimal brain damage," *Advances in neural information processing systems*, vol. 2, pp. 598-605, 1989.
- [11] S. Han, J. Pool, J. Tran, and W. Dally, "Learning both weights and connections for efficient neural network," *Advances in neural information processing systems*, vol. 28, pp. 1135-1143, 2015.
- [12] J. Wu, C. Leng, Y. Wang, Q. Hu, and J. Cheng, "Quantized convolutional neural networks for mobile devices," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 4820-4828.

- [13] Z. Cai, X. He, J. Sun, and N. Vasconcelos, "Deep learning with low precision by half-wave gaussian quantization," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, pp. 5918-5926.
- [14] B. Jacob *et al.*, "Quantization and training of neural networks for efficient integer-arithmetic-only inference," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018, pp. 2704-2713.
- [15] X. Zhang, J. Zou, X. Ming, K. He, and J. Sun, "Efficient and accurate approximations of nonlinear convolutional networks," in *Proceedings of the IEEE Conference on Computer Vision and pattern Recognition*, 2015, pp. 1984-1992.
- [16] W. Wen, C. Xu, C. Wu, Y. Wang, Y. Chen, and H. Li, "Coordinating filters for faster deep neural networks," in *Proceedings of the IEEE International Conference on Computer Vision*, 2017, pp. 658-666.
- [17] G. Hinton, O. Vinyals, and J. Dean, "Distilling the knowledge in a neural network," *arXiv preprint arXiv:1503.02531*, 2015.
- [18] A. Romero, N. Ballas, S. E. Kahou, A. Chassang, C. Gatta, and Y. Bengio, "Fitnets: Hints for thin deep nets," *arXiv preprint arXiv:1412.6550*, 2014.
- [19] 江郡邦, "運用多樣教師結構進行知識蒸餾於模型壓縮之研究," 碩士, 電子工程系, 國立臺灣科技大學, 台北市, 2020. [Online]. Available: <https://hdl.handle.net/11296/sjtdjz>
- [20] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278-2324, 1998.
- [21] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770-778.