

國立雲林科技大學電機工程系

碩士論文

Department of Electrical Engineering
National Yunlin University of Science & Technology
Master Thesis

多域多級知識蒸餾應用於軸承故障檢測
Multi-domain and Multi-level Knowledge Distillation for
Bearing Fault Detection

廖政傑

Zheng-Jie Liao

指導教授：洪崇文 博士

Advisor: Chung-Wen Hung, Ph.D.

中華民國 114 年 6 月

June 2025

國立雲林科技大學
碩士班學位論文考試委員會審定書
National Yunlin University of Science and Technology
Thesis Oral Defense Approval Form

本論文係 廖政傑 君在本校 電機工程系碩士班 所提論文 多域多級知識蒸餾應用於軸承故障檢測 碩士資格水準，業經本委員會評審認可，特此證明。

The student LIAO, ZHENG-JIE enrolled in the Master's program in Department of Electrical Engineering has satisfactorily passed the oral defense of the thesis Multi-domain and Multi-level Knowledge Distillation for Bearing Fault Detection.

口試委員：
Oral defense
committee members

洪崇文

李慶鴻

張廷安

洪崇文
李慶鴻
張廷安

指導教授：
Advisor(s)

洪崇文

洪崇文

所長：
Dean of Graduate
Institute

電機工程系 張家宏
系主任

中 華 民 國

114 年 7 月 18 日

摘要

本論文針對工業場域中軸承故障診斷的應用需求，提出一套結合多域多級教師的知識蒸餾訓練，以及加密資料傳輸機制之邊緣運算架構。隨著深度學習技術的快速發展，大型模型雖具備高辨識能力，卻因模型龐大而不易部署於資源有限的邊緣裝置上。為解決此問題，本論文採用知識蒸餾技術，將多個大型教師模型所學之知識轉移至輕量化的學生模型，並引入中等規模之助教模型作為中介橋梁，緩解模型間結構差異過大所造成的學習瓶頸，以提升學生模型在小樣本條件下的辨識能力。

本論文選用 CWRU(Case Western Reserve University)、TBVD (Triaxial Bearing Vibration Dataset)與 VDAB(Vibration Data for Axial Ball bearings) 三種常見軸承振動資料集進行實驗驗證，採用多種資料交互訓練，設計出單教師、雙教師、雙教師單助教與雙教師雙助教等多種知識融合模式，並比較平均權重與動態權重分配策略的影響。結果顯示，融合多教師知識相較於單教師能有效提升學生模型 1~4% 的準確率，動態權重分配更具穩定性，誤差波動範圍較小。引入助教模型進行蒸餾後，學生模型可額外獲得 1~3% 的準確率提升；在雙教師雙助教結構下，於樣本數充分時可獲得最佳表現，顯示多級、多域知識對學生模型具強化效益。

系統實作方面，本論文以 Raspberry Pi 5 作為邊緣平台，設計基於裝置 MAC(Media Access Control Address)位址的 SHA-256 雜湊金鑰產生機制，並透過 AES-CTR 模式 (Advanced Encryption Standard-Counter)進行資料加密，有效確保數據在蒸餾訓練過程中之傳輸安全與裝置認證機制。整體系統不僅具備良好的訓練效果，更兼顧運算效率與資料隱私，驗證其在智慧工業場域中落地應用之可行性。

綜上所述，本論文提出一套具備高效能與安全性的知識蒸餾訓練架構，從多教師、多層級與加密傳輸三面向，實現邊緣運算於設備健康診斷中的解決方案，為未來智慧製造與工業 4.0 發展奠定一重要基礎。

關鍵字：知識蒸餾、跨域、多域、邊緣運算、預防性維護、資料隱私

ABSTRACT

This thesis presents an edge computing framework that integrates multi-domain, multi-level teacher knowledge distillation and encrypted data transmission to address the needs of bearing fault diagnosis in industrial environments. Although large deep learning models offer high recognition accuracy, their size limits deployment on resource-constrained edge devices. To overcome this, knowledge distillation is applied to transfer knowledge from multiple large teacher models to a lightweight student model. Medium-sized assistant models are introduced to bridge structural gaps and enhance student performance, especially under small-sample conditions.

Experiments were conducted using three common bearing vibration datasets: CWRU(Case Western Reserve University), TBVD(Triaxial Bearing Vibration Dataset), and VDAB(Vibration Data for Axial Ball bearings). Various knowledge fusion modes were designed, including single-teacher, dual-teacher, and dual-teacher with assistant configurations. The results show that multi-teacher distillation improves student accuracy by 1–4%, with dynamic weighting offering better stability. Assistant models further boost accuracy by 1–3%, with the dual-teacher dual-assistant setup achieving the best results when sufficient data is available.

The system is implemented on a Raspberry Pi 5 platform, utilizing SHA-256 hash-based keys derived from the device MAC (Media Access Control Address) address and AES-CTR (Advanced Encryption Standard-Counter) encryption to secure data transmission and device authentication. The proposed framework demonstrates strong recognition performance, efficient computation, and reliable data security, validating its practicality for smart industrial applications.

In summary, this research provides a high-performance, secure knowledge distillation solution for edge-based equipment health monitoring, supporting the advancement of smart manufacturing and Industry 4.0.

Key Word : Knowledge distillation, Cross-domain, Multi-domain, Edge Computing, Predictive Maintenance, Data privacy

誌謝

首先感謝洪崇文博士在我碩士學習生涯中的諄諄教誨，使我獲益良多，除了學術及實作的知識外，也提供優越的實驗環境與資源，使我具備良好的專業知識與能力。同時感謝陽明交通大學的李慶鴻教授與雲林科技大學的張廷安教授，在百忙之中抽空擔任學生的口試委員，並提供許多寶貴意見及精進方向，使本論文更加完整。

在求學過程中，由衷感謝我的父親廖明烽先生、母親范曉梅女士、弟弟廖政皓一路上對我的支持與肯定，使我能順利完成碩士學位。

同時也感謝實驗室學長姐們陳煊妮、周雅淳、林彥廷、楊佳叡、吳泰璇、蔡承佑，同學們呂為鈞、林振煌、朱晏廷、張恆恩、蘇禹行、吳佳昌，以及學弟妹們黃祥瑞、吳昱儕、涂宸維、許耀龍、謝昌彥，在研究過程中大家互相給予意見交流與經驗分享，感謝你們，使本論文順利完成。

最後，僅以本論文獻給所有關心幫助我的親人、朋友們，與你們一起分享這份喜悅。



目錄

摘要	i
ABSTRACT	ii
誌謝	iii
目錄	iv
表目錄	vi
圖目錄	viii
第 1 章 緒論	1
1.1 研究背景與動機	1
1.2 文獻回顧	2
1.2.1 邊緣運算相關論文	2
1.2.2 模型壓縮與知識蒸餾論文探討	3
1.2.3 軸承診斷論文探討	4
1.3 內容大綱	6
第 2 章 演算法架構介紹	7
2.1 神經網路演算法	7
2.1.1 人工神經網路(Artificial Neural Network, ANN)	7
2.1.2 卷積神經網路(Convolution Neural Network, CNN)	8
2.2 知識蒸餾演算法	9
2.3 多教師演算法	11
2.4 硬體加密演算法	13
2.5 小結	16
第 3 章 資料處理與模型最佳化評估方法	17
3.1 資料前處理	17
3.1.1 傅立葉轉換(Fourier Transform)	17
3.1.2 正規化與標準化	17
3.2 超參數最佳化及模型訓練	19
3.2.1 網格搜尋法	19

3.2.2 隨機搜尋法	20
3.2.3 貝葉斯最佳化	20
3.3 模型評估法	21
3.3.1 交叉驗證	21
3.3.2 混淆矩陣	22
3.4 小結	24
第 4 章 軟硬體系統架構開發	25
4.1 系統架構	25
4.2 數據分析	27
4.2.1 CWRU 數據集	27
4.2.2 TBVD 數據集	29
4.2.3 VDAB 數據集	31
4.2.4 模型超參數	32
4.3 多級訓練架構	37
4.4 小結	39
第 5 章 實驗結果與分析	40
5.1 跨域知識蒸餾效果	40
5.2 基於多級知識蒸餾效果	41
5.3 基於多域多級教師知識蒸餾效果	43
5.4 硬體加密結果	50
5.5 小結	52
第 6 章 結論與未來展望	53
6.1 結論	53
6.2 未來展望	53
6.2.1 樣本收集問題	53
6.2.2 邊緣端平台問題	54
6.2.3 演算法問題	54
參考文獻	55

表目錄

表 4-1 伺服器端規格表	26
表 4-2 機邊端規格表	26
表 4-3 CWRU 故障類型	29
表 4-4 TBVD 故障類型	30
表 4-5 VDAB 故障類型	32
表 4-6 CWRU 資料集 CNN 演算法超參數範圍表	33
表 4-7 CWRU 資料集超參數搜尋前十名	33
表 4-8 CWRU 排名第一模型捲積層詳細超參數	34
表 4-9 TBVD 資料集 CNN 演算法超參數範圍表	34
表 4-10 TBVD 資料集超參數搜尋前十名	35
表 4-11 TBVD 排名第一模型捲積層詳細超參數	35
表 4-12 VDAB 資料集 CNN 演算法超參數範圍表	36
表 4-13 VDAB 資料集超參數搜尋前十名	36
表 4-14 VDAB 排名第一模型捲積層詳細超參數	36
表 4-15 教師、助教與學生模型參數	37
表 4-16 TBVD 各模型大小單獨訓練效果	38
表 4-17 CWRU 各模型大小單獨訓練效果	38
表 4-18 VDAB 各模型大小單獨訓練效果	38
表 5-1 兩種教師架構對 TBVD 學生的跨域蒸餾效果	41
表 5-2 兩種教師架構對 VDAB 學生的跨域蒸餾效果	41
表 5-3 兩種教師架構對 CWRU 學生的跨域蒸餾效果	41
表 5-4 使用 VDAB 與 CWRU 作為教師訓練 TBVD 學生	43
表 5-5 使用 VDAB 與 TBVD 作為教師訓練 CWRU 學生	43
表 5-6 使用 TBVD 與 CWRU 作為教師訓練 VDAB 學生	43
表 5-7 使用 VDAB 與 CWRU 教師訓練 TBVD 學生	44
表 5-8 使用 VDAB 與 TBVD 教師訓練 CWRU 學生	45
表 5-9 使用 CWRU 與 TBVD 教師訓練 VDAB 學生	45

表 5-10 使用 VDAB 與 CWRU 的不同組合訓練 TBVD 學生	46
表 5-11 使用 VDAB 與 TBVD 的不同組合訓練 CWRU 學生	46
表 5-12 使用 TBVD 與 CWRU 的不同組合訓練 VDAB 學生	46
表 5-13 使用雙教師單助教組合訓練 TBVD 學生	47
表 5-14 使用雙教師單助教組合訓練 CWRU 學生	47
表 5-15 使用雙教師單助教組合訓練 VDAB 學生	48
表 5-16 各種教師組合訓練 TBVD 學生	49
表 5-17 各種教師組合訓練 CWRU 學生	49
表 5-18 各種教師組合訓練 VDAB 學生	50
表 5-19 加密時間成本與功耗比較	51
表 5-20 加解密性能	52



圖目錄

圖 2-1 ANN 結構示意圖	7
圖 2-2 CNN 結構示意圖	8
圖 2-3 知識蒸餾架構圖	9
圖 2-4 不同溫度 T 時的機率分佈示意圖	10
圖 2-5 硬標籤與軟標籤示意圖	11
圖 2-6 多教師訓練架構圖	12
圖 2-7(a)ECB 結構圖(b)CBC 結構圖(c)CTR 結構圖	14
圖 2-8 合加密演算法硬體網路架構圖	15
圖 3-1 最佳化模型時損失函數(loss function)分布[57]	19
圖 3-2 GS 與 RS 搜尋法比較[58]	20
圖 3-3 貝葉斯搜尋示意圖[59]	21
圖 3-4 交叉驗證方法示意圖	22
圖 3-5 混淆矩陣	23
圖 4-1 系統架構圖	26
圖 4-2 CWRU 資料集實驗平台	27
圖 4-3 CWRU 資料集頻域波型	28
圖 4-4 TBVD 資料集實驗平台	29
圖 4-5 TBVD 資料集頻域波型	30
圖 4-6 VDAB 資料集頻域波型	31
圖 5-1 跨域知識蒸餾訓練架構圖	40
圖 5-2 知識蒸餾導入助教輔助之多級訓練架構圖	42
圖 5-3 多域教師訓練架構圖	44
圖 5-4 多教師自動分配權重實際結果	44
圖 5-5 多域多級教師訓練架構圖(雙教師)	45
圖 5-6 多域多級教師訓練架構圖(雙教師單助教)	47
圖 5-7 多域多級教師訓練架構圖(雙教師雙助教)	48
圖 5-8 Local 端與 Server 端加密訓練流程圖	51

第1章 緒論

1.1 研究背景與動機

人工智慧 (Artificial Intelligence, AI) 蓬勃發展並廣泛應用於各個領域，各國無不將 AI 列為國家發展的重點，透過制定發展戰略與投入研發資源來推動相關技術發展，行政院與國科會提出促進 AI 產業發展計畫[1]，從產業端出發促進 AI 落地應用帶動國內產業的轉型與升級。現有 AI 技術的應用多集中於雲端計算，運算核心依賴雲端服務、GPU 或 PC 平台，實現在機邊端的嵌入式系統或微處理器 (Microcontroller Unit, MCU) 相對有限。由於網路延遲、通訊成本與裝置成本等問題，AI 技術難以有效導入自動化系統等需要即時反應的應用場景，使人工智慧的「落地實現」面臨挑戰。物聯網時代加劇了相關應用的討論，大量設備產生的數據為模型訓練提供了廣泛的資源，但分散的數據集中到雲端進行處理，往往面臨通訊延遲、效率低下、隱私洩漏與高昂成本等問題。且通用數據保護條例 (GDPR) [2] 等嚴格的數據隱私法規，也使數據傳輸和共享變得更加複雜，為解決這些挑戰，以微處理器為核心的邊緣運算 (Edge Computing) 成為學界與業界近期的關注焦點。邊緣運算透過直接在設備端進行模型訓練與更新，減少數據傳輸需求，有效保障數據隱私安全，同時降低通訊延遲與成本，報告指出邊緣運算市場規模將在 2025 年達到 122 億美元，預計於 2032 年增至 1,436 億美元[3]，其增長趨勢顯示出極具潛力的產業成長。然而邊緣運算伴隨著諸多挑戰，例如儲存、計算與功耗限制，使邊緣端模型的訓練與計算不易實現；同時，由於數據來源限制於單一裝置，模型準確性與數據泛化能力相對較低，增加了在邊緣端建立高效模型的障礙。

滾動軸承廣泛應用於鑽孔機、電動馬達、風力發電機和發動機等各類旋轉機械設備，是機械的重要組成部分；由於運行環境通常封閉且複雜，故障的檢測和預防較為關鍵，為了提高設備的可靠性、可用性和安全性，減少非計劃維護成本，滾動軸承剩餘使用壽命 (RUL) 預測技術日益受到關注，由於過載、潤滑不良、安裝不當甚或自然磨損等原因，經常出現老化、損壞等故障，嚴重時可能導致整個機器停機，甚至造成巨大的經濟損失和人員傷亡[4] - [6]。人工智慧的特性適合應用於設備診斷，深度學習技術被廣泛應用，不論是磨損或故障預測皆可為產線

帶來諸多助益，以便提前警告並優化維護計劃，防止災難性後果的發生。常用來檢測的網路模型包括深度置信網路（DBN）[7]、深度自動編碼器（DAE）[8]以及循環神經網路（RNN）[9]等，這些模型能夠從大量的感測數據中提取深層特徵，顯著提升故障檢測的準確性和效率；然而，設備中的實際應用會受到模型參數規模過大的限制[10]；為了兼顧性能與輕量化，模型壓縮技術被提出並得到廣泛應用[11]。此外，生產現場多預先替換可能損壞零件避免損失，除非刻意收集，設備的故障資料通常收集不易，一直是訓練人工智慧診斷系統時的痛點，知識蒸餾（Knowledge Distillation, KD）為一種源自師生模型的創新方法，透過蒸餾過程使學生模型從教師模型中學習知識，在不增加額外參數的情況下顯著提高模型性能[12]，[13]基於解耦知識蒸餾以少量資料借重別的領域模型完成訓練，成為解決方向。本論文的目標為解決產線機具即時診斷的需求，及不容許明知軸承故障或損耗較大時產線依舊生產，導致取樣稀少的痛點。使用知識蒸餾降低模型大小，降低對記憶體與計算資源需求，有助於微處理器實現邊緣計算完成即時診斷，降低部屬成本。本論文著重於使用多個不同領域教師進行多階知識蒸餾法的研究，兼顧機邊端平台的建立，進一步降低成本來實現 AI 落地，提供產業應用的解決方案。

1.2 文獻回顧

1.2.1 邊緣運算相關論文

邊緣運算最早由 Pang 和 Tan 提出[14]，在學術界和工業界的關注度日益提高，但由於當時嵌入式系統的運算能力有限，這項技術並沒有受到廣泛應用。近年則隨著硬體製成的進步與演算法的更新迭代，研究的主軸也已從雲端運算衍伸到邊緣運算，最後進步到直接於邊緣端裝置計算和訓練，[15]依據模型的複雜度將結構拆分並分別將高計算量的區塊放置雲端伺服器進行運算，低計算量的區塊則交給邊緣端裝置執行運算，確保在網路速度不佳的情況下保有較低的延遲，此外越來越多的研究針對在邊緣運算平台上實現人工智慧的預測或訓練，已有多種針對邊緣運算領域設計的設備投入商業應用[16] [17]。相關領域的開發重點是支持深度學習的輕量級系統，特別是實現邊緣端的深度神經網路推理[18] [19]。[20]基於邊緣人工智慧 AIoT(The Artificial Intelligence of Things)在記憶體受限的環境中實現高性能和高效率，以低功耗和最小的頻寬成本，滿足自動化家禽健康監測的實

際需求，優化農業營運和減少資源需求。[21] 在 Raspberry Pi 邊緣設備上部署 MinSnore 模型進行即時打鼾檢測，準確率達到 96.37%。在工業應用領域，[22] 使用工業邊緣設備人工智慧模型 Bi-LSTM 和 Bi-GRU 架構的循環神經網路，減少智慧製造中對昂貴感測器的需求、製造停機時間以及設備使用不足或過度使用來最大限度地降低生產成本，並整合到數位孿生系統中。[23] 展示了監測工業驅動裝置的三相電網中的 PQ(Power Quality)，使用 STFT 和最佳化的 ANN 對電壓波形進分類的應用，分析在邊緣設備上部署人工智慧模型相比雲端運算的通訊資料傳輸量減少了 94%，每年資料傳輸成本節省高達 5,900 歐元。除了克服資料傳輸延遲的問題外，資料的安全與隱私保護也是重要的課題[24]，[25] 基於 PUF 產生的對稱金鑰的輕量級加密技術，克服 IIoT(Industrial Internet of Things)設備運行複雜演算法的限制，並結合 ElGamal 加密和數位簽章方案實現使用者身分驗證提高任務機密性，[26] 利用 ZSS 短簽章演算法和 Paillier 同態加密實現資料保密和隱私保護。邊緣運算具備多項優點，包括低延遲、高效能、減少網路負載及增強數據隱私，將計算從雲端移至邊緣設備，不僅提升即時性與可靠性，還能降低數據傳輸成本，同時減少了數據外泄風險，對於工廠需要即時性與講求成本效益的應用場景提供了解決方案。[27] 於系統晶片平台針對倒角刀具開發人工智慧邊緣計算演算法；[28] 針對刀具加工早期故障檢測的研究，以嵌入式系統實現邊緣端的數據取樣與預測，取得了良好的效果；[29] 使用 CNN 處理加速度資料進行即時物體形狀識別，並在 Renesas RX65N MCU 上實現最佳化模型；[30] 透過最小化模型減少記憶體大小的需求，成功將光紋辨識演算法應用於一般 MCU 中，實現了手機光紋辨識系統；針對前述數據收集困難，[31] 亦嘗試聯邦學習與知識蒸餾技術開發，透過全局模型與個性化的訓練方法，強化邊緣端的辨識能力。本論文為實現邊緣運算落地應用，在取得模型準確率與計算資源需求之間平衡，目標開發出具有較低計算量和記憶體需求的精簡模型，以利安裝於市售微控制器或嵌入式晶片系統平台中。

1.2.2 模型壓縮與知識蒸餾論文探討

基於深度學習的故障診斷方法，對構建智慧工業系統、降低意外停機時間及減少生產力損失至關重要，過去二十年來，這些方法的應用和影響力持續增加，在檢測故障方面展現了卓越的能力。然而隨著性能的提升，計算成本和網路參數

規模也呈指數級增長，對即時應用構成了挑戰，然而即時性是智慧製造領域的核心需求之一。為解決此問題，過去的研究提出了多種神經網路小型化技術，主要分為網路量化、網路剪枝和知識轉移三大類。網路量化[32] 則將高精度參數轉換為低精度格式，以更高效地利用計算資源；網路剪枝[33] 通過移除冗餘的權重或神經元來降低網路複雜度；而知識轉移方法則將深層網路（教師網路）的知識提取並傳遞給較小的網路（學生網路）。其中知識蒸餾是其中最具代表性的方法，[34] 首次提出暗知識的概念，通過提高教師網路輸出層 Softmax 函數的溫度來生成軟標籤，進而訓練學生網路，使其在保持性能的同時大幅降低計算需求；[35] 從教師的內層分解特徵的知識，然後將這些知識提煉到學生的內層，可以拉近教師和學生之間的差距，提高學生的表現。[36] 將 DecouplingNet 設計為知識蒸餾解耦模型，以實現不同速度下旋轉機械的故障偵測；[37] 提出適用於迴歸問題的無數據知識蒸餾方法，透過生成器網路以對抗方式生成合成數據，實現教師網路知識向學生網路的轉移，學生網路在效能損失極小的情況下成功模仿了教師網路的預測能力。然而上述蒸餾方法皆依賴於單一預先訓練的網路，[38] 提出了一種多域的聯邦遷移學習方法，透過多教師知識蒸餾來獲取多領域知識並傳遞資訊；[39] 引進了知識融合的漸進訓練方法，讓學生模型能夠模仿多個教師的特徵，而後分層的向教師學習；[40] 提出 DE-MKD 解耦知識蒸餾損失，並為每位教師分配自適應權重，以根據其預測的熵來反映其重要性提高輕量級學生網路的效能，[41] 進一步提出了一種自適應多教師多級知識蒸餾學習框架，通過將教師模型的知識多階自適應地傳遞給學生模型，成功實現了更高的效能。本論文擬提出以多域多級教師知識蒸餾架構，因應工業生產現場機台故障數據取樣不易，透過相似領域的預訓練教師模型，對僅有少量資料的學生端進行知識蒸餾遷移訓練，加速模型的擬合與提高準確度，更高效的實現人工智慧落地應用。

1.2.3 軸承診斷論文探討

滾動軸承剩餘使用壽命(Remaining Useful Life, RUL) 的預測，能夠提前發出故障警告並優化維護計劃，在工業應用上是一項重要的技術，可以有效降低高成本的非計劃性維護需求，提升設備的可靠性、可用性及運行安全性。滾動軸承的 RUL 被定義為：從當前檢測時間到未來某一時刻軸承不再能執行其預定功能的時間跨度，傳統上，軸承的壽命可以根據國際標準 ISO 281-2007，或美國軸承製造

商協會(American Bearings Manufacturers Association, ABMA)的標準 ABMA 9-2015，和 ABMA 11-2014 進行計算[42]。然而，由於嚴苛的操作條件、製造缺陷等原因，軸承的實際壽命與理論壽命之間存在顯著差異。目前軸承 RUL 預測的方法主要分為兩大類：數據驅動方法(Data Driven Decision Making, DDDM)和基於模型的方法(Model-based systems engineering, MBSE) [43] [44]，數據驅動方法的優點是可以透過數據監測資料，與人工智慧直接從感測器數據中了解軸承退化趨勢。[45] 提出連續小波轉換及區域二進位卷積神經網路(LBCNN)，進行軸承故障診斷與變速箱複合式故障診斷；[46] 基於 LightGBM(Light Gradient-Boosting Machine) 的感應馬達軸承故障診斷模型，以及改進的遞迴特徵消除方法，用於處理在變化工況下的旋轉機械故障診斷問題；而[47] 利用 XGBoost(eXtreme Gradient Boosting)算法與基於深度學習的特徵提取和經驗特徵相結合，該方法從軸承振動信號中提取特徵，採用了深度學習技術和傳統經驗方法相結合的方式，將這些特徵融合後作為 XGBoost 分類器的輸入，用於實現軸承故障分類；[48] 進一步討論 MAKD(Multiassistant Knowledge Distillation) 方法在少量參數下進行軸承故障檢測，通過結合多個中等規模的輔助模型來縮小教師模型與學生模型之間的性能差距，為進一步優化網路結構以提升蒸餾效果，該方法引入了遞減閾值通道剪枝(DTCP)，以達到更好的蒸餾效果；最後，[49] 針對滾動軸承跨域故障診斷將均勻量化融入蒸餾過程中，實現量化與蒸餾的協同優化，以進一步壓縮學生網路的規模，同時保持性能表現，而本論文以此為參考，針對軸承磨損故障狀態，改採邊緣運算與多教師知識蒸餾，並結合數據加密，實現具備邊緣訓練與檢測的計算平台，減少對於故障樣本取樣數量的依賴，減少人工智慧落地應用的障礙。

1.3 內容大綱

本論文共分為六大章節，其章節內容概述分別如下：

第1章 緒論

主要敘述本論文研究背景與動機，以及整理有關於邊緣運算、模型壓縮、知識蒸餾、隱私安全、預防性維護等相關文獻，透過這些文獻滿足本研究內容所需知識。

第2章 演算法架構介紹

介紹本論文中使用到的神經網路、知識蒸餾、通訊交握、硬體加密、權重分配等演算法，於本論文提出的機邊端平台上運行測試比較不同演算法比較其效能與效果。

第3章 資料處理與模型最佳化與評估方法

簡述在本論文使用前處理方式，以提升模型訓練的效果；在模型超參數最佳化方法中，使用各種調整模型超參數的方法，透過自動調整模型超參數來選擇容量需求小的模型並且保有較佳準確率。

第4章 軟硬體系統架構與開發

詳細說明本論文研究的系統架構，包括模型設計、硬體規劃、資料集來源以及樣本前處理方法；並進一步說明多域多級教師知識蒸餾訓練架構。

第5章 實驗結果與分析

評估多域多級教師知識蒸餾學習方法結果，估測機邊端平台運行時間以及評估加密演算法安全性效果。

第6章 結論與未來展望

整理本論文中的研究內容及實驗結果，從中探討本論文中需改進之處並作為後續相關研究之方向。

第2章 演算法架構介紹

本章依序介紹論文使用到的神經網路演算法、知識蒸餾演算法、權重分配演算法、通訊交握及硬體加密演算法，後續在實驗中將上述演算法實現於機邊端平台。

2.1 神經網路演算法

神經網路演算法 (Neural Network Algorithms) 是一種受人腦運作機制啟發的技術，透過相互連接的節點 (神經元) 來模擬人腦的信息處理過程，這類演算法是機器學習與人工智慧的核心技術之一，可實現自適應學習與模式識別。

2.1.1 人工神經網路(Artificial Neural Network, ANN)

ANN[50] 為神經網路學習最基礎的架構，其架構由輸入層(Input Layer)、隱藏層(Hidden Layer)與輸出層(Output Layer)三個結構組成，每一層中的神經元(Neuron)數量可依照實際應用進行修改，且每個神經元都具有輸入及輸出，結構如圖 2-1 所示，各神經元以不同的權重(Weight)和偏移量(Bias)相互連接，計算式如下：

$$y_n = \sigma(\sum_{m=0}^M (w_{m,n} \times x_m) + bias_n) \quad (2-1)$$

y_n 為欲求得之神經節點值， M 為前一層神經節點數量， $w_{m,n}$ 為連接欲求得之節點的權重， x_m 為前一層之神經節點值， $bias$ 為偏移量，並透過激活函數 σ (Activation Function) 將權重進行非線性轉換後得到輸出。




圖 2-1 ANN 結構示意圖

2.1.2 卷積神經網路(Convolution Neural Network, CNN)

在深度學習中，CNN[51] 是一個關鍵組成部分，主要用於從圖像或訊號中提取特徵，CNN 的典型結構包含卷積層（Convolution Layer）、池化層（Pooling Layer）、扁平層（Flatten Layer）以及全連接層（Fully Connected Layer），全連接層即為前述的 ANN，結合各層可實現高效的辨識與分類。結構圖如圖 2-2：卷積層中含有多個卷積核(Kernel)，透過在輸入資料上進行滑動並進行卷積求和生成特徵圖(Feature Map)，再來進行池化縮小特徵圖尺寸，目的是為了減少模型參數量，進一步降低計算成本，最後由扁平層將特徵展平接著連接全連接層與輸出分類，整體計算公式如下：

$$y_{h,w} = \sigma \left(\sum_{m=0}^h \sum_{n=0}^w (x_{h,w} \times f_{h_f-n*s, w_f-m*s}) \right) \quad (2-2)$$

$$m = 0, 1, 2, \dots, h_f - 1$$

$$n = 0, 1, 2, \dots, w_f - 1$$

其中 y 為輸出， x 為輸入資料， f 為濾波器， (h_f, w_f) 代表濾波器大小，濾波器根據移動步伐 s 調整當前輸入資料間隔，並於輸出結果透過激活函數 σ 縮放至一定範圍以利下一層網路或是分類器進行計算。




圖 2-2 CNN 結構示意圖

2.2 知識蒸餾演算法

知識蒸餾(Knowledge Distillation, KD)[34] 是一種模型壓縮技術，透過學生較簡易的模型模仿教師複雜模型，讓學生模型在維持輕量化的同時達到與教師相似或更好的辨識效果。知識蒸餾技術能縮減用戶端模型的規模並降低訓練所需的計算資源，當教師模型經過充分訓練且具備良好的泛化能力時，用戶端的學生模型在針對個別數據進行知識蒸餾訓練時，也能展現出一定的知識遷移效果，其架構如圖 2-3 所示。




圖 2-3 知識蒸餾架構圖

知識蒸餾的目標是讓學生模型學習教師模型的輸出分佈，而非僅學習真實標籤，透過 softmax 函數對 logits 進行轉換，計算如下所示，

$$q^i = \frac{\exp(\frac{z^i}{T})}{\sum_j \exp(\frac{z^j}{T})} \quad (2-3)$$

其中 z^i 是第 i 個類別的輸出 logits，且引入一個溫度(temperature)係數變量 T ，當 T 越高時 softmax 的輸出機率分布越平滑，其分布的熵越大，模型訓練將更關注負標籤，有助於提高學生模型的泛化能力，如圖 2-4 所示，當 T 增加時，指數函數的變化率下降，使不同類別的機率差異減少，可以讓分佈更加平滑，而當 T 減小時則相反。




圖 2-4 不同溫度 T 時的機率分佈示意圖

在蒸餾的過程中，損失函數的計算如下所示：

$$L = \alpha L_{soft} + (1 - \alpha) L_{hard} \quad (2-4)$$

由蒸餾損失 L_{soft} 和學生損失 L_{hard} 加權組成，分別表示學生模型與教師模型輸出之間的軟標籤損失 (Soft Labels Loss)，與學生模型和真實標籤之間的硬標籤損失 (Hard Labels Loss)。如圖 2-5 所示，硬標籤除了目標分類的標籤為 1，其他皆為 0，又可稱為 One-hot label，而軟標籤透過 softmax 輸出各個類別機率總和為 1 的機率分佈，此方式可以知道不同類別間的相似程度，並保有對目標類別以外的響應，其中含有更多來自教師模型的暗知識 (Dark Knowledge)，能更好的引導學生模型。

L_{soft} 計算如下：

$$L_{soft} = - \sum_j^N p_i^T \log(q_j^T) \quad (2-5)$$

$$\text{其中 } p_i^T = \frac{\exp(\frac{v_i}{T})}{\sum_k^N \exp(\frac{v_k}{T})}, q_i^T = \frac{\exp(\frac{z_i^l}{T})}{\sum_k^N \exp(\frac{z_k^l}{T})}$$

其中 v_i 和 z_i^l 分別代表教師與學生的輸出 logits 而 p_i^T 和 q_i^T 則表示經過 softmax 教師與學生模型的輸出，以此計算教師與學生輸出的 KL (Kullback-Leibler) 散度，以此衡量兩個機率分佈的相似程度，促進教師模型與學生模型的 logits 匹配；而計算 L_{hard} 則是使用：

$$L_{hard} = - \sum_j^N c_j \log(q_j^l), \text{ 其中 } q_i^l = \frac{\exp(z_i^l)}{\sum_k^N \exp(z_k^l)} \quad (2-6)$$

c_j 表示真實標籤計算學生輸出與真實標籤的交叉熵，引入 L_{hard} 的原因在於不完全信任教師，以有效降低錯誤的傳播至學生模型，並透過 α 來調整兩者之間的比例。




圖 2-5 硬標籤與軟標籤示意圖

而在蒸餾策略的部分可以分為三種[52]，離線蒸餾、在線蒸餾與自蒸餾。離線蒸餾(Offline Distillation)為傳統的知識蒸餾訓練方法，通常分為兩個階段，首先預訓練一個教師模型，再對學生模型進行蒸餾訓練以傳遞知識，由於蒸餾過程中不用持續運行大模型，因此具有較低的運算成本。在線蒸餾(Online Distillation)於訓練過程中同時訓練教師與學生模型，學生模型從教師模型的即時輸出中學習，此方法讓兩者在相同數據上一起學習，甚至可以相互影響同時進化，但相對需要較高的運算成本。自蒸餾(Self-Distillation)則是使用自己對已進行蒸餾訓練的方法，透過模型的不同層或不同訓練階段互相傳遞知識，通常使用外加模組提取自身特徵引導自己的訓練方向，但其效果不如傳統蒸餾方式穩定。本論文中使用離線蒸餾策略，透過預訓練後的教師模型對跨域的學生模型進行蒸餾訓練，讓相似領域但不同工作狀態的老師與學生之間能有知識遷移的效果。

2.3 多教師演算法

多教師知識蒸餾 (Multi-Teacher Knowledge Distillation) 演算法的核心架構：利用多個預訓練模型作為教師模型，共同輔助學生模型的訓練。這些教師模型可能來自不同的架構或訓練數據，使學生模型能夠綜合不同教師的特徵與決策模式，獲得更具多樣性與泛化能力的知識。透過學習來自多個教師的知識，學生模型的準確度有機會趨近於所有教師模型的平均準確度，甚至可能超越其中最優的教師模型。此方法能有效運用已訓練大量資料的教師模型，僅需較少的額外資料，即可幫助學生模型吸收多種不同模型的知識，進一步提升其準確度。

在使用多教師對學生進行蒸餾時，為了有效地聚合多個教師的預測分佈，本論文比較平均權重法及透過計算教師預測，和真實標籤之間的交叉熵損失來分配

不同權重的動態權重，兩種權重分配方式。平均權重法假設所有教師模型對學生模型的貢獻相同，因此為每個教師分配等比例權重，即所有教師的預測結果對學生模型的學習影響力。而動態權重法透過計算每個教師模型的預測結果與真實標籤之間的交叉熵損失，來動態調整權重，確保更準確的教師能夠對學生模型產生更大的影響。相關計算式如下：

$$L_{IEKD}^k = - \sum_{i=1}^I p^i \log(q_{T_k}^i) \quad (2-7)$$

T_k 表示第k個教師，計算 L_{IEKD}^k 為對第k個教師預測的損失，使用

$$w_{KD}^k = \frac{1}{K-1} \left(1 - \frac{\exp(L_{IEKD}^k) - 1}{\sum_j \exp(L_{IEKD}^j) - 1} \right) \quad (2-8)$$

計算各個教師的權重 w_{KD}^k ，其中越少的 L_{IEKD}^k 則會分配到越大的權重值，從而對學生模型產生更大影響，然後由

$$L_{KD} = - \sum_{k=0}^K w_{KD}^k \sum_{i=0}^I z_{T_k}^i \log(q_S^i) \quad (2-9)$$

將各個教師的預測結果與權重進行加總，最後由

$$L = \alpha L_{hard} + (1 - \alpha) L_{KD} \quad (2-10)$$

以 α 分配 L_{hard} 與 L_{KD} 的比例計算出整體的損失函數，用以平衡學生模型學習真實標籤與教師知識的影響力。




圖 2-6 多教師訓練架構圖

本論文的多教師訓練架構如圖 2-6，教師與學生模型的訓練會使用不同的數據集，教師模型預先經過大量數據訓練，具備優秀的辨識能力，而學生模型則反映實際場域情形，僅能使用有限的訓練資料，因此在未使用知識蒸餾下的訓練成果辨識性能不佳。透過使用多級的訓練方式先對中量級的助教模型進行知識蒸餾再對學生模型進行二次蒸餾，逐步傳遞知識，同時建立多教師及助教的訓練方式，使得學生模型能夠更有效地學習來自高性能教師模型的資訊，透過多教師的融合，使學生模型能夠學習更廣泛且具泛化能力的知識，各個教師模型對學生模型的影響程度由損失函數動態調整權重分配，來達到提升學生模型辨識準確率的效果。

透過動態權重分配方法，能夠根據教師模型的能力來調整引導學生模型學習的權重，使得教師模型與學生模型的互動更加靈活與高效。當教師模型的預測能力不均衡時，該方法能夠自適應地調整各教師對學生模型學習過程的影響力，以確保學生模型接收到的知識更加準確。而來自不同領域的教師或助教動以態權重方法，根據教師在特定目標數據上的預測能力來動態調整影響權重，使學生模型能夠更有效地融合多源知識，進而提升其在不同應用場景下的適應能力。這種策略目標能夠優化學生模型的學習效果，並有助於提升其在多域學習中的泛化能力，確保其能夠在不同的環境下都能保持較高的準確性，以適應更廣泛的應用場景。

2.4 硬體加密演算法

本論文目標可以透過硬體加密技術提升隱私安全性，利用裝置的網路硬體 ID（如 MAC 地址）或 CPU 硬體序號作為識別標誌，以確保數據的加密與驗證機制。本論文以 Raspberry Pi 5 作為機邊端運算平台，每個嵌入式系統皆擁有獨立的網路硬體 ID 及 CPU 硬體序號，本地端基於這些唯一識別碼，透過雜湊演算法產生對應的加密金鑰，確保數據的安全性與不可逆性。伺服器端則利用這些識別碼作為驗證名單，對上傳的特徵向量或梯度進行檢查，確保數據來源的可信度。這種基於硬體識別的金鑰生成與驗證機制，有助於防止未授權設備的存取，進一步強化數據隱私與安全保護能力。金鑰的生成與管理至關重要，而雜湊演算法（Hash Algorithm）在金鑰生成過程中扮演了關鍵角色。常見的雜湊演算法包括 MD5[53]、SHA（Secure Hash Algorithm）[54]、Blake2[55]、Whirlpool[56] 等，其中 SHA-256 由於其較高的安全性與計算效率，被廣泛應用於資料加密與驗證機制。本論文採用 SHA-256 演算法進行金鑰生成，藉由該演算法的特性確保產生的金鑰具備

高強度的安全性與不可逆性，從而構建出穩固的加密保護機制，以抵禦潛在的攻擊威脅。在金鑰生成過程原理如下：

$$H_{i+1} = ((H_i + \sum_i' (E_i) + Ch(E_i, F_i, G_i) + K_i + W_i) \gg r_i) + H_i \quad (2-11)$$

每回合的哈希值 H_i 被分為 E_i, F_i, G_i 三個部分，通過右移 1、7、19 和 32 位的運算，增強數據的隨機性與分散特性，為確保每回合的運算獨特性，設計中引入固定常數 K_i 和輸入變量 W_i ， r_i 為該輪的右移數位數，這些設計共同作用生成了 256 位的金鑰，具備唯一性和不可逆性。同時加入

$$Ch(E_i, F_i, G_i) = (E_i \wedge F_i) \oplus (\neg E_i \wedge G_i) \quad (2-12)$$

非線性選擇函數，進一步提升生成過程的複雜性與不可預測性，為數據保護提供了強大的基礎。

確立了金鑰的生成方式後，接著須針對資料隱私建立有效的加密方式，而常見的加密方式有對稱式加密與非對稱式加密，其中對稱式加密採用單一金鑰，透過相同的金鑰即可加密與解密，常見的有 DES、3DES、AES 等；而非對稱式加密需要一個公開金鑰(Public key)和私有金鑰(Private key)來進行加解密，常用的有 RSA、Elgamal、ECC 等。為了兼顧安全性與計算效率，本論文採用 AES 演算法進行數據加密。AES 具有多種加密模式，Electronic Code Book (ECB)、Cipher Block Chaining(CBC)、Counter(CTR)，如圖 2-7。




圖 2-7 加密結構(a)ECB 結構圖(b)CBC 結構圖(c)CTR 結構圖

ECB 模式先將明文數據分成固定大小的區塊，然後使用相同的金鑰對每個區塊進行獨立的加密處理，然出現重複密文時可能會暴露加密模式或數據結構，從而降低安全性；CBC 方法始於隨機生成的初始化向量（IV）與第一個區塊進行 XOR，在每次加密都會加入前一區塊的密文，藉此提高安全性，但加密過程中，若某個區塊發生錯誤，則會影響後續所有區塊的解密，導致誤差累積，影響解密資料的完整性；CTR 每次的加密過程皆獨立並透過計數器來完成加解密，每次加密時，計數器的值會隨區塊索引變化，確保每個區塊的加密結果不同，這種設計避免了 ECB 模式可能暴露數據結構的問題，同時克服了 CBC 模式累積錯誤的風險。此外，加密和解密過程可以分割成多個獨立的子任務，因此能夠並行處理，提高運算效率。本論文實驗中，採用

$$C_i = P_i \oplus E_k(iv + i) \quad (2-13)$$

CTR 模式進行加密，其中 C_i 是第 i 個密文區塊， P_i 是第 i 個明文區塊， E_k 是 AES 加密算法其中 k 是金鑰，而 iv 為初始計數器的值， i 為當前計數器的數值，這設計確保了每個數據塊的加密結果獨立，即可完成加密過程。




圖 2-8 加密演算法硬體網路架構圖

加密方法的硬體網路結構如圖 2-8，邊緣端將收集到的振動數據加密後上傳至伺服器，確保數據在傳輸過程中的安全性。伺服器端可以根據不同硬體序號形成的金鑰進行解密運算，解密資料後經過伺服器端的教師模型輸出 logits 後再加密，下傳至邊緣端進行知識蒸餾。這樣的設計提供輸出資料的安全性，本論文預計以此架構實現數據加密傳輸，並在邊緣平台上實現此加密演算法，進一步加強

資料的隱私安全性，為人工智慧邊緣訓練提供一種安全可靠的解決方案。

2.5 小結

在本節介紹了本論文使用到的神經網路演算法與知識蒸餾演算法，透過多教師演算法設計多域多級的訓練架構；此外，為確保通訊過程中的數據安全性，本研究結合了硬體加密演算法，提供可靠的資料保護機制，提升系統的安全性與隱私保障。



第3章 資料處理與模型最佳化評估方法

本章介紹論文中使用的預處理方法、超參數調整策略與模型評估方式，透過適當的預處理，可提取有效特徵，進而提升模型的準確度。在深度學習中，隱藏層數、節點數與濾波器大小等超參數皆可調整，因此本章將探討超參數搜尋方法，根據不同需求，如準確度、運算量與記憶體限制，選擇最佳配置。最後，針對訓練完成的模型，透過多種指標評估其優劣，以全面分析模型的效能。

3.1 資料前處理

3.1.1 傅立葉轉換(Fourier Transform)

在進行人工智慧計算前，前處理常用來凸顯關鍵特徵，以提升辨識效果。本論文使用軸承震動作為輸入資料，若直接使用時域資料作為深度學習的輸入樣本，可能因工況變化而導致時域信號產生變動，造成在模型訓練上不易收斂，並在推論時容易造成誤判。為了克服此問題，將資料轉換成頻域作分析，能有助於凸顯出每筆資料共同的特徵頻率點與差異處，有效提高模型的準確率，而將時域轉換為頻域的方法，可依據離散傅立葉(Discrete Fourier Transform, DFT)公式進行轉換，其計算如下：

$$X[k] = \sum_{n=0}^{N-1} x[n] \cdot e^{-\frac{2\pi i}{N}kn} \quad (3-1)$$

其中的 $x[n]$ 為輸入時域信號， $X[k]$ 為輸出的頻域信號， N 為輸入時域信號樣本序列的總長度， $e^{-\frac{2\pi i}{N}kn}$ 為旋轉因子(twiddle factor)，經此公式即可將時域訊號轉為頻域訊號，而快速傅立葉轉換(Fast Fourier Transform, FFT)是一種用於高效計算離散傅立葉轉換及其逆變換的算法，FFT 利用對稱性與週期性降低其計算複雜度，提取有效點數也相當於對數據進行壓縮，有效降低模型所需的參數量及運算量。

3.1.2 正規化與標準化

在分析不同數據時，由於數據的單位不同，以及各欄位數值變化的幅度不同，這些差異可能會影響模型的辨識效果，甚至導致模型訓練過程中難以收斂。因此，為了減少這些不均衡影響，提高模型的穩定性與準確性，經常會對數據進行正規化(Normalization)或標準化(Standardization, STD)處理。這些方法能夠將數據縮放到特定範圍內，使每筆樣本或每個特徵的數值變化影響得到適當平衡，確保不同特徵之間具有相同的比較基準，並減少訓練過程中對特定特徵產生過擬合，

進而提升後續分析與模型訓練的效果。資料正規化常見的方式可分為兩種，其一為最小值最大值正規化(Min-Max Normalization)，此方式將資料大小等比例縮放至 0 與 1 的範圍之內，其計算公式如下：

$$X_{nom} = \frac{X - X_{min}}{X_{max} - X_{min}} \in [0,1] \quad (3-2)$$

其中 X_{nom} 為正規化後的資料， X 為原始資料， X_{max} 為原始資料中的最大值， X_{min} 為原始資料中的最小值，經(3-2)公式運算後，為確保資料的正確性，在有新的數據加入時，須重新確認最大值與最小值是否有變化；另一種方式為平均值正規化(Mean Normalization)，此方法將數據縮放至-1 與 1 之間，且經縮放後之數據平均值為 0，其運算公式如下：

$$X_{nom} = \frac{X - \mu}{X_{max} - X_{min}} \in [-1,1] \quad (3-3)$$

其中與最大值最小值正規化的差異在於使用原始資料平均值 μ 進行運算， X_{nom} 、 X 、 X_{min} 及 X_{max} 則與(3-2)相同。

資料標準化(Standardizing, STD)計算公式如下：

$$z_i = \frac{x_i - \mu_i}{\sigma_i} \quad (3-4)$$

其中 z_i 為經過標準化計算後的結果， x_i 為原始特徵值， μ_i 為全部特徵值的平均值， σ_i 則為該特徵在訓練集中的標準差，其標準差計算式如下：

$$\sigma_i = \sqrt{\frac{1}{N} \sum_{j=1}^M (x_j - \mu_i)^2} \quad (3-5)$$

N 為資料集總數， M 為每筆資料的特徵數量，主要是將資料進行縮放其特徵平均值為 0，標準差為 1。

透過上述資料縮放方法，可提升模型訓練的效率與收斂速度。如圖 3-1 所示，當特徵值之間的差距過大，使用梯度下降 (Gradient Descent) 進行模型最佳化時，損失函數可能呈現狹長的橢圓形，導致梯度下降的更新步伐不均勻，使訓練過程需要更長的時間與更高的計算成本。而透過適當的資料縮放，可以有效降低這種影響，使損失函數形狀更加對稱，進而加速模型的收斂，提高訓練效率，但也要考慮到縮放後的訊息損失。




圖 3-1 最佳化模型時損失函數(loss function)分布[57]

3.2 超參數最佳化及模型訓練

超參數最佳化 (Hyperparameter Optimization) 是在機器學習與深度學習中，透過調整模型的參數來提升性能的關鍵過程，與透過訓練數據學習的參數不同，超參數是在訓練開始前需要預先設定的數值，並會直接影響模型的學習能力與最終表現。常見的超參數包括學習率、正則化參數、隱藏層的節點數、批量大小、激活函數等。由於超參數的選擇會對模型的收斂速度、訓練穩定性以及泛化能力產生顯著影響，因此找到合適的超參數組合至關重要。超參數最佳化的目標即是透過適當的方法搜尋最優配置，使模型能夠在訓練數據上達到最佳學習效果，並保持良好的泛化能力。

3.2.1 網格搜尋法

網格搜尋 (Grid Search, GS) 是一種自動化的超參數搜尋方法之一，透過窮舉法 (Exhaustive Search) 來遍歷所有可能的超參數組合，以取代傳統依賴人工調整超參數的繁瑣過程。此方法首先需明確定義每個超參數的搜索範圍與可能的值，然後按照所有可能的組合進行測試，當所有組合訓練完成後，根據模型的評估結果選出最佳的超參數配置。

然而，網格搜尋的主要缺點在於計算成本極高，隨著需調整的超參數數量增加，搜索空間會呈指數級增長，使得遍歷所有可能組合的計算成本變得龐大。此外，機器學習模型在訓練時通常會隨機初始化權重，因此即使使用相同的超參數，每次訓練的結果仍可能有所差異，雖然網格搜尋能夠保證找到全局最優解，但其計算效率較低。

3.2.2 隨機搜尋法

隨機搜尋 (Random Search, RS) 也是自動化的超參數搜尋方法之一，與網格搜尋法不同，主要差異在於搜尋策略，隨機搜尋法不會設定具體數值，而是為每個超參數設定一個範圍，並在該範圍內隨機抽樣超參數組合進行測試。在隨機搜尋的過程中，需事先設定搜索次數，模型將根據該次數隨機選取不同的超參數組合並進行訓練與評估，最終根據評估結果選擇最佳組合。這種方法的優勢在於能夠在高維度的超參數空間中更靈活地探索不同區域，而不像網格搜尋法受限於固定間隔。如圖 3-2 網格搜尋法與隨機搜尋法的比較結果中，網格搜尋法可以清楚觀察到參數點的分布呈現規則且間隔均勻，而隨機搜尋的參數點則以不規則分布，隨機落在定義的搜尋範圍內。因此，當某些超參數對模型的影響較大，而其他超參數影響較小時，隨機搜尋有更高的機率發現較佳的超參數組合，但如果搜尋次數過少，則仍可能無法涵蓋關鍵的超參數區域，導致最終選出的超參數組合未能達到最佳效果。




圖 3-2 GS 與 RS 搜尋法比較[58]

3.2.3 貝葉斯最佳化

貝葉斯最佳化 (Bayesian Optimization) 是一種基於代理模型 (Surrogate Model) 與取樣函數 (Acquisition Function) 所組成的最佳化方法，適合用於計算成本較高的函數最佳化場景。與網格搜尋 (Grid Search) 或隨機搜尋 (Random Search) 不同，貝葉斯最佳化並非單純地遍歷或隨機選取超參數組合，而是透過數據驅動 (Data Driven Decision Making, DDDM) 的方法來動態選擇評估點，以提升搜尋效率並減少不必要的計算開銷。

在貝葉斯最佳化的過程中，利用高斯過程 (Gaussian Process, GP) 來建立超

參數空間的代理模型，高斯過程的特點是，對於給定的輸入，它可以估計對應輸出的均值（Mean）和方差（Variance），進而描述模型在該點的不確定性，這使得我們不僅可以預測某個超參數組合的性能，還可以衡量該預測結果的可靠性。隨著超參數搜尋的進行，貝葉斯最佳化會根據當前的代理模型，利用取樣函數來決定下一個應該評估的超參數組合，通常優先選擇那些不確定性較大的區域，以獲取更多資訊並逐步完善代理模型。圖 3-3 為貝葉斯最佳化的過程，其中黑線代表代理模型，綠線代表取樣函數，藍色區域則顯示模型的不確定範圍，而虛線則為尚待測試的代理模型。在初始階段，藍色區域較為廣泛，表示模型的不確定性較高，但隨著迭代次數的增加，代理模型會根據已測試的數據逐步擬合，減少不確定性區域，最終獲得代理模型的分布趨近於真實模型的最佳解。




圖 3-3 貝葉斯搜尋示意圖[59]

3.3 模型評估法

3.3.1 交叉驗證

交叉驗證（Cross-validation, CV）是一種常見的統計方法，主要用於評估人工智慧模型的泛化能力，即模型在未見過的數據上表現的能力。一般來說，數據集的分布會直接影響模型的評估結果，若數據集的特徵差異較大，直接切割成訓練集與測試集可能導致評估結果的不穩定。若訓練集與測試集的分布不均勻，模型可能會過度擬合（Overfitting）訓練集，導致無法有效泛化到測試集，使測試結果無法準確代表模型的實際效能。因此，為了避免因隨機切割數據集所產生的數據偏差問題，交叉驗證技術被廣泛應用於機器學習與深度學習領域，以更可靠

地評估模型表現。交叉驗證將數據集劃分為多個子集，並通過不同的方式進行多次訓練與測試，以確保模型不會因特定數據分布而影響最終結果。常見的交叉驗證方法包括 K 折交叉驗證（K-Fold Cross-validation）、留一法（Leave-One-Out Cross-validation, LOO-CV）、留 P 法（Leave-P-Out Cross-validation, LPO-CV）等，其中 K 折交叉驗證是最常用的方法。如圖 3-4 所示，K 折交叉驗證將數據集劃分為 5 等分，其中淺色區塊代表訓練集，深色區塊代表驗證集。在每次迭代中，從 5 個子集中選擇其中一部分作為驗證集，剩餘的部分則用於訓練模型，並計算該迭代的準確度。整個過程將重複 5 次，使每個子集都被用作一次驗證集，最終取所有回合得到的準確度平均值作為模型的綜合評估指標。




圖 3-4 交叉驗證方法示意圖

3.3.2 混淆矩陣

混淆矩陣（Confusion Matrix）是一種常見的統計工具，廣泛應用於人工智慧與機器學習領域中，專門用來評估分類模型的性能。混淆矩陣能夠直觀地呈現模型在不同類別上的預測結果，並且幫助分析錯誤的類型，以利後續優化，如圖 3-5 所示，其中將分類結果區分為正類（Positive）與負類（Negative），並依照模型的預測結果是否與真實標籤相符，進一步劃分為四種類別，包括真陽性（True Positive, TP）、真陰性（True Negative, TN）、偽陽性（False Positive, FP）與偽陰性（False Negative, FN）。當模型的預測結果與實際類別一致時，若該樣本為正

類且被成功預測為正類，則稱為真陽性；若為負類且成功預測為負類，則稱為真陰性；若模型將負類錯誤分類為正類，則為偽陽性；若模型將實際為正類的樣本誤分類為負類，則稱為偽陰性。透過分析這四種類別的比例，可以有效衡量模型的準確性與穩定性。

Confusion Matrix		Predict	
		Positive	Negative
Actual	Positive	TP	FN
	Negative	FP	TN

圖 3-5 混淆矩陣

基於混淆矩陣，可以延伸出多種評估指標，以更精確地描述模型的分類能力。準確度（Accuracy, ACC）是最直觀的衡量方式

$$ACC = \frac{TP + TN}{TP + TN + FP + FN} \quad (3-6)$$

計算方式為模型正確預測的比例，即真陽性與真陰性的總和除以所有樣本數。

然而，當數據集分布不均衡時，僅依賴準確度可能會產生誤導，因為即使模型完全忽略少數類別，仍可能獲得較高的準確率。除了準確度，還可考量其他評估指標，例如精確度（Precision, PRE）

$$PRE = \frac{TP}{TP + FP} \quad (3-7)$$

其關注模型在預測為正類時的可信度，即被模型判定為正類的樣本中，實際為正類的比例。精確度較高的模型適用於需要避免誤報的情境。另一個指標是真陽率（True Positive Rate, TPR），又稱召回率（Recall）

$$TPR = \frac{TP}{TP + FN} \quad (3-8)$$

用來衡量實際為正類的樣本中有多少被成功預測為正類。該指標特別適用於希望減少漏報的應用場景。真陰率（True Negative Rate, TNR）

$$TNR = \frac{TN}{TN + FP} \quad (3-9)$$

則衡量模型對負類的判別能力，表示實際為負類的樣本中有多少被正確分類，適

用於需要確保負類預測準確性的場合。偽陽率（False Positive Rate, FPR）

$$FPR = \frac{FP}{TN + FP} \quad (3-10)$$

與偽陰率（False Negative Rate, FNR）

$$FNR = \frac{FN}{FN + TP} \quad (3-11)$$

則分別代表模型誤判負類為正類，或誤判正類為負類的比例。當偽陽率過高時，系統的誤報率可能會影響整體使用體驗，而當偽陰率過高時，則代表模型容易忽略關鍵資訊，如安全監測系統中，過多的偽陰性可能會讓真正的異常事件未被檢測出來。本研究著重於人工智慧平台的開發與多域多級知識蒸餾演算法的可行性驗證，因此在模型評估方面，主要以準確度作為核心指標，以評估模型的整體表現。

3.4 小結

本章介紹了資料前處理的方法，透過前處理可以凸顯關鍵特徵並對數據進行壓縮以減少模型的輸入資料，而後介紹了深度學習中的超參數選擇方法以及模型評估策略，本論文將前述的處理方式應用在不同的數據集上，並針對不同的數據集進行超參數搜尋，透過交叉驗證選擇性能最佳的模型進行後續的實驗比較。

第4章 軟硬體系統架構開發

4.1 系統架構

本論文基於深度學習的故障診斷技術，目標達到降低故障停機時間，避免因設備異常而導致生產力下降。然而，隨著性能的提升增加了計算資源的需求，也提高了網路傳輸的成本，不易將高性能模型部署至邊緣端進行即時應用。此外，與正常狀態數據相比，故障狀態的數據較為稀缺，難以大量收集，導致訓練高精度模型變得更加困難。為了解決這些問題並降低成本，透過知識蒸餾可將大型模型中學習到的知識有效轉移至輕量級模型，使其在較低計算資源需求的情況下，依然能夠維持良好的診斷性能。然而，由於教師模型 (Teacher Model) 與學生模型 (Student Model) 之間的能力存在顯著差異，若直接從深層模型提取知識至輕量級模型，可能無法達到最佳的學習效果。因此，為提升知識轉移的效果，本論文參考前述文獻的方法，提出如圖 4-1 的系統架構，引入中量級的助教模，作為教師與學生模型之間的橋樑，以多級的訓練方法協助知識的逐步遷移，提升學生模型的學習效果。此外，考量到邊緣端設備往往僅能獲取有限的訓練數據，為了提升學生模型的辨識能力，本論文選擇在相似工作領域且擁有大量數據的環境下，預先訓練教師模型，確保其具備足夠的故障診斷知識，為進一步強化知識遷移的效果，本論文採用了多教師 (Multi-Teacher) 設計，透過多個領域的教師模型引導學生模型訓練，使其能夠學習更豐富的知識並提升泛化能力，並比較參數依據比例縮放設計的教師與超參數優化的教師對學生的教學效果，最終達成模型壓縮與知識遷移的雙重目標，提升邊緣端應用的可行性與實用性。

在數據傳輸方面，本論文透過 HTTP (HyperText Transfer Protocol) 進行數據的即時傳輸，透過 HTTP 協議，邊緣端設備可以將振動數據上傳至伺服器，並獲取來自教師模型或助教模型的診斷結果，為了保障數據的安全性與隱私性，進一步導入資料加密技術，利用邊緣端設備的硬體序號生成金鑰，透過 AES 加密方法以防止數據在傳輸過程中遭受盜取與竄改。透過這些技術，達到提升智慧工業系統的診斷能力與邊緣計算的應用可行性，並加強數據傳輸與存儲過程中的安全性與隱私保護，使得故障診斷技術能夠在工業環境中更安全、穩定地運行。




圖 4-1 系統架構圖

在實驗平台部分，伺服器端電腦的詳細規格如表 4-1，用於部屬教師模型提供機邊端設備進行數據交握，並執行模型超參數以及訓練架構的驗證，機邊端平台使用 Raspberry Pi 5 的詳細規格如表 4-2，用於驗證本論文所設計系統的可行性。

表 4-1 伺服器端規格表

	規格
作業系統	Windows 11
CPU	AMD Ryzen™ 5 3600
GPU	RTX 3090
RAM	32 GB

表 4-2 機邊端規格表

	規格
作業系統	Raspbian GNU/Linux 12 (bookworm)
CPU	Broadcom BCM2712 quad-core Cortex-A77
RAM	8 GB

4.2 數據分析

本論文在數據方面採用軸承振動數據集的網路公開資料 CWRU[60]、TBVD[61] 以及 VDAB[62]，透過三個數據集，更廣泛地評估系統架構及演算法，在伺服器上驗證演算法架構，以交叉驗證的方式，輪流將其中兩組作為教師模型的訓練資料，一組作為學生模型的訓練資料，且學生模型的訓練僅會使用少量資料進行訓練，透過這樣的對比，我們將能夠全面評估演算法在不同實際應用場景下的性能表現，藉此證明此方法的可行性和有效性。

4.2.1 CWRU 數據集

本論文使用的第一個數據集是美國凱斯西儲大學(CWRU) 滾珠軸承振動數據集[60]，該數據集被廣泛應用於感應馬達軸承故障診斷的研究與驗證，如圖 4-2，在馬達的驅動端與風扇端分別安裝了兩顆加速規，以 48kHz 與 12kHz 進行取樣。




圖 4-2 CWRU 資料集實驗平台

為了確保實驗數據的一致性，本論文對 48kHz 的驅動端軸承數據進行降取樣 (Down sampling)處理，使其取樣頻率與其他數據庫保持一致，以利後續測試計畫提出的分類方法。資料庫包括內圈 (Inner ring, IR)故障、外圈 (Outer ring, OR)故障、滾珠故障和正常狀態 (Normal)，而故障的直徑分為 0.007、0.014 和 0.021 英寸，表 4-3 列出不同故障狀態，以及針對內圈故障、外圈故障和正常狀態規劃的標籤。在數據域處理部分，將 48kHz 的振動訊號透過多項式差值法降取樣至 10kHz 後，以每段 2048 點進行切割後執行快速傅立葉轉換獲取頻域特徵，各個狀態下的波形顯示於圖 4-3，可以看出在 Normal 下平順的運轉，而 IR 與 OR 在不同的故障尺寸下，

可以看出不同故障狀態下具有不同的頻率分佈，將三種負載下的相同故障大小分為同一類，共可分為 7 種狀態，前處理方法的頻域特徵變化清晰地反映軸承磨損造成的振動，更容易判斷與診斷，有助本論文的實驗更準確地評估軸承狀態。




圖 4-3 CWRU 資料集頻域波型

表 4-3 CWRU 故障類型

故障類型	毀損大小(in.)	毀損大小(mm)	標籤
正常	0	0	0
內圈毀損	0.007	0.17	1
內圈毀損	0.014	0.35	2
內圈毀損	0.021	0.53	3
外圈毀損	0.007	0.17	4
外圈毀損	0.014	0.35	5
外圈毀損	0.021	0.53	6

4.2.2 TBVD 數據集

第二個數據集為不同負載條件下，感應馬達三軸軸承振動資料集(TBVD)[61]，包含三維（X、Y 和 Z 軸）的軸承故障振動資料，平台由三相感應馬達和具有可變負載的交流發電機組成，加速度計安裝於靠近驅動端軸承的馬達外殼上，以 10kHz 進行取樣，軸承狀態分為內圈故障、外圈故障和正常狀態，故障程度分為 0.7、0.9、1.1、1.3、1.5 和 1.7mm，並且分別在 100W、200W 和 300W 負載下收集振動資料。表 4-4 列出了不同的故障以及對內圈故障、外圈故障和正常狀態規劃標籤，各個狀態下的波形如圖 4-5 所示，可以看出在不同故障狀態下具有不同的振動頻率分佈。



圖 4-4 TBVD 資料集實驗平台

表 4-4 TBVD 故障類型

故障類型	毀損大小(mm)	標籤
正常	0	0
內圈毀損	0.7	1
內圈毀損	1.3	2
內圈毀損	1.7	3
外圈毀損	0.7	4
外圈毀損	1.3	5
外圈毀損	1.7	6




圖 4-5 TBVD 資料集頻域波型

4.2.3 VDAB 數據集

第三個數據集則是使用推力球軸承和剝落故障的振動數據(VDAB)[62]，資料集由推力球軸承在健康和故障條件下，進行振動量測量，故障狀況指外圈和內圈處以人工產生的剝落缺陷，使用安裝在軸承外圈上的加速度計收集軸向振動，資料集均以 25.6 kHz 進行取樣，如同前述將降取樣率使用。表 4-5 列出使用到的不同故障狀態以及對選用的內圈故障、外圈故障和正常狀態規劃的標籤，各個狀態下的振動頻譜波形如圖 4-6 所示，可以看出在不同故障狀態下具有不同的頻率分佈。




圖 4-6 VDAB 資料集頻域波型

表 4-5 VDAB 故障類型

故障類型	毀損大小(mm)	標籤
正常	0	0
內圈毀損	1.0	1
內圈毀損	2.1	2
內圈毀損	3.8	3
外圈毀損	1.4	4
外圈毀損	2.4	5
外圈毀損	4.0	6

4.2.4 模型超參數

本論文所使用的三個數據集，採用 CNN 進行訓練，由於 CNN 在特徵提取方面具有優異的性能，適合處理不同應用場景，以提升故障診斷的準確性與泛化能力。在超參數優化採用貝葉斯最佳化自動搜尋最優模型超參數，以提高模型的訓練效率與性能表現。為了確保模型的穩定性與收斂速度，模型的最佳化演算法均使用 Adam 優化器，並以 Categorical Crossentropy 作為多分類損失函數，以確保模型在多類別分類問題中的有效學習，分類器的激活函數使用 Softmax，以計算各輸出節點的信心值，確保模型能夠正確評估不同類別的機率分佈。

為了驗證模型的性能與穩定性，本論文採用交叉驗證進行模型的評估，並以準確度和模型參數量作為主要評估標準。由於各個數據集的樣本數量不一，為了確保不同數據集之間的公平性，本論文統一使用 K-fold 交叉驗證法將數據集切割，以確保訓練與測試數據的均衡分配。透過 K-fold 交叉驗證，可以有效檢測模型的泛化能力，減少因數據分佈偏差所造成的影響，進而提升模型在實際應用中的穩健性與可靠度。

在 CWRU 資料集中，進行交叉驗證評估模型訓練結果，對時域資料以每 2048 點執行 FFT 取得頻域特徵，CNN 模型超參數搜尋範圍如表 4-6，共搜尋七個參數，其中包含捲積層數、卷積層使用的卷積核數、卷積核長度、卷積核移動步伐，再來是攤平後的全連接層數、全連接層點數以及模型使用的激活函數。

表 4-6CWRU 資料集 CNN 演算法超參數範圍表

參數名稱	數值
捲積層數	1~17
Filters	4~128
Kernel size	3~21
Stride size	1~3
ANN 層數	1~2
ANN 點數	10~500
激活函數	Sigmoid, ReLU

經過貝葉斯最佳化後的訓練結果如表 4-7，將交叉驗證準確度作為排名，由高到低進行排序，本次超參數交叉驗證準確度都於 98%以上，由於伺服器端的硬體性能較高，不易被參數量與記憶體空間限制，因此採用排名第一的模型作為教師模型的候選名單，並於後續實驗中將其稱為超參數教師模型，其捲積的各層詳細參數於表 4-8。

表 4-7 CWRU 資料集超參數搜尋前十名

捲積層數	激活函數	ANN 層數	ANN 點數 1	ANN 點數 2	ACC	參數量
10	ReLU	1	444	0	0.998222	351,101
6	ReLU	2	302	55	0.997333	600,392
8	ReLU	1	306	0	0.996444	447,010
4	Sigmoid	1	232	0	0.994667	643,005
12	ReLU	2	499	240	0.990222	637,763
10	ReLU	1	416	0	0.989333	546,140
7	ReLU	2	295	68	0.988444	641,771
8	ReLU	2	199	455	0.987556	435,364
7	ReLU	2	11	143	0.985778	381,545
7	ReLU	2	191	79	0.983111	466,988

表 4-8 CWRU 排名第一模型捲積層詳細超參數

層數	Filters	Kernel size	Stride size
1	18	(1, 13)	(1, 1)
2	53	(1, 8)	(1, 1)
3	40	(1, 5)	(1, 3)
4	82	(1, 3)	(1, 3)
5	56	(1, 15)	(1, 3)
6	65	(1, 6)	(1, 1)
7	104	(1, 13)	(1, 3)
8	70	(1, 6)	(1, 3)
9	13	(1, 20)	(1, 2)
10	111	(1, 20)	(1, 2)

在 TBVD 資料集中，以 CWRU 模型架構為參考進行超參數搜尋，設計的 CNN 模型超參數搜尋範圍如再來是攤平後的全連接層數、全連接層點數以及模型使用的激活函數。

表 4-9，共搜尋七個參數，其中包含捲積層數、卷積層使用的卷積核數、卷積核長度、卷積核移動步伐，再來是攤平後的全連接層數、全連接層點數以及模型使用的激活函數。

表 4-9 TBVD 資料集 CNN 演算法超參數範圍表

參數名稱	數值
捲積層數	1~17
Filters	4~128
Kernel size	3~21
Stride size	1~3
ANN 層數	1~2
ANN 點數	10~500
激活函數	Sigmoid, ReLU

經過貝葉斯最佳化後的訓練結果如表 4-10，將交叉驗證準確度作為排名，由高到低進行排序，本論文將採用排名第一的模型作為教師模型的候選名單，其捲積的各層詳細參數於表 4-11。

表 4-10 TBVD 資料集超參數搜尋前十名

捲積層數	激活函數	ANN 層數	ANN 點數 1	ANN 點數 2	ACC	參數量
10	ReLU	1	140	0	0.971429	447,063
10	ReLU	2	244	10	0.967033	367,786
9	ReLU	1	143	0	0.962637	576,496
5	ReLU	2	319	111	0.96044	651,898
10	ReLU	1	85	0	0.958242	596,416
12	ReLU	2	189	113	0.956044	776,858
11	ReLU	1	289	0	0.949451	550,317
11	ReLU	1	49	0	0.947253	644,148
10	ReLU	2	164	76	0.942857	566,785
10	ReLU	1	219	0	0.940659	321,442

表 4-11 TBVD 排名第一模型捲積層詳細超參數

層數	Filters	Kernel size	Stride size
1	115	(1, 15)	(1, 1)
2	51	(1, 19)	(1, 1)
3	18	(1, 3)	(1, 2)
4	104	(1, 11)	(1, 3)
5	81	(1, 19)	(1, 3)
6	65	(1, 8)	(1, 3)
7	113	(1, 4)	(1, 3)
8	13	(1, 8)	(1, 2)
9	65	(1, 11)	(1, 3)
10	57	(1, 13)	(1, 2)

在 VDAB 資料集中，同樣以 CWRU 模型架構為參考進行超參數搜尋，設計的 CNN 模型超參數搜尋範圍如表 4-10，共搜尋七個參數，其中包含捲積層數、卷積層使用的卷積核數、卷積核長度、卷積核移動步伐，再來是攤平後的全連接層數、全連接層點數以及模型使用的激活函數。經過貝葉斯最佳化後的訓練結果如表 4-13，將交叉驗證準確度作為排名，由高到低進行排序，同樣採用排名第一的模型作為教師模型的候選名單，其捲積的各層詳細

參數於表 4-14。

表 4-12 VDAB 資料集 CNN 演算法超參數範圍表

參數名稱	數值
捲積層數	1~17
Filters	4~128
Kernel size	3~21
Stride size	1~3
ANN 層數	1~2
ANN 點數	10~500
激活函數	Sigmoid, ReLU

表 4-13 VDAB 資料集超參數搜尋前十名

捲積層數	激活函數	ANN 層數	ANN 點數 1	ANN 點數 2	ACC	參數量
5	ReLU	2	183	371	0.999518	624,243
6	ReLU	2	158	90	0.998072	483,601
6	ReLU	1	298	0	0.995663	420,019
6	ReLU	2	276	388	0.992289	505,367
4	ReLU	1	348	0	0.990843	946,781
7	ReLU	1	150	0	0.988434	308,829
5	ReLU	2	140	218	0.987952	566,406
4	ReLU	1	290	0	0.986988	451,779
8	ReLU	2	186	287	0.98506	637,414
10	ReLU	1	298	0	0.976386	571,586

表 4-14 VDAB 排名第一模型捲積層詳細超參數

層數	Filters	Kernel size	Stride size
1	84	(1, 8)	(1, 2)
2	119	(1, 13)	(1, 1)
3	86	(1, 9)	(1, 1)
4	75	(1, 6)	(1, 1)
5	18	(1, 6)	(1, 3)

4.3 多級訓練架構

本論文的多域多級模型訓練方式，首先對三個軸承振動資料集，分別針對不同規模的教師(Teacher)、助教(Assistant)及學生(Student)三種模型，獨立進行訓練，以獲得各個模型在不同訓練資料量的準確率表現數據。完成初步訓練後，進一步使用教師與助教模型對學生模型進行知識蒸餾，同時亦比較不同訓練資料量下學生模型在獨立訓練與透過知識蒸餾學習後的辨識能力，驗證在少量資料訓練下，透過知識蒸餾進行的遷移學習效果，可以獲得較高的辨識準確率。

表 4-15 教師、助教與學生模型參數

	教師(Teacher)	助教(Assistant)	學生(Student)
Block1	(1x3 conv1D,8)×2 MaxPool	(1x3 conv1D,8)×1 MaxPool	(1x3 conv1D,4)×1 MaxPool
Block2	(1x3 conv1D,16)×2 MaxPool	(1x3 conv1D,16)×1 MaxPool	(1x3 conv1D,8)×1 MaxPool
Block3	(1x3 conv1D,32)×3 MaxPool	(1x3 conv1D,32)×1 MaxPool	(1x3 conv1D,16)×1 MaxPool
Block4	(1x3 conv1D,64)×3 MaxPool	(1x3 conv1D,64)×1 MaxPool	
Block5	(1x3 conv1D,64)×3 MaxPool		
Activation Function	Relu		
Dense	128-128	128	128
Output	7		
Activation Function	Softmax		
Optimizer	Adam		
Parameter	348,655	29,783	11,791

透過等比例縮放參數與刪減各區塊層數的方式設計教師、助教與學生模型詳細的模型參數如表 4-15，教師模型為 1D CNN VGG 網路架構；而助教以及學生模

型以教師模型架構為基礎，對各區塊層數參數進行刪減，縮小模型大小，最終的模型參數量教師與助教相差 11.7 倍，教師與學生相差 29.5 倍，針對使用超參數搜尋的教師與使用 VGG 架構的教師對於學生知識蒸餾效果的影響也會於後續進行比較。

表 4-16 TBVD 各模型大小單獨訓練效果

模型 資料筆數	Student	Assistant	Teacher
72	0.552	0.648	0.769
182	0.769	0.868	0.934
364	0.813	0.912	0.956

表 4-17 CWRU 各模型大小單獨訓練效果

模型 資料筆數	Student	Assistant	Teacher
35	0.742	0.822	0.964
71	0.862	0.978	0.987
143	0.991	0.977	0.998

表 4-18 VDAB 各模型大小單獨訓練效果

模型 資料筆數	Student	Assistant	Teacher
65	0.529	0.764	0.939
132	0.727	0.909	0.909
264	0.906	0.910	0.985

在獨立訓練的比較與驗證部分，針對 TBVD、CWRU 及 VDAB 三個軸承振動數據集，分別進行不同模型規模下的單獨訓練，並比較其在不同訓練數據量下的辨識準確度。詳細結果列於

表 4-16 到表 4-18，其中，各個表格呈現了不同資料集在不同模型大小下，以不同訓練數據量進行單獨訓練時的辨識準確率。依據各個表中所示的資料量，驗證資料是單獨切分出 20% 未參與訓練資料，剩餘的 80% 資料為訓練資料集，並使用 K 折交叉驗證將 5 折的訓練結果進行平均。三個資料集的訓練結果顯示：使用

學生模型在最少資料量下，訓練的準確度不盡理想，顯示其受限於模型規模，難以學習到足夠的特徵資訊，無法有效的檢測軸承的使用狀態，使用教師模型在最大資料量下訓練表現出最好的效果，使用助教模型表現介於教師與學生模型之間，能在較小規模的模型結構下，仍保有一定的辨識能力，此結論在各個資料集中表現趨勢相同。

4.4 小結

本章節介紹系統的硬體與模型訓練架構，以及通訊架構與傳輸方法；然後針對本論文使用的資料集進行介紹，透過不同資料集來更廣泛的對系統架構及演算法實現進行評估；最後則是針對不同資料集進行超參數搜尋，找尋最佳化模型參數，用以進行後續訓練。



第5章 實驗結果與分析

5.1 跨域知識蒸餾效果

本論文的跨域(Cross-domain)知識蒸餾架構如圖 5-1 所示，實驗首先於前述的三個資料集中選擇一組數據作為資料集 A 用於訓練教師模型，並使用完整的資料用於訓練以達到最佳的辨識效果，而後在剩餘的兩個資料集中選擇其一作為資料集 B 用於訓練學生模型，並僅採用該資料集中的少量樣本，透過已訓練完成的教師模型所產生的預測結果引導學生模型進行知識蒸餾訓練。此方式模擬了邊緣端平台在實際應用中僅有少量可用數據的情境，進而驗證在小樣本學習下的可行性與有效性。




圖 5-1 跨域知識蒸餾訓練架構圖

實驗設計中將三個資料集輪流作為教師與學生模型的訓練來源，並比較使用 VGG 架構下的教師模型與經由貝葉斯超參數優化所調整出的教師模型對於學生模型的知識蒸餾效果，詳細結果列於表 5-1 到表 5-3。表 5-1 中使用 VDAB 資料集的 VGG 教師模型對 TBVD 資料集的學生模型進行知識蒸餾訓練其準確度為 0.792，使用超參數教師模型蒸餾後的準確率僅有 0.784，而使用 CWRU 資料集的 VGG Big 教師模型對 TBVD 資料集的學生模型進行知識蒸餾訓練其準確度為 0.822，使

用超參數教師模型蒸餾後的準確率則僅有 0.764，由結果顯示透過相似架構下以等比例縮放參數與刪減各區塊層數的方式設計的教師與學生模型會有較好的知識蒸餾效果，表 5-2 與表 5-3 的實驗結果中皆有相同趨勢，因此，為了確保後續實驗的一致性與效能，本論文後續知識蒸餾相關實驗皆將以 VGG 架構的教師模型為主體進行設計與分析。

表 5-1 兩種教師架構對 TBVD 學生的跨域蒸餾效果

教師模型架構 教師資料集	VGG 教師	超參數教師
VDAB	0.792	0.784
CWRU	0.822	0.764

表 5-2 兩種教師架構對 VDAB 學生的跨域蒸餾效果

教師模型架構 教師資料集	VGG 教師	超參數教師
CWRU	0.851	0.824
TBVD	0.851	0.806

表 5-3 兩種教師架構對 CWRU 學生的跨域蒸餾效果

教師模型架構 教師資料集	VGG 教師	超參數教師
VDAB	0.969	0.966
TBVD	0.975	0.920

5.2 基於多級知識蒸餾效果

本論文嘗試知識蒸餾中導入助教模型的多級訓練方法，實現遷移學習效果的架構如圖 5-2，先由教師模型對中等規模的助教模型進行知識蒸餾訓練，再由助教模型將所學知識進一步傳遞至小型的學生模型。透過引入助教作為中介橋樑，可以緩解教師與學生模型之間模型參數量差異過大造成知識傳遞障礙，助教模型作為一個具備中等參數量的過渡網路，能更容易從教師模型中學習複雜特徵並傳遞給學生模型，使學生模型在接受訓練時更易於收斂，進而提升其在少量資料條件下的辨識性能。




圖 5-2 知識蒸餾導入助教輔助之多級訓練架構圖

由表 5-4 的實驗結果中可以觀察到，分別使用 VDAB 與 CWRU 資料訓練的教師模型對 TBVD 資料集以小樣本(總資料量的 5%與 10%) 進行知識蒸餾訓練學生與助教模型的效果：利用教師學生模型進行蒸餾訓練與單獨訓練學生模型的方式相比可以有 3~14%的提升；而助教模型利用教師進行蒸餾訓練與單獨訓練助教模型相比則可以有 16~18%的提升幅度；進一步透過訓練後的助教模型對學生模型進行訓練的結果(Student(Assistant)模式)，相比單獨訓練學生模型可以有 4~19%的提升，相比教師直接對學生模型進行訓練則可以額外提升 1~5%，顯示出助教模型在蒸餾過程中扮演著關鍵的中介角色。觀察表 5-5 及表 5-6 針對 CWRU 與 VDAB 資料集所進行的訓練結果也驗證了此趨勢，透過助教模型對學生模型進行輔助訓練相比教師的直接蒸餾訓練可以有 1~2%的額外提升。以上結果顯示，三個資料集的故障尺寸皆不相同，但透過跨域教師的輸出分布提供額外的資訊用於知識蒸餾訓練中，有助於改善學生的辨識效果。而教師相較於學生模型大 29.5 倍，辨識準確率的确具有明顯地優勢；但若透過小 11.7 倍的助教模型，來降低因模型尺寸差異過大的蒸餾效果不佳，進一步訓練相較助教模型小 2.5 倍的學生模型，

所進行輔助的訓練，相較於教師模型直接蒸餾，學生模型可以額外提升最高 5% 的準確率，有助維持較好的辨識效果利於部署至機邊端。

表 5-4 使用 VDAB 與 CWRU 作為教師訓練 TBVD 學生

模型尺寸 資料量	VDAB 教師			CWRU 教師		
	Student	Assistant	Student (Assistant)	Student	Assistant	Student (Assistant)
72	0.692	0.837	0.711	0.700	0.834	0.713
182	0.792	0.929	0.842	0.822	0.934	0.863

表 5-5 使用 VDAB 與 TBVD 作為教師訓練 CWRU 學生

模型尺寸 資料量	VDAB 教師			TBVD 教師		
	Student	Assistant	Student (Assistant)	Student	Assistant	Student (Assistant)
35	0.893	0.928	0.886	0.898	0.925	0.879
71	0.969	0.982	0.977	0.975	0.981	0.971

表 5-6 使用 TBVD 與 CWRU 作為教師訓練 VDAB 學生

模型尺寸 資料量	TBVD 教師			CWRU 教師		
	Student	Assistant	Student (Assistant)	Student	Assistant	Student (Assistant)
65	0.727	0.813	0.737	0.720	0.803	0.736
132	0.851	0.928	0.862	0.851	0.942	0.878

5.3 基於多域多級教師知識蒸餾效果

除了使用助教進行多級知識蒸餾輔助訓練外，本論文亦進一步提出多個教師融合知識蒸餾遷移訓練，架構如圖 5-3 所示。此架構透過整合來自不同來源的知識，先透過其中兩組資料集，分別訓練教師模型 A 與教師模型 B，第三組資料集則用於訓練學生模型，實驗設計採用資料集間交叉輪替的方式，將三組資料集互相交換教師與學生角色，進行多次訓練與測試。




圖 5-3 多域教師訓練架構圖

在訓練過程中的權重分配方面，則比較了平均權重的方式，以及依照教師預測和真實標籤之間交叉熵損失的自動動態權重分配方法，在知識蒸餾訓練 CWRU 學生時實際的損失與權重分配值如圖 5-4 所示， w_1 為 VDAB 教師的權重 w_2 為 TBVD 教師的權重。由表 5-7、表 5-8 及表 5-9 的結果，顯示在不同教師組合下的訓練結果，在以雙教師訓練的結果中相比使用單一教師的訓練，使用平均權重可以有最高 4.4% 的提升，但有可能造成 2.1% 的下降，而使用動態權重則可以有最高 3.7% 的提升，最差也僅有 0.7% 的下降。

```
exp_loss_1: 0.00535262609 exp_loss_2: 0.00406245654 sum_exp_losses 0.00941508263
w_1: 0.431483924 w_2: 0.568516135
```

圖 5-4 多教師自動分配權重實際結果

表 5-7 使用 VDAB 與 CWRU 教師訓練 TBVD 學生

資料量 \ 模型	CWRU 教師 & VDAB 教師	
	平均	權重
72	0.736	0.698
182	0.825	0.829

表 5-8 使用 VDAB 與 TBVD 教師訓練 CWRU 學生

資料量 \ 模型	VDAB 教師&TBVD 教師	
	平均	權重
35	0.902	0.888
71	0.967	0.968

表 5-9 使用 CWRU 與 TBVD 教師訓練 VDAB 學生

資料量 \ 模型	CWRU 教師&TBVD 教師	
	平均	權重
65	0.706	0.727
132	0.860	0.861




圖 5-5 多域多級教師訓練架構圖

雙教師的多域多級教師訓練又可如圖 5-5：分為教師加助教以及助教加助教的兩種組合方式，分別訓練出教師模型 A 與教師模型 B，藉由兩個教師模型各自學習不同資料特性的知識，再以第三個資料集作為目標資料集，用於訓練助教模型，而後由教師加助教與助教加助教進行知識蒸餾續練學生。蒸餾訓練後的結果由表 5-10、表 5-11 及表 5-12 所示，教師與助教分別為使用不同的資料集時，相比使用單一教師訓練，使用自動分配權重最高提升 3.9%的；而教師與助教使用相同的資料集時，以平均權重可以有最高 3.2%的提升；最後，在同時使用兩個不同資料集的助教下，使用自動分配權重則可以有最高 3.3%的提升效果。

平均以及動態分配權重方面，平均分配權重在最佳情況下可以使學生模型提升 4.4%的準確度，但最差則可能造成 5.4%的下降；相較之下，動態分配權重表現更為穩定，最高提升可達 3.9%，而最差的影響僅為-2.9%。在導入助教模型方面，以 CWRU 為學生的情形下使用動態分配權重相比具有全面的提升，最高為 1.4%，以 VDAB 為學生的情形下使用平均權重的效果則相對較好，最高為 2.3%，而以 TBVD 為學生的情形下使用助教模型並無顯著效果，綜上所述，兩種權重的方式以多教師與助教進行知識蒸餾，相比單教師整體平均皆有約 1%的提升；同時，利用動態權重相比平均權重，產生負面效果較小，更適合落地應用，因此後續實驗中將以動態分配權重為主。

表 5-10 使用 VDAB 與 CWRU 的不同組合訓練 TBVD 學生

模型 資料量	CWRU 教師 & VDAB 助教		CWRU 助教 & VDAB 教師		CWRU 助教 & VDAB 助教		CWRU 教師 & CWRU 助教		VDAB 教師 & VDAB 助教	
	平均	權重	平均	權重	平均	權重	平均	權重	平均	權重
72	0.700	0.731	0.696	0.671	0.710	0.692	0.716	0.692	0.721	0.681
182	0.819	0.815	0.816	0.807	0.832	0.825	0.814	0.820	0.824	0.806

表 5-11 使用 VDAB 與 TBVD 的不同組合訓練 CWRU 學生

模型 資料量	VDAB 教師 & TBVD 助教		VDAB 助教 & TBVD 教師		VDAB 助教 & TBVD 助教		VDAB 教師 & VDAB 助教		TBVD 教師 & TBVD 助教	
	平均	權重	平均	權重	平均	權重	平均	權重	平均	權重
35	0.844	0.900	0.876	0.901	0.889	0.899	0.905	0.902	0.891	0.893
71	0.968	0.980	0.968	0.977	0.971	0.976	0.973	0.975	0.970	0.971

表 5-12 使用 TBVD 與 CWRU 的不同組合訓練 VDAB 學生

模型 資料量	CWRU 教師 & TBVD 助教		CWRU 助教 & TBVD 教師		CWRU 助教 & TBVD 助教		CWRU 教師 & CWR 助教		TBVD 教師 & TBVD 助教	
	平均	權重	平均	權重	平均	權重	平均	權重	平均	權重
65	0.729	0.730	0.714	0.707	0.708	0.707	0.727	0.727	0.714	0.711
132	0.872	0.852	0.876	0.845	0.856	0.875	0.869	0.849	0.853	0.867




圖 5-6 多域多級教師訓練架構圖(雙教師單助教)

雙教師單助教的多域多級教師訓練架構如圖 5-6，分別訓練出教師模型 A 與教師模型 B，藉由兩個教師模型各自學習不同資料特性的知識，再以第三個資料集作為目標資料集，用於訓練助教模型，而後由兩個教師模型與一個助教模型同步進行知識蒸餾續練學生。訓練結果由表 5-13、表 5-14 及表 5-15 所示，以雙教師與單助教聯合進行蒸餾相比

表 4-16 到表 4-18 單獨訓練的結果，準確率具有全面的提升；且相比表 5-7 到表 5-12 雙教師訓練的結果，具有接近的效果。

表 5-13 使用雙教師單助教組合訓練 TBVD 學生

模型 資料量	CWRU 教師 & VDAB 教師 &VDAB 助教	CWRU 教師 & VDAB 教師 &CWRU 助教
72	0.626	0.624
182	0.769	0.773

表 5-14 使用雙教師單助教組合訓練 CWRU 學生

模型 資料量	TBVD 教師 & VDAB 教師 &VDAB 助教	TBVD 教師 & VDAB 教師 &TBVD 助教
35	0.888	0.901
71	0.980	0.981

表 5-15 使用雙教師單助教組合訓練 VDAB 學生

模型 資料量	TBVD 教師 & CWRU 教師 &CWRU 助教	TBVD 教師 & CWRU 教師 &TBVD 助教
65	0.738	0.729
132	0.867	0.865




圖 5-7 多域多級教師訓練架構圖(雙教師雙助教)

雙教師雙助教的多域多級教師訓練架構如圖 5-7，分別訓練出教師模型 A 與教師模型 B，藉由兩個教師模型各自學習不同資料特性的知識，再以第三個資料集作為目標資料集，用於訓練助教模型，而後由兩個教師模型與兩個助教模型同步進行知識蒸餾續練學生。由表 5-16、表 5-17 及表 5-18 的訓練結果所示，以 TBVD 為學生模型，當資料筆數為 72 筆時，使用雙教師單助教的最佳準確率為 0.626，而雙教師雙助教架構則為 0.613，略有下降；但在資料筆數達 182 筆時，準確率由雙教師單助教的 0.773 提升至 0.791；針對 CWRU 學生模型，雙教師雙助教訓練架構下的準確率分別為 0.897 與 0.966，略低於雙教師單助教的 0.901 與 0.981；VDAB 學生模型部分，在資料筆數為 132 筆時，雙教師雙助教架構達到 0.859 的準確率，略低於雙教師單助教架構下的 0.865，而在資料筆數較少時，雙教師雙助教則略低於雙教師單助教的 0.729 對比 0.738，顯示在小樣本下可能因教師模型過多導致學生過擬合風險，但在資料量充足的情況下，多架構能有效增強泛化能力，提供學生模型更豐富的學習訊息。

表 5-16 各種教師組合訓練 TBVD 學生

	VDAB 教師			CWRU 教師		
模型 資料量	Student	Assistant	Student (Assistant)	Student	Assistant	Student (Assistant)
72	0.692	0.837	0.711	0.700	0.834	0.713
182	0.792	0.929	0.842	0.822	0.934	0.863
	CWRU 教師 & VDAB 教師			VDAB 助教&TBVD 助教		
	平均	權重		平均	權重	
72	0.736	0.698		0.710	0.692	
182	0.825	0.829		0.832	0.825	
	CWRU 教師 & VDAB 助教			CWRU 助教 & VDAB 教師		
72	0.700	0.731		0.696	0.671	
182	0.819	0.815		0.816	0.807	
	CWRU 教師 & CWRU 助教			VDAB 教師 & VDAB 助教		
72	0.716	0.692		0.721	0.681	
182	0.814	0.820		0.824	0.806	
	CWRU 教師 & VDAB 教師&VDAB 助教		CWRU 教師 & VDAB 教師&CWRU 助教	CWRU 教師 & VDAB 教師&CWRU 助教&VDAB 助教		
72	0.626		0.624	0.613		
182	0.769		0.773	0.791		

表 5-17 各種教師組合訓練 CWRU 學生

	VDAB 教師			TBVD 教師		
模型 資料量	Student	Assistant	Student (Assistant)	Student	Assistant	Student (Assistant)
35	0.893	0.928	0.886	0.898	0.925	0.879
71	0.969	0.982	0.977	0.975	0.981	0.971
	VDAB 教師&TBVD 教師			VDAB 助教&TBVD 助教		
	平均		平均	平均		權重
35	0. 902		0. 888	0.889		0.899
71	0. 967		0. 968	0.971		0.976
	VDAB 教師&TBVD 助教			VDAB 助教&TBVD 教師		
35	0.844		0.900	0.876		0.901
71	0.968		0.980	0.968		0.977
	VDAB 教師&VDAB 助教			TBVD 教師&TBVD 助教		
35	0.905		0.902	0.891		0.893
71	0.973		0.975	0.970		0.971
	TBVD 教師 & VDAB 教師&VDAB 助教		TBVD 教師 & VDAB 教師 &TBVD 助教	TBVD 教師 & VDAB 教師 教師&TBVD 助教&VDAB 助教		
35	0.888		0.901	0.897		
71	0.980		0.981	0.966		

表 5-18 各種教師組合訓練 VDAB 學生

	TBVD 教師			CWRU 教師		
模型 資料量	Student	Assistant	Student (Assistant)	Student	Assistant	Student (Assistant)
65	0.727	0.813	0.737	0.720	0.803	0.736
132	0.851	0.928	0.862	0.851	0.942	0.878
	CWRU 教師&TBVD 教師			CWRU 助教&TBVD 助教		
	平均		平均	平均		權重
65	0.706		0.727	0.708		0.707
132	0.860		0.861	0.856		0.875
	CWRU 教師&TBVD 助教			CWRU 助教&TBVD 教師		
65	0.729		0.730	0.714		0.707
132	0.872		0.852	0.876		0.845
	CWRU 教師&CWR 助教			TBVD 教師&TBVD 助教		
65	0.727		0.727	0.714		0.711
132	0.869		0.849	0.853		0.867
	TBVD 教師 & CWRU 教師&CWRU 助教		TBVD 教師 & CWRU 教 師&TBVD 助教	TBVD 教師 & CWRU 教 師&TBVD 助教&CWRU 助教		
65	0.738		0.729	0.729		
132	0.867		0.865	0.859		

5.4 硬體加密結果

本論文的加密訓練流程如圖 5-8，在機邊端(Local)開始訓練流程後，會先將收集好的震動資料透過 AES 加密演算法進行加密確保資料在傳輸過程中的機密性後，透過 HTTP 將資料傳送至遠端伺服器(Server)。伺服器端收到資料封包後，進行解密並還原出原始的震動資料，資料解碼成功，會被輸入已部署在伺服器端的教師模型中進行辨識，教師模型推論完成後，系統會再次對這些辨識輸出進行加密處理，最後將結果回傳給 Local 端。Local 端在收到伺服器回傳的教師模型輸出結果之後，會先進行解密，而後進行知識蒸餾訓練，以教師模型之輸出作為知識基礎來訓練學生模型，進一步強化 Local 端的模型性能並完成邊緣端的檢測任務部署。

該流程部署在 Raspberry Pi 5 的邊緣端平台上，使用 CWRU 的 35 筆少量資料進行學生的知識蒸餾訓練，訓練時間由表 5-19 中所示，在邊緣平台上，Raspberry Pi 5 對未加密資料的訓練時間為 6.39 秒，透過功率計測量總能量消耗為 16.9J，而加入加解密流程進行訓練後，則增加 1.21 秒，能量消耗增加 3.7J。




圖 5-8 Local 端與 Server 端加密訓練流程圖

表 5-19 加密時間成本與功耗比較

Platform	Unencrypted Training time	Power consumption	Encrypted Training time	Power consumption
Raspberry Pi 5	6.39s	16.9J	7.79s	20.6J

如表 5-20 所示，伺服器端的加密和解密性能模擬，比較單線程和多線程的性能，用以證明在多個客戶端請求下的效率。使用單線程處理單個特徵向量的加密與傳輸，時間為 1.0131 秒，解密時間為 1.0002 秒；對於 100 個特徵向量以單線程進行順序處理，加密時間為 101.0217 秒，解密時間為 101.0031 秒；處理 400 個特徵向量時，數據均勻分佈在 4 個線程中，在這種情況下，總加密時間為 107.4449 秒，總解密時間為 107.2223 秒。通過利用多線程，系統可以在同一時間範圍內處理更多數據，從而提高可擴展性和整體性能。

表 5-20 加解密性能

	1 feature vector (1 thread)	100 feature vector (1 thread)	400 feature vector (4 threads)
Encryption	1.0131s	101.0217s	107.4449s
Decryption	1.0002s	101.0031s	107.2223s

5.5 小結

本章針對三個資料集設計訓練架構，並測試多域多級知識蒸餾的可行性與有效性，透過知識蒸餾可利用少量的資料以及輕量化的模型實現遷移學習的效果；而後，針對本論文提出的加密演算法，於 Raspberry Pi 5 及 PC 進行驗證，並評估加密的時間成本與能耗。



第6章 結論與未來展望

6.1 結論

本論文針對軸承故障診斷的應用，提出結合多域多級教師以及加密傳輸之知識蒸餾架構，並成功實作於機邊端嵌入式平台。為解決學生模型在小樣本訓練情境下學習能力不足的問題，本文設計多種教師與助教組合方式，進行跨域資料與多級的知識蒸餾，驗證不同架構對學生模型準確率之影響。

實驗部分分別針對 CWRU、TBVD 與 VDAB 三組軸承振動資料集進行多輪交叉訓練與測試，結果顯示，利用相似結構的教師與學生進行多教師知識融合相較於單一教師，準確率提升 1~4%；而引入助教模型後，蒸餾效果再提升 1~3%，其中以「教師+助教」與「助教+助教」雙源蒸餾效果最佳。雙教師單助教與雙教師雙助教訓練架構亦在樣本數不同的情境下進行比較，顯示當資料量充足時，教師數量越多對模型泛化能力越具幫助。除了演算法外，本論文亦著重於邊緣部署的可行性，使用 Raspberry Pi 5 作為運算平台，設計基於裝置 MAC 位址的金鑰產生機制，搭配 SHA-256 雜湊與 AES-CTR 模式進行資料加密與解密，確保伺服器與邊緣裝置間資料傳輸的安全性。整體系統具備低耗能、模型輕量化與高準確率的特性，展示出於智慧工業、設備診斷等應用場域的可行性。

綜上所述，本論文提出之多域多級知識蒸餾與安全訓練機制，成功實現模型壓縮與準確率兼具的目標，並為未來深度學習模型於工業場域中的部署提供一套有效的解決方案。

6.2 未來展望

由本論文實驗結果可知，多教師融合與助教協同蒸餾能有效提升學生模型的辨識能力，透過實驗分析結果，未來可朝以下幾個方向持續深化：

6.2.1 樣本收集問題

本論文使用網路公開數據集進行系統模擬與演算法驗證，雖已展現所提出架構於不同資料來源下的穩定性與準確性，然而於實際工業應用場景中存在更多外界的干擾。為此，未來期望能與產業界或設備製造商建立長期合作關係，導入來自現場的實際感測數據進行訓練與測試，進一步驗證本系統於真實場域中之可行性與適應性。

6.2.2 邊緣端平台問題

本論文目前僅於 Raspberry Pi 平台進行驗證，已證實在中等運算資源下具備良好的模型部署與推論能力。然而，為進一步強化本系統於極低功耗與資源受限環境中的應用，未來可延伸至 MCU 平台進行部署與測試。由於 MCU 通常系統頻率較低、記憶體有限與無作業系統等，將本論文所提出之架構應用於 MCU 上，需針對模型大小、運算流程與記憶體使用進行更嚴格的優化設計。透過在 MCU 平台的實際測試，可驗證本系統在超低資源條件下的可行性與效能表現，進一步推動低功耗、輕量化、可攜式設備的實際落地。

6.2.3 演算法問題

本論文主要採用 CNN 結合知識蒸餾進行軸承故障診斷，並搭配動態權重分配策略以提升多域蒸餾效果。未來在演算法方面可導入注意力機制（Attention Mechanism）以強化模型對時序特徵的辨識能力，提升對震動訊號中微弱但關鍵部分的敏感度。此外，為提升工業應用的可靠性，未來可引入可解釋性模組，讓模型能提供故障判斷依據。



參考文獻

- [1] 行政院智慧國家推動小組, "臺灣 AI 行動計畫 2.0", Feb., 2023, 檢自 : <https://digi.nstc.gov.tw/File/7C71629D702E2D89> (Dec. 2, 2024)
- [2] P. Voigt and A. Von dem Bussche, "The eu general data protection regulation (gdpr)," *A practical guide, 1st ed.*, Cham: Springer International Publishing, vol. 10, no. 3152676, pp. 10–5555, 2017.
- [3] 新通訊, "邊緣 AI 促 MCU 設計再進化", Feb., 2024, 檢自 : https://www.2cm.com.tw/2cm/zh-tw/market/26D3C71B2FC4445C9B3851B53F565F13#google_vignette (Dec. 10, 2024)
- [4] M. Cerrada et al., "A review on data-driven fault severity assessment in rolling bearings," (in English), *Mech Syst Signal Pr*, vol. 99, pp. 169–196, Jan 15 2018, doi: 10.1016/j.ymssp.2017.06.012.
- [5] N.-H. Kim, D. An, and J.-H. Choi, *Prognostics and Health Management of Engineering Systems : An Introduction*, 1st ed. Cham: Springer International Publishing : Imprint: Springer,, 2017, pp. 1
- [6] F. Jia, Y. G. Lei, L. Guo, J. Lin, and S. B. Xing, "A neural network constructed by deep learning technique and its application to intelligent fault diagnosis of machines," (in English), *Neurocomputing*, vol. 272, pp. 619–628, Jan 10 2018, doi: 10.1016/j.neucom.2017.07.032.
- [7] Y. Hua, J. Guo, and H. Zhao, "Deep belief networks and deep learning," in *Proceedings of 2015 international conference on intelligent computing and internet of things*, 2015: IEEE, pp. 1–4.
- [8] H. Shao, H. Jiang, F. Wang, and H. Zhao, "An enhancement deep feature fusion method for rotating machinery fault diagnosis," *Knowledge-Based Systems*, vol. 119, pp. 200–220, 2017.
- [9] H. Liu, J. Zhou, Y. Zheng, W. Jiang, and Y. Zhang, "Fault diagnosis of rolling bearings with recurrent neural network-based autoencoders," *ISA transactions*, vol. 77, pp. 167–178, 2018.
- [10] C. Li, S. Zhang, Y. Qin, and E. Estupinan, "A systematic review of deep transfer learning for machinery fault diagnosis," *Neurocomputing*, vol. 407, pp. 121–135, 2020.
- [11] L. Deng, G. Li, S. Han, L. Shi, and Y. Xie, "Model compression and hardware acceleration for neural networks: A comprehensive survey," *Proceedings of the IEEE*, vol. 108, no. 4, pp. 485–532, 2020.
- [12] A. Alkhulaifi, F. Alsahli, and I. Ahmad, "Knowledge distillation in deep learning and its applications," *PeerJ Computer Science*, vol. 7, p. e474, 2021.
- [13] S. Feng, H. Zhang, B. Xi, C. Zhao, Y. Li, and J. Chanussot, "Cross-domain few-shot learning based on decoupled knowledge distillation for hyperspectral image classification," *IEEE Transactions on Geoscience and Remote Sensing*, 2024.
- [14] H. Pang and K.-L. Tan, "Authenticating query results in edge computing," in *Proceedings. 20th International Conference on Data Engineering*, 2004: IEEE, pp. 560–571.
- [15] A. M. Ghosh and K. Grolinger, "Edge-cloud computing for Internet of Things data analytics: Embedding intelligence in the edge with deep learning," *IEEE Transactions on Industrial Informatics*, vol. 17, no. 3, pp. 2191–2200, 2020.
- [16] B. Chen, J. Wan, A. Celesti, D. Li, H. Abbas, and Q. Zhang, "Edge computing in IoT-based manufacturing," *IEEE Communications Magazine*, vol. 56, no. 9, pp.

- 103–109, 2018.
- [17] I. Sittón-Candanedo, R. S. Alonso, S. Rodríguez-González, J. A. García Coria, and F. De La Prieta, "Edge computing architectures in industry 4.0: A general survey and comparison," in *International Workshop on Soft Computing Models in Industrial and Environmental Applications*, 2019: Springer, pp. 121–131..
 - [18] V. K. Prasad, M. D. Bhavsar, and S. Tanwar, "Influence of monitoring: Fog and edge computing," *Scalable Computing: Practice and Experience*, vol. 20, no. 2, pp. 365–376, 2019.
 - [19] S. Cass, "Nvidia makes it easy to embed AI: The Jetson nano packs a lot of machine-learning power into DIY projects-[Hands on]," *IEEE Spectrum*, vol. 57, no. 7, pp. 14–16, 2020.
 - [20] Q. Tong *et al.*, "Edge AI-enabled chicken health detection based on enhanced FCOS-Lite and knowledge distillation," *Computers and Electronics in Agriculture*, vol. 226, p. 109432, 2024.
 - [21] N. N. Dinh *et al.*, "Implementing deep learning on edge devices for snoring detection and reduction," *Computers in Biology and Medicine*, vol. 184, p. 109458, 2025.
 - [22] M. Chehrehzad, G. Kecibas, C. Besirova, U. Uresin, M. Irican, and I. Lazoglu, "Tool wear prediction through AI-assisted digital shadow using industrial edge device," *Journal of Manufacturing Processes*, vol. 113, pp. 117–130, 2024.
 - [23] S. K. Bhoi *et al.*, "Intelligent data-driven condition monitoring of power electronics systems using smart edge–cloud framework," *Internet of Things*, vol. 26, p. 101158, 2024.
 - [24] J. Zhang, B. Chen, Y. Zhao, X. Cheng, and F. Hu, "Data security and privacy-preserving in edge computing paradigm: Survey and open issues," *IEEE access*, vol. 6, pp. 18209–18237, 2018.
 - [25] A. S. Hosen, P. K. Sharma, I.-H. Ra, and G. H. Cho, "SPTM-EC: A security and privacy-preserving task management in edge computing for IIoT," *IEEE Transactions on Industrial Informatics*, vol. 18, no. 9, pp. 6330–6339, 2021.
 - [26] K. Li, X. Han, Y. Yang, S. Wang, R. Shi, and J. Li, "A novel edge computing offloading and privacy-preserving scheme for energy Internet," in *2021 IEEE 5th International Conference on Cryptography, Security and Privacy (CSP)*, 2021: IEEE, pp. 79–83.
 - [27] C.-W. Hung, W.-T. Li, W.-L. Mao, and P.-C. Lee, "Design of a chamfering tool diagnosis system using autoencoder learning method," *Energies*, vol. 12, no. 19, p. 3708, 2019.
 - [28] C.-W. Hung, C.-H. Lee, C.-C. Kuo, and S.-X. Zeng, "SoC-based early failure detection system using deep learning for tool wear," *Ieee Access*, vol. 10, pp. 70491–70501, 2022.
 - [29] C.-W. Hung, S.-X. Zeng, C.-H. Lee, and W.-T. Li, "End-to-end deep learning by MCU implementation: an intelligent gripper for shape identification," *Sensors*, vol. 21, no. 3, p. 891, 2021.
 - [30] C.-W. Hung, J.-R. Wu, and C.-H. Lee, "Device light fingerprints identification using MCU-based deep learning approach," *IEEE Access*, vol. 9, pp. 168134–168140, 2021.
 - [31] C.-W. Hung, C.-Y. Tsai, and C.-H. Lee, "Enhancing edge-based federated learning with privacy-preserving gradient transmission for tool wear detection," *IEEE Sensors Journal*, vol. 24, no. 12, pp. 19780–19790, 2024.
 - [32] B. Jacob *et al.*, "Quantization and training of neural networks for efficient integer-

- arithmetic-only inference," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 2704–2713.
- [33] S. Han, J. Pool, J. Tran, and W. Dally, "Learning both weights and connections for efficient neural network," *Advances in neural information processing systems*, vol. 28, 2015.
 - [34] G. Hinton, O. Vinyals, and J. Dean, "Distilling the knowledge in a neural network," *arXiv preprint arXiv:1503.02531*, 2015.
 - [35] M. Sepahvand, F. Abdali-Mohammadi, and A. Taherkordi, "Teacher–student knowledge distillation based on decomposed deep feature representation for intelligent mobile applications," *Expert Systems with Applications*, vol. 202, p. 117474, 2022.
 - [36] Z. Shi, J. Chen, Y. Zi, and Z. Chen, "DecouplingNet: A stable knowledge distillation decoupling net for fault detection of rotating machines under varying speeds," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 35, no. 8, pp. 11276–11290, 2023.
 - [37] M. Kang and S. Kang, "Data-free knowledge distillation in neural networks for regression," *Expert Systems with Applications*, vol. 175, p. 114813, 2021.
 - [38] Y. Zhou, J. Wang, and Z. Wang, "Bearing faulty prediction method based on federated transfer learning and knowledge distillation," *Machines*, vol. 10, no. 5, p. 376, 2022.
 - [39] C. Shen, X. Wang, J. Song, L. Sun, and M. Song, "Amalgamating knowledge towards comprehensive classification," in *Proceedings of the AAAI Conference on Artificial Intelligence*, 2019, vol. 33, no. 01, pp. 3068–3075.
 - [40] X. Cheng, Z. Zhang, W. Weng, W. Yu, and J. Zhou, "DE-MKD: decoupled multi-teacher knowledge distillation based on entropy," *Mathematics*, vol. 12, no. 11, p. 1672, 2024.
 - [41] Y. Liu, W. Zhang, and J. Wang, "Adaptive multi-teacher multi-level knowledge distillation," *Neurocomputing*, vol. 415, pp. 106–113, 2020.
 - [42] R. K. Singleton, E. G. Strangas, and S. Aviyente, "Extended Kalman filtering for remaining-useful-life estimation of bearings," *IEEE Transactions on Industrial Electronics*, vol. 62, no. 3, pp. 1781–1790, 2014.
 - [43] Y. Lei, N. Li, L. Guo, N. Li, T. Yan, and J. Lin, "Machinery health prognostics: A systematic review from data acquisition to RUL prediction," *Mech Syst Signal Pr*, vol. 104, pp. 799–834, 2018.
 - [44] K. L. Tsui, N. Chen, Q. Zhou, Y. Hai, and W. Wang, "Prognostics and health management: A review on data driven approaches," *Mathematical Problems in Engineering*, vol. 2015, no. 1, p. 793161, 2015.
 - [45] Y. Cheng, M. Lin, J. Wu, H. Zhu, and X. Shao, "Intelligent fault diagnosis of rotating machinery based on continuous wavelet transform-local binary convolutional neural network," *Knowledge-Based Systems*, vol. 216, p. 106796, 2021.
 - [46] A. N. Saberi, A. Belahcen, J. Sobra, and T. Vaimann, "LightGBM-based fault diagnosis of rotating machinery under changing working conditions using modified recursive feature elimination," *IEEE Access*, vol. 10, pp. 81910–81925, 2022.
 - [47] J. Xie, Z. Li, Z. Zhou, and S. Liu, "A novel bearing fault classification method based on XGBoost: The fusion of deep learning-based features and empirical features," *IEEE Transactions on Instrumentation and Measurement*, vol. 70, pp. 1–9, 2020.
 - [48] H. Zhong, S. Yu, H. Trinh, Y. Lv, R. Yuan, and Y. Wang, "Multiassistant knowledge distillation for lightweight bearing fault diagnosis based on decreasing threshold

- channel pruning," *IEEE Sensors Journal*, vol. 24, no. 1, pp. 486–494, 2023.
- [49] W. Guo, X. Li, and Z. Shen, "A lightweight residual network based on improved knowledge transfer and quantized distillation for cross-domain fault diagnosis of rolling bearings," *Expert Systems with Applications*, vol. 245, p. 123083, 2024.
- [50] B. Yegnanarayana, *Artificial neural networks*. PHI Learning Pvt. Ltd., 2009.
- [51] Z. Li, F. Liu, W. Yang, S. Peng, and J. Zhou, "A survey of convolutional neural networks: analysis, applications, and prospects," *IEEE transactions on neural networks and learning systems*, vol. 33, no. 12, pp. 6999–7019, 2021.
- [52] L. Wang and K.-J. Yoon, "Knowledge distillation and student-teacher learning for visual intelligence: A review and new outlooks," *IEEE transactions on pattern analysis and machine intelligence*, vol. 44, no. 6, pp. 3048–3068, 2021.
- [53] M. A. Hossain, M. K. Islam, S. K. Das, and M. A. Nashiry, "Cryptanalyzing of message digest algorithms MD4 and MD5," *International Journal on Cryptography and Information Security (IJCIS)*, vol. 2, no. 1, pp. 1–13, 2012.
- [54] H. Handschub and H. Gilbert, "Evaluation report security level of cryptography–sha-256," *Journal of Women s Health*, 2002.
- [55] J.-P. Aumasson, S. Neves, Z. Wilcox-O’Hearn, and C. Winnerlein, "BLAKE2: simpler, smaller, fast as MD5," in *International Conference on Applied Cryptography and Network Security*, 2013: Springer, pp. 119–135.
- [56] W. Stallings, "The whirlpool secure hash function," *Cryptologia*, vol. 30, no. 1, pp. 55–67, 2006.
- [57] K. K. A. Farag, H. H. Shehata, and H. M. El-Batsh, "Mobile robot obstacle avoidance based on neural network with a standardization technique," *Journal of Robotics*, vol. 2021, no. 1, p. 1129872, 2021.
- [58] J. Bergstra and Y. Bengio, "Random search for hyper-parameter optimization," *The journal of machine learning research*, vol. 13, no. 1, pp. 281–305, 2012.
- [59] B. Shahriari, K. Swersky, Z. Wang, R. P. Adams, and N. De Freitas, "Taking the human out of the loop: A review of Bayesian optimization," *Proceedings of the IEEE*, vol. 104, no. 1, pp. 148–175, 2015.
- [60] Brjapon, "CWRU Bearing Dataset". <https://www.kaggle.com/datasets/brjapon/cwru-bearing-datasets>, 2023.
- [61] D. Kumar, S. Mehran, M. Z. Shaikh, M. Hussain, B. S. Chowdhry, and T. Hussain, "Triaxial bearing vibration dataset of induction motor under varying load conditions," *Data in Brief*, vol. 42, p. 108315, 2022.
- [62] M. A. Ismail, J. Windelberg, A. Bierig, I. Bravo, and A. Arnaiz, "Vibration Data for Axial Ball Bearings and Spall Faults", *Mendeley Data*, V2, 2022.