

第四章 知識蒸餾

本章只在建立兩階段多教師知識蒸餾架構，透過導入多教師聯合蒸餾與 Teacher Assistant (TA) 機制，緩解單一教師與學生模型間能力差距過大所導致的知識傳遞效率不佳問題。我們設計兩階段蒸餾流程：第一階段由兩個 Teacher 模型 (EfficientNet 系列) 聯合蒸餾出 TA 模型 (ResNet20)；第二階段則由 Teacher1、Teacher2 與 TA 共同蒸餾出最終 Student 模型 (CNN8)。

根據本章實驗結果顯示，Teacher1 與 Teacher2 之準確率分別為 96.17% 與 94.81%，TA 模型之準確率為 92.33%，最終 Student 模型與測試集上達到 87.74% 準確率，Performance Retention (相對於三個知識來源中表現最佳者) 為 91.24%。進一步觀察各類別表現，Student 模型在 Normal 類別上表現優異 (F1-score 0.95)，但在 Ischemia 類別之 Recall 僅 0.54，顯示模型對缺血性中風樣本存在明顯的漏判傾向。

實驗方法

資料庫

本實驗採用 CT 腦中風三分類資料集，涵蓋 Normal、Ischemia、Hemorrhagic 三個類別，影像來源分別存放於對應資料夾下之 PNG 格式檔案。資料集依 64%/16%/20% 比例切分為訓練集、驗證集與測試集，並採與分層抽樣 (Stratified Sampling) 確保各集合中類別比例與原始資料集一致，避免因類別分布不均衡而影響模型評估之公正性。

表 x. 資料集各類別樣本統計表

類別	樣本數	佔比
Normal	4427	66.6%
Ischemia	1130	17.0%
Hemorrhagic	1093	16.4%
總計	6650	100%

須說明的是，資料集本身存在類別分類不均的問題，Normal 類別樣本數約為 Ischemia 或 Hemorrhagic 的 4 倍。本研究與資料切分階段僅以分層抽樣維持各集合類別比例一致，訓練過程中的損失函數 (Student Loss weight 或 oversampling)。此設計選擇集其對模型表現 (特別是少數類別) 之影顯，將於後續章節結果中進一步討論。

資料前處理

本研究採用自訂之 `tf.data.Dataset` 前處理流程，將同一張 PNG 影像於單次讀取後，同步 `resize` 為兩種解析度並整理為三份對應輸出，以 `tuple` 形式回傳，確保 Teacher1、Teacher2、TA 與 Student 四個模型於訓練與評估階段，皆能對應到同一組 image-label pair (表 x)

表 x.各模型輸入解析度對照表

	角色	輸入解析度
Teacher1 (EfficientNetB3)	指導來源教師模型	300*300
Teacher2 (EfficientNetB0)	指導來源教師模型	224*224
TA (ResNet20)	TA 模型	300*300
Student (CNN8)	最終學生模型	300*300

具體前處理流程如下：

1. 使用 `tf.io.read_file` 與 `tf.image.decode_png` 讀取原始 PNG 影像 (三通道)，並轉換為 `float32` 型態。
2. 對同一張影像分別以 `tf.image.resize` 縮放至 300*300 (供 Teacher1、TA、Student 使用) 與 224*224 (供 Teacher2 使用) 兩種尺寸。
3. 兩種尺寸的影像皆透過 EfficientNet 系列模型內建的 `preprocess_input` 函式進行像素值正規化，以符合各 EfficientNet 教師模型原始訓練時的輸入分布。
4. 類別標籤 (Normal / Ischemia / Hemorrhagic) 以 one-hot 編碼方式輸出，並與兩種解析度、三份對應影像組成 `((img_t1,img_t2,img_s),label)` 的資料結構，供後續蒸餾訓練同時取用。

此設計的動機在於：Teacher1 與 Teacher2 分別基於 EfficientNetB3 與 EfficientNetB0 訓練而成，其原始訓練解析度並不相同 (300*300 對 224*224)。若採用單一解析度餵入所有模型，將導致原生輸入解析度與模型不匹配之教師模型 (如 Teacher2) 特徵提取效果失真，進而影響其產生之 soft label 品質，最終降低蒸餾訓練的有效性。透過單次讀取、多尺寸輸出的資料流程設計，可在確保個模型皆於其原生訓練解析度下運作的同時，避免因分別建立資料集造成 image-label 對應不一致的風險。

模型架構

本研究之兩階段蒸餾架構共涉及四個模型：Teacher1、Teacher2 為以訓練完成之預訓練模型 (權重凍結，trainable = False)，TA 與 Student 則為蒸餾過程中訓練之目標模型，架構分別如表 x、表 x 所示。

教師模型：Teacher1 採用 EfficientNetB3、Teacher2 採用 EfficientNetB0，兩只皆為已於本資料集完成微調 (fine-tuned) 的訓練模型，於蒸餾過程中僅作為固定知識來源，不參與梯度更新。

表 x. TA 模型 (ResNet20) 架構

Layer Configuration	Output Channels	Stride
Conv → BN → ReLU	32	2
MaxPooling (3×3)	32	2
Residual Block ×3	16	1 (首層含 shortcut)
Residual Block ×3	32	2 (首層含 shortcut)
Residual Block ×3	64	2 (首層含 shortcut)
Global Average Pooling	-	-
Dropout (0.3)	-	-
Dense	Num_classes (3)	-

TA 模型採用簡化版 ResNet 架構 (ResNet20)，由 9 個殘差區塊 (Residual Block) 構成，通道數依序為 16、32、64，個階段首個區塊搭配 1*1 卷積之 shortcut 連接以匹配維度變化。模型最終以 Global Average Polling 取代全連接層以降低參數量，並於輸出前加入 Dropout (rate=0.3) 以緩解過擬合。

表 x. Student 模型 (CNN8) 架構

Layer Configuration	Output Channels
Conv → BN → ReLU → MaxPool	32
Conv → BN → ReLU → MaxPool	64
Conv → BN → ReLU → MaxPool	128
Conv → BN → ReLU → MaxPool	128
Conv → BN → ReLU → MaxPool	256
Conv → BN → ReLU → Global Average Pooling	512
Dense (ReLU)	128
Dropout (0.3)	-
Dense	Num_classes (3)

Student 模型為一自訂的輕量化 CNN (CNN8)，由 6 層卷積區塊構成，通道數依序遞增為 32、64、128、128、256、512，個卷積層後皆接 Batch Normalization 與 ReLU 活化函數，並以 MaxPooling 進行降採樣：最後一層卷積後改採 Global Average Pooling，接續一層 128 維全連接層 (ReLU) 與 Dropout (rate = 0.3)，最終輸出 3 維 logits 對應三個分類類別。相較於作為指導來源的 Teacher (EfficientNetB3/B0) 與 TA (ResNet20)，Student 模型結構更為精簡，此設計符合知識蒸餾的核心目標——在大幅降低模型參數量與運算成本之前提下，透過蒸餾機制盡可能保留教師模型的判斷能力。

訓練方法

本研究採用兩階段知識蒸餾架構進行訓練：第一階段由 Teacher1、Teacher2 聯合蒸餾出 TA 模型；第二階段則由 Teacher1、Teacher2 與訓練完成的 TA 模型三者共同蒸餾出最終 Student 模型（圖 x）。兩階段訓練過程共用的超參數設定如下：溫度參數 (Temperature) = 3.0、Alpha (Hard Loss 權重) = 0.7、訓練輪數 = 50 epochs、優化器採用 Adam (learning rate = 1e-3)。

蒸餾損失函數設計

兩階段訓練接採用相同的損失組合方式：總損失由 Student Loss (Hard Loss) 與 Distillation Loss (Soft Loss) 加權組成，如 (式 x)：

$$Loss = \alpha \cdot L_{\{student\}} + (1 - \alpha) \cdot L_{\{distill\}} \cdot T^2$$

其中 $L_{student}$ 為學生輸出與真實標籤 (one-hot) 間的 CategoricalCrossentropy； $L_{distill}$ 為學生輸出與指導來源軟標籤 (soft label) 間的 KLOivergence，兩者皆以溫度 T 對 logits 進行 softmax 平滑化處理，並於 T^2 以平衡梯度尺度。

第一階段：Teacher1 + Teacher2 → TA

第一階段中，Teacher1 與 Teacher2 的 soft label 依各自權重加權平均後，作為 TA 模型的蒸餾目標 (式 x)：

$$Soft_{\{teacher\}} = w_{\{1\}} \cdot softmax\left(\frac{Z_{\{T1\}}}{T}\right) + w_{\{2\}} \cdot softmax\left(\frac{Z_{\{T2\}}}{T}\right)$$

其中 Teacher1 權重 $w_1 = 0.6$ 、Teacher2 權重 $w_2 = 0.4$ ，此權重配置依兩個 Teacher 模型於資料集上之個別表現差異設定，使準確率較高的 Teacher1 於指導 TA 時佔有較大影響力。

第二階段：Teacher1 + Teacher2 + TA → Student

第二階段改採用「各指導來源獨立計算蒸餾損失後加權加總」的設計 (而非先平均 soft label 再計算單一蒸餾損失)，如 (式 x)：

$$L_{\{distill\}} = w_{\{T1\}} \cdot KL(Soft_{\{T1\}}, Soft_{\{student\}}) + w_{\{T2\}} \cdot KL(Soft_{\{T2\}}, Soft_{\{student\}}) \\ + w_{\{TA\}} \cdot KL(Soft_{\{TA\}}, Soft_{\{student\}})$$

三來源重設定為 Teacher1 = 0.25、Teacher2 = 0.25、TA = 0.50，TA 模型獲得最高權重。此設計呼應 Teacher Assistant Knowledge Distillation (TAKD) 的核心論點：TA 模型的容量介於 Teacher 與 Student 之間，其輸出的 soft label 分布較貼近 Student 模型實際可吸收之知識範圍，相較於容量差距過大的 Teacher 直接指導，更能有效縮小師生間的能力落差，提升知識傳遞效率。

模型儲存策略

訓練過程中以驗證損失 (val_loss) 作為監控指標，於每個 epoch 結束時判斷是否優於歷史最佳值，若是則儲存當下模型權重 (僅儲存內部實際運算的模型權重，而非整個蒸餾 Trainer 外殼)，確保最終評估所使用的模型為驗證集表現最佳者，而非訓練結束時之最終權重。

蒸餾策略對模型壓縮效率與分類表現的影響

本節旨在比較不同蒸餾策略下，Student 模型 (CNN8) 於大幅壓縮參數的前提下，對 Teacher 知識的保留程度與各類別分類表現之差異，藉此說明本研究最終選用「Teacher1 + Teacher2 + TA 三來源同時指導」(3 對 1) 架構的依據。

除了上述「3 對 1」設計外，本研究於架構探索階段亦嘗試過「TA 單獨作為 Stage2 唯一指導來源」(即「2 對 1 對 1」策略)，以及完全不採用蒸餾，直接以 hard label 訓練 Student 的作法 (baseline)。以下比較三者於測試集上的表現差異，說明最終選用 3 對 1 架構之依據。

無蒸餾 baseline 與三來源蒸餾的比較

表 x.無蒸餾 baseline 與 3 對 1 蒸餾的效能比較

模型	訓練方法	準確率	Hemorrhagic F1	Ischemia F1	Normal F1
CNN (無蒸餾 baseline)	直接以 hard label 訓練	92.03%	0.84	0.85	0.96
CNN8 (3 對 1 蒸餾)	Teacher1 + Teacher2 + TA 三來源蒸餾	87.74%	0.76	0.70	0.95

值得注意的是，未經蒸餾的 CNN8 baseline 於整體準確率及各類別 F1-score 上，皆優於經過三來源蒸餾之 Student 模型，尤其 Ischemia 類別差距最為明顯 (0.85 對 0.70)。此結果出看似與知識蒸餾的預期效益相悖，但須說明的是：(一) 本資料集標籤明確且樣本量充足 (訓練集逾 4200 張)，在此條件下，Student 模型直接以 hard label 學習已具備足夠的 監督訊號，蒸餾所提供的 soft label 額外資訊，其邊際效益本就有限；(二) 此 baseline 與蒸餾版 Student 的網路架構 (全連接層維度、Dropout rate) 及訓練超函數 (learning rate、正規化方式) 並未完全對其，兩者的差異無法完全歸因於「是否蒸餾」此單一變因。因此，本研究並未將知識蒸餾的核心價值定位於「超越直接訓練的準確率」，而是聚焦於太大幅壓縮模型容量 (Student 參數量遠小於 Teacher 之 EfficientNetB3/B0) 的前提下，探討不同蒸餾策略對知識保留效率與少數類別 (如 Ischemia) 判斷能力的影響，此為後續 4.2.2 節的比較重點。

兩階段蒸餾策略的比較：2 對 1 對 1 與 3 對 1

本章節比較兩種兩階段蒸餾策略下 Student 模型的表現差異：其一為「2 對 1 對 1」策略，即 Stage1 由 Teacher1、Teacher2 聯合蒸餾出 TA 模型後，Stage2 僅由 TA 單獨蒸餾出 Student；其二為本研究最終採用的「3 對 1」策略，即 Stage2 改由 Teacher1、Teacher2 與 TA 三者同時指導 Student。兩者 Stage1 (Teacher1、Teacher2 → TA) 完全相同，差異僅在 Stage2 的指導來源設計。

表 x.2 對 1 對 1 與 3 對 1 蒸餾策略的效能比較

策略	Stage2 指導來源	Student 準確率	Hemorrhagic F1	Ischemia F1	Normal F1
2 對 1 對 1	TA 單獨指導	77.22%	0.62	0.53	0.88
3 對 1	Teacher1 + Teacher2 +TA 同時 指導	87.74%	0.76	0.70	0.95

結果顯示，3 對 1 策略的 Student 模型於整體準確率及各類別 F1-score 上，皆明顯優於 2 對 1 對 1 策略，整體準確率差距達 10.52 葛百分點，其中 Ischemia 類別的 F1-score 差距亦達 0.17。此現象顯示，若 Stage2 僅由 TA 單獨作為指導來源，Student 模型的學習效果反而大幅劣化。

推測其原因可能在於：TA 模型本身是自 Teacher1、Teacher2 蒸餾而來的壓縮模型，其 soft label 分布相較於原始高容量 Teacher，已存在一定程度的資訊損耗。若 Stage2 的 Student 完全僅依賴 TA 的輸出進行學習，等同於在原始 Teacher 的知識傳遞至 Student 的路徑中，疊加了兩次壓縮損耗 (Teacher → TA、TA → Student)，使得 Student 最終所能習得知判斷能力受到侷限。相對地，3 對 1 策略讓 Student 於 Stage2 訓練過程中，同時保留與原始 Teacher1、Teacher2 的直接連結，僅將 TA 是為額外的輔助指導來源 (而非唯一來源)，使 Student 得以直接吸收高容量 Teacher 的知識，同時透過 TA 的居中指導緩解 Teacher 與 Student 間容量差距過大的問題，此設計較符合 Teacher Assistant Knowledge Distillation (TAKD) 機制的原始精神 —— TA 應作為橋接角色，而非取代原始 Teacher 的唯一知識來源。

惟仍須說明，本比較的兩組 Student 模型於 CNN8 架構細節（卷積層通道數、全連接層維度）上並未完全對齊（2 對 1 對 1 版本通道數為 16 → 32 → 64 → 128，3 對 1 版本為 32 → 64 → 128 → 128 → 256 → 512），故此效能差距亦可能部分源於模型容量差異，而非純粹歸因於蒸餾策略不同。此為本研究於探索不同蒸餾架構過程中留下的限制，後續研究若欲更嚴謹地驗證此現象，應在控制 Student 架構一致的前提下重新進行。

整體結果評估

本節彙整本研究最終採用的兩階段三來源蒸餾架構（Teacher1 + Teacher2 → TA；Teacher1 + Teacher2 + TA → Student）於測試集完整表現，最為本章實驗結果的總結。

表 x. 各模型測試集準確率比較

模型	角色	參數量層級	測試集準確率
Teacher1 (EfficientNetB3)	指導來源	大	96.17%
Teacher2 (EfficientNetB0)	指導來源	中	94.81%
TA (ResNet20)	中介模型	中小	92.33%
Student (CNN8)	最終模型	小	87.74%

Student 模型相對於三個指導來源中表現最佳者（Teacher1，96.17%）的效能保留率為 91.24%，顯示在大幅壓縮模型容量之前提下，仍能保留原始 Teacher 絕大部分的判斷能力。

表 x. Student 模型各類別分類表現

類別	Precision	Recall	F1-score	Specificity	NPV	ROC-AUC
Hemorrhagic	0.62	0.99	0.76	0.8785	0.9969	0.9935
Ischemia	0.98	0.54	0.70	0.9982	0.9138	0.9856
Normal	0.97	0.94	0.95	0.9416	0.8821	0.9870
Micro-average	-	-	-	-	-	0.9703

整體測試及準確率為 87.74%（樣本數 $n = 1330$ ，正確預測 1167 筆），以常態近似法計算的 95% 信賴區間為 [85.98%，89.51%]。

由各類別表現可觀察到，Student 模型於 Normal 類別上表現最穩定 (F1-score 0.95)，Hemorrhagic 類別雖 Recall 極高 (0.99)，但 Precision 偏低 (0.62)，顯示模型傾向將其他類別 (尤其 Normal) 誤判為 Hemorrhagic，導致偽陽性偏多；相對地，Ischemia 類別呈現相反模式 —— Precision 高達 0.98，但 Recall 僅 0.54，顯示模型對 Ischemia 樣本的判斷較為保守，容易將真實的缺血性中風樣本誤判為其他類別 (漏判)，此為本研究模型於臨床應用情境下最需留意的限制，因缺血性中風的漏判可能延誤治療時機，風險較偽陽性更高。

此外，各類別的 ROC-AUC 皆達 0.98 以上 (Micro-average AUC = 0.9703)，顯示模型在機率排序層面的整體判別能力仍屬良好，惟此指標與 Recall 偏低的現象並不衝突 —— AUC 反映模型對不同決策閾值下區辨能力，而目前預設的 0.5 閾值下 Ischemia 類別的召回率不足，意味著透過調整決策閾值或引入類別加權機制，仍有進一步優化空間，此將於本章最後的限制與未來研究方向中一併討論

本章限制與討論

綜合本章各節實驗結果，本研究於發展兩階段多來源知識蒸餾架構的過程中，觀察到以下數項限制，於此一併討論，作為後續研究改進方向。

類別分佈不平衡未經加權處理

本資料集三個類別間樣本數差距達 4 倍 (Normal 4427 張，Ischemia、Hemorrhagic 各約 1100 張)，然本研究於資料切分階段僅以分層抽樣維持各集合類別比一致，訓練過程中無論 Hard Loss 或 Distillation Loss，皆未針對少數類別進行加權處理 (如 class weight、oversampling)。此設計選擇可能是導致 Student 模型於 Ischemia 類別上 Recall 偏低 (0.54) 的主要原因之一，後續觀察研究可嘗試於損失函數中導入類別權重，或於資料層面採用過採樣策略，觀察對少數類別偵測能力的改善程度。

Ischemia 類別的低 Recall 為本研究最主要的限制

Student 模型於 Ischemia 類別呈現高 Precision (0.98)、低 Recall (0.54) 的不對稱表現，亦即模型對於判定為 Ischemia 的樣本有高度把握，但仍有近半數的真實缺血性中風未被正確偵測。於臨床應用情境下此類漏判風險高於誤判，因缺血性中風的延遲診斷可能錯失治療黃金時間。此限制的成因除類別不平衡外，亦可能與 Ischemia 於 CT 影像上的病灶特徵較不明顯，與 Normal 類別的影像差異較細微有關，後續研究可考慮增加 Ischemia 樣本數，引入病灶區域強化的前處理技術，或針對此類別調整決策閾值，以提升臨床可用性。

實驗過程中各版本 Student 架構未完全對齊

本章 4.2 節所比較的數個 Student 模型（無蒸餾 baseline、2 對 1 對 1 版、3 對 1 版）的網路架構與訓練超參數並未一致，此為研究過程中逐步探索不同蒸餾策略所留下的限制，使得部分比較結果（如 baseline 準確率高於蒸餾版本）無法完全歸因於單一變因。後續研究若欲更嚴謹地驗證蒸餾策略之效益，應於固定 Student 架構與超參數的前提下，僅改變指導來源設計進行控制實驗。

知識蒸餾的邊際效益隨資料充足程度而遞減

本研究觀察到，於標籤明確、樣本量充足的資料集條件下，Student 模型直接以 hard label 訓練的表現可能優於經蒸餾訓練的版本，顯示知識蒸餾的效益並非於所有情境下皆能展現。